

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

CARACTERIZAÇÃO DE ROCHA DIGITAL USANDO INTELIGÊNCIA ARTIFICIAL – APLICAÇÃO A SEGMENTAÇÃO DE IMAGENS

João Marcelo Cardoso Carvalho

Laboratório Engenharia Exploração e Produção de Petróleo
Universidade Estadual do Norte Fluminense Darcy Ribeiro

Macaé, Março 2021

Sumário

1 Introdução

2 Revisão Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

3 Metodologia

4 Desenvolvimento

Ferramenta de Anotação de Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação das Redes Neurais

Coleta de Resultados

5 Resultados

6 Conclusões

7 Bibliografia

Escopo do Problema

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

- É cada vez mais comum a aplicação de algoritmos de inteligência artificial nas mais diferentes áreas de pesquisa, principalmente na engenharia, graças ao aumento exponencial da capacidade de processamento dos computadores e seu baixo custo.
- O uso dessas metodologias se torna muito pertinente na engenharia de reservatórios, uma vez que a capacidade de prever e delimitar sua capacidade produtiva é essencial no âmbito econômico.

Escopo do Problema

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

- Métodos como análise petrofísica de testemunhos são extremamente úteis nesses aspectos, muitas vezes demandam um custo muito alto para serem realizadas devido aos equipamentos utilizados no processo, como porosímetro e permeâmetro, mas principalmente devido o custo para obter as amostras.
- São caros e destrutivas, logo a amostra é perdida assim que o estudo é concluído.

Escopo do Problema

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

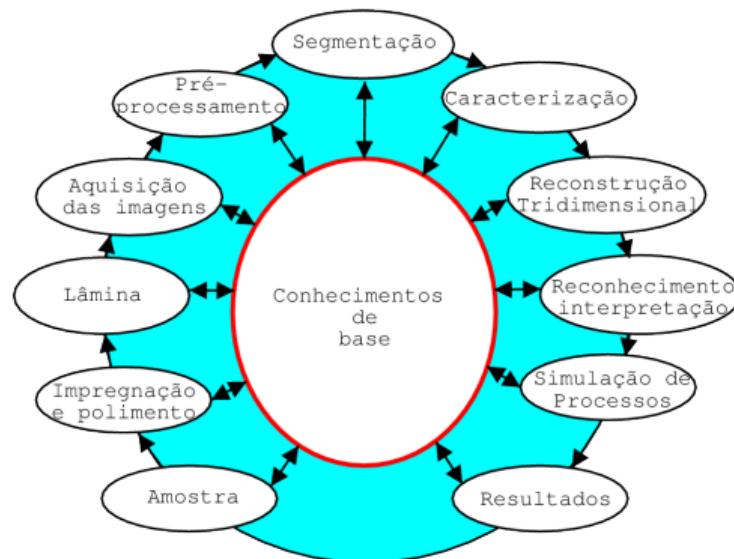


Figura: Conhecimentos de Base para Análise de Imagens de Rochas Reservatório.
[Fonte: (REGO; BUENO, 2010)].

Objetivo Geral

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

- Desenvolver métodos de inteligência artificial capazes de reconhecer padrões relevantes para a análise das propriedades petrofísicas em imagens de rochas reservatórios.

Objetivos Específicos

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

- Estudar diferentes métodos de aprendizagem de maquina e aprendizagem profundas aplicadas à análise de imagens.
- Estudar o comportamento dos métodos de IA em geometrias de poros complexas.
- Comparar resultados obtidos com aqueles já apresentados na literatura.
- Implementação de algorítmos em C++ e inclusão dos mesmos na biblioteca criada pela equipe do Laboratório de Desenvolvimento de Software Científico (`lib_ldsc`).

Descrição do Modelo

Introdução

Revisão
Bibliográfica

Lin et al. (2018)

Rubo et al. (2019)

Alqahtani et al. (2018)

Hébert et al. (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

- Segmentação de rochas baseada na porosidade calculada como limitador (*threshold*).
- Considera características petrofísicas das amostras.

Resultados

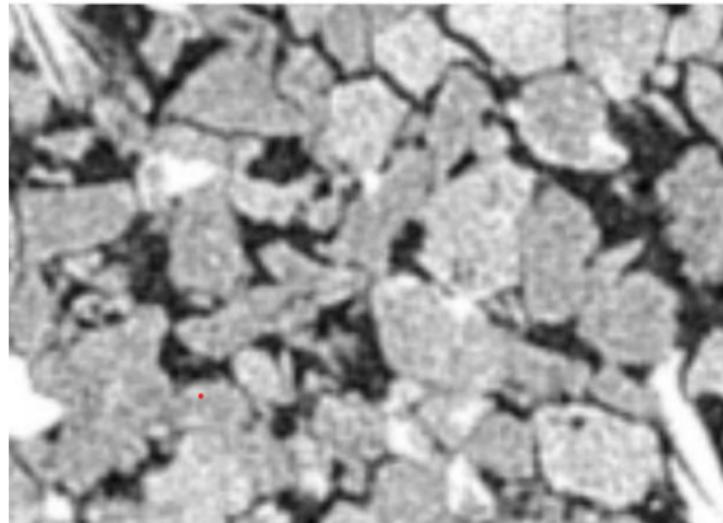


Figura: Imagem em escala de cinza de um arenito obtido por meio de tomografia computadorizada [Fonte: (LIN et al., 2018)].

Resultados

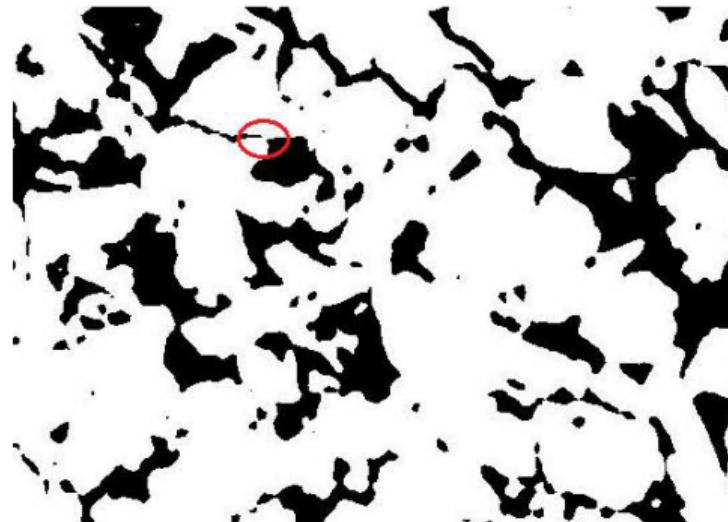


Figura: Imagem binarizada do arenito usando método comum para o cálculo da porosidade [Fonte: (LIN et al., 2018)].

Resultados

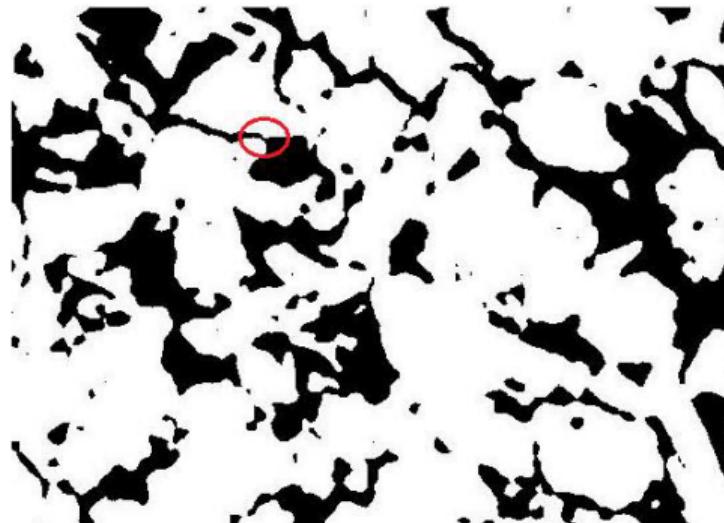


Figura: Imagem binarizada do arenito usando método baseado nas características petrofísicas [Fonte: (LIN et al., 2018)].

Descrição do Modelo

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

- Geração de modelos de classificação mineralógica.
- Filtros convolucionais para extração de informações de cada pixel.
- Redes neurais com 3 camadas de 45 neurônios, ativados por meio da função logística.
- Gradiente descendente estocástico como algoritmo de aprendizagem.

Estrutura Rede Neural

Introdução

Revisão

Bibliográfica

Lin et al. (2018)

Rubo et al. (2019)

Alqahtani et al. (2018)

Hébert et al. (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

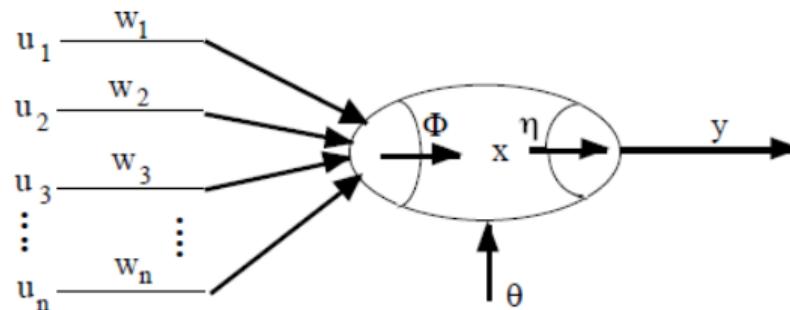


Figura: Representação de um neurônio artificial.

Estrutura Rede Neural

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

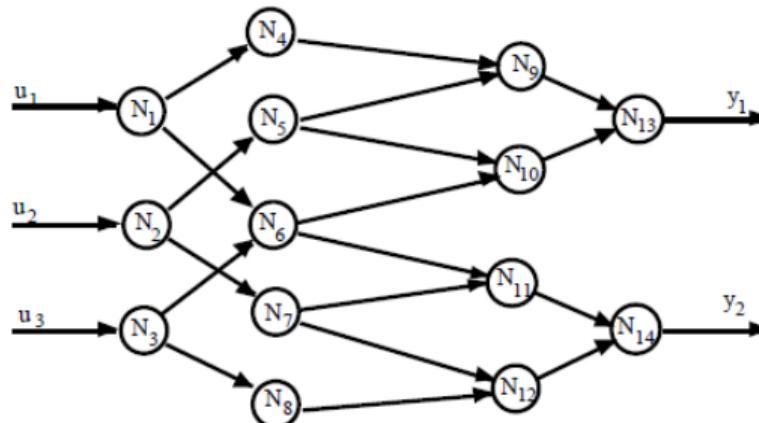


Figura: Rede neural artificial direta com 2 camadas profundas.

Função Custo

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

- Uma função de custo mede o quanto diferente da saída da rede está a relação ao valor verdadeiro atribuído ao dado imputado na camada de entrada.
- Um exemplo de função de custo é a função de custo quadrático.
-

$$C = \frac{1}{2n} \sum_x \| y(x) - y^L(x) \|^2$$

Algorítimo *Backpropagation*

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

- ① Entra-se com um conjunto de dados na camada de entrada da rede neural;
- ② Para cada exemplo de treino é feito o seguinte procedimento:

① computar as saídas dos neurônios até a última camada utilizando a Equação
$$y_j^l = \eta \left(\sum_k w_{jk}^l y_k^{l-1} + \theta_j^l \right);$$

② calcular o erro $\delta^{x,L} = \nabla_a C_x \odot \eta'(w^L y^{L-1} + \theta^L)$;

③ Retro-propagar o erro pela rede utilizando a Equação

$$\delta^{x,l} = \left((w^{l+1})^T \delta^{x,l+1} \right) \odot \eta'(w^l y^{l-1} + \theta^l)$$
 para calcular o erro em cada
camada $l = L-1, L-2, \dots;$

- ④ Atualizar os pesos e *biases* da rede por meio das Equações
 $w^l \rightarrow w^l - \frac{\mu}{m} \sum_x \delta^{x,l} (a^{x,l-1})^T$ e $b^l \rightarrow b^l - \frac{\mu}{m} \sum_x \delta^{x,l}$, onde μ representa a taxa
de aprendizagem da rede e m o tamanho do *mini-batches*.

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

- Bolhas foram confundidas com regiões porosas.
- Dificuldade de classificar poros na presença de materiais argilosos.
- Uso de outras funções de ativação.

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

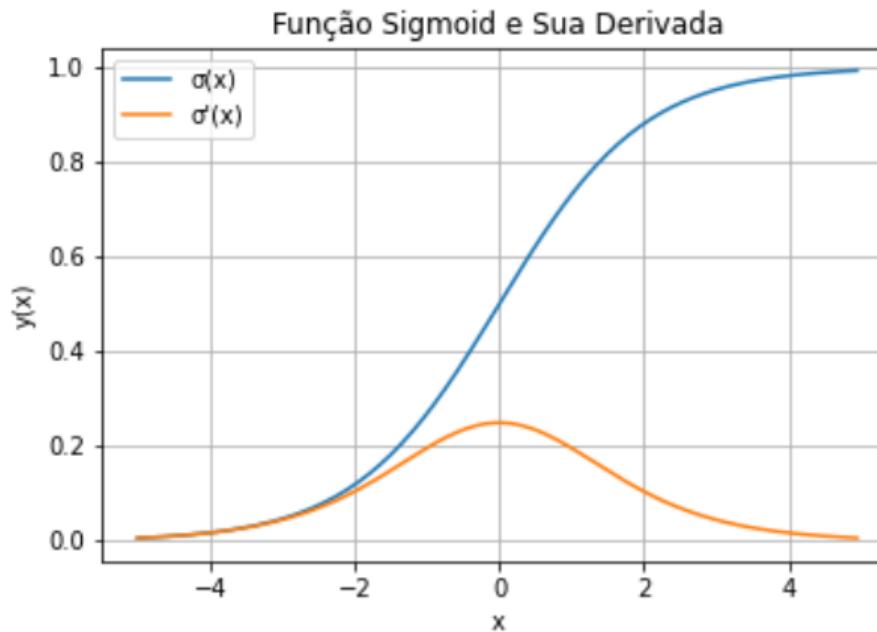


Figura: Função Sigmoid e sua Derivada.

Função Custo Cross-Entropy

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

- O uso da função de custo quadrática pode tornar o aprendizado muito lento.
-

$$C = -\frac{1}{n} \sum_x [y \ln a + (1 - y) \ln(1 - a)]$$

-

$$\frac{\partial C}{\partial \theta} = \frac{1}{n} \sum_x (a - y)$$

-

$$\frac{\partial C}{\partial w} = \frac{1}{n} \sum_x x(a - y)$$

Introdução

Revisão

Bibliográfica

Lin et al. (2018)

Rubo et al. (2019)

Alqahtani et al. (2018)

Hébert et al. (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

Função Custo Cross-Entropy

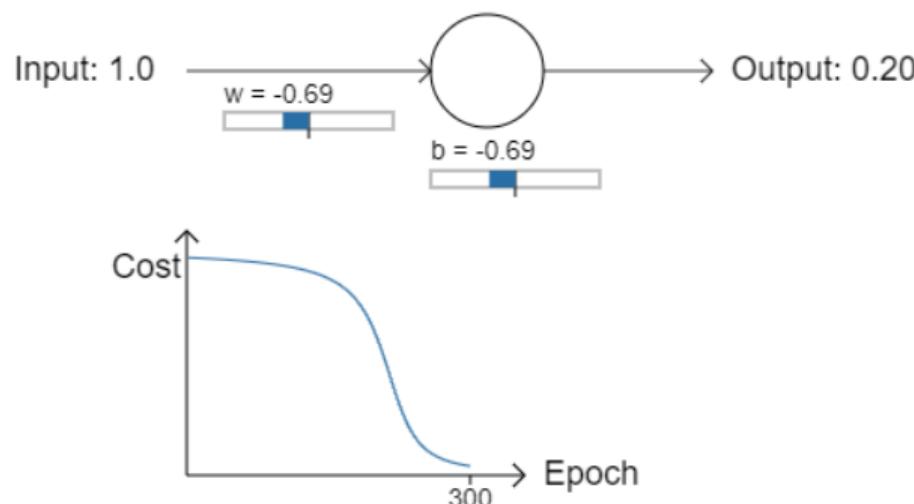


Figura: Relação custo x número de épocas para uma função de custo quadrática [Fonte: (NIELSEN, 2015)].

Introdução

Revisão

Bibliográfica

Lin et al. (2018)

Rubo et al. (2019)

Alqahtani et al. (2018)

Hébert et al. (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

Função Custo Cross-Entropy

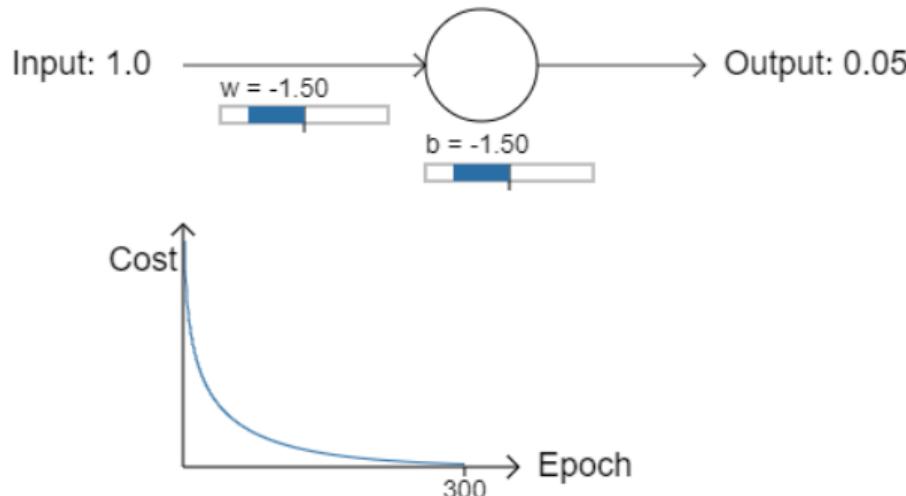


Figura: Relação custo x número de épocas para uma função de custo *Cross-Entropy* [Fonte: (NIELSEN, 2015)].

Descrição do Modelo

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

- Previsão de propriedades petrofísicas por meio de redes neurais convolucionais.
- Dataset composto com 3 tipos de arenitos: *Bentheimer*, *Berea* e *Fine-Grain*.
- Segmentação pelo método de *Otsu*.

Descrição do Modelo

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

- Rede de poros por meio do algoritmo de *watershead*.
- Aplicada função de perda de Huber em conjunto com o otimizador Adam.
-

$$L_s(a) = \begin{cases} 0,5a^2 & |a| \leq \delta \\ (|a| - 0,5\delta)\delta & |a| > \delta \end{cases}$$

Redes Neurais Convolucionais

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

- Aplicada a dados com topologia em grade, como no caso de matrizes 2D.
- Sobre cada imagem são aplicados filtros convolucionais que retornam vários mapas de características.
- Cada mapa passa em seguida por um processo de subamostragem, chamado de *pooling*.
- No final da rede, a topologia em 2D é transformada em um vetor, unidimensional e é usado para alimentar uma rede neural comum.
- Em problemas de classificação é comum utilizar uma função *softmax*.

Redes Neurais Convolucionais

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

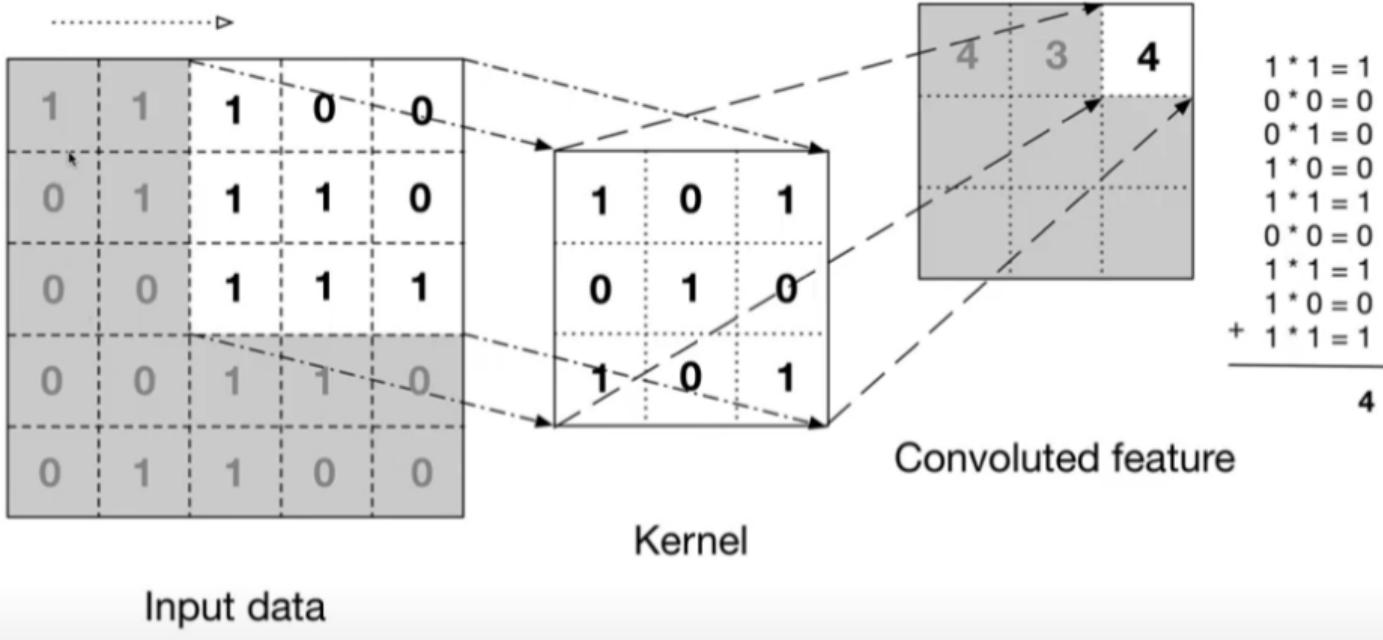


Figura: Operação de convolução.

Redes Neurais Convolucionais

Introdução

Revisão

Bibliográfica

Lin et al. (2018)

Rubo et al. (2019)

Alqahtani et al. (2018)

Hébert et al. (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

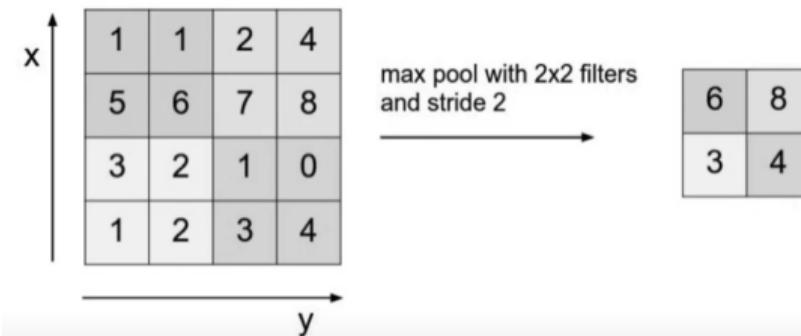


Figura: Operação de *pooling*.

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

Redes Neurais Convolucionais

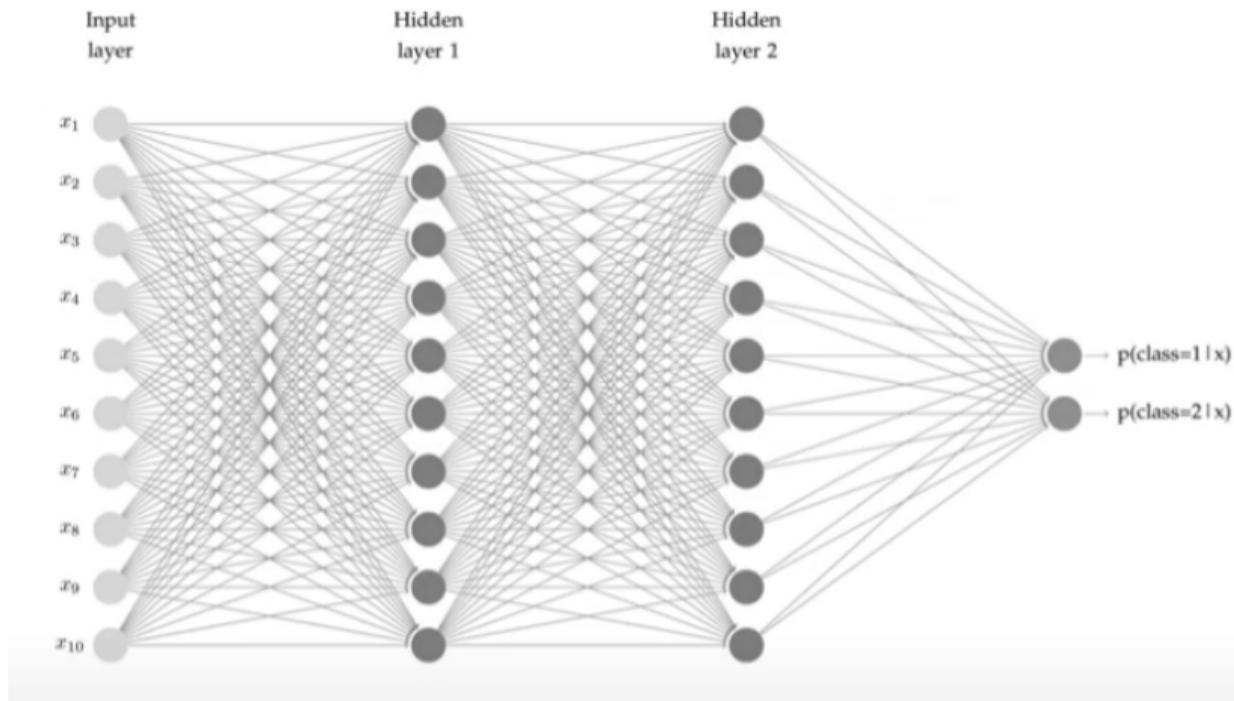


Figura: Operação de *flattening*.

Redes Neurais Convolucionais

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

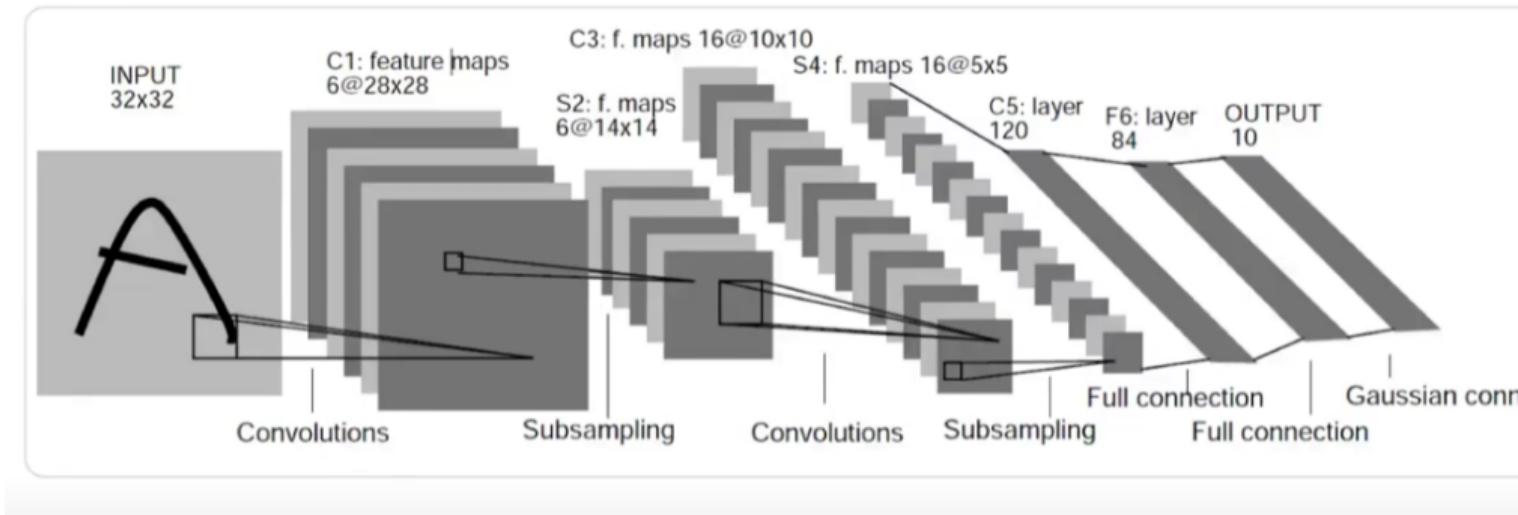


Figura: Exemplo de rede convolucional.

Função Softmax

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

- A função *softmax* é semelhante a uma função *sigmoid* e é bastante utilizada para a classificação de problemas com mais de duas classes. Ela converte os valores das camadas de saída em uma função de probabilidade.
-

$$\eta(\vec{u})_i = \frac{e^{u_i}}{\sum_{j=1}^k e^{u_j}}$$

Algorítimo Watershead

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

- Imagem é modelada como uma superfície topográfica (vales e montanhas) que corresponde aos valores de intensidade dos pixeis.
- Inundação dos mínimos locais formando bacias até que eventualmente essas bacias se encontram e formam as linhas de contenção.

Método de Otsu

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

- Baseado na seleção do menor ponto entre dois picos no histograma, considerando que os níveis médios de cinza do objeto do fundo são diferentes.



$$\sigma_T^2 = \sum_{i=0}^{255} p_i \left(\frac{\sum_{i=0}^{255} i \cdot p_i}{\sum_{i=0}^{255} p_i} \right)^2$$



$$\eta(T_h) = \frac{\sigma_{inter}^2}{\sigma_T^2} = \frac{B_0 B_1 (\mu_0 \mu_1)^2}{\sigma_T^2}$$

Algorítimo Watershead

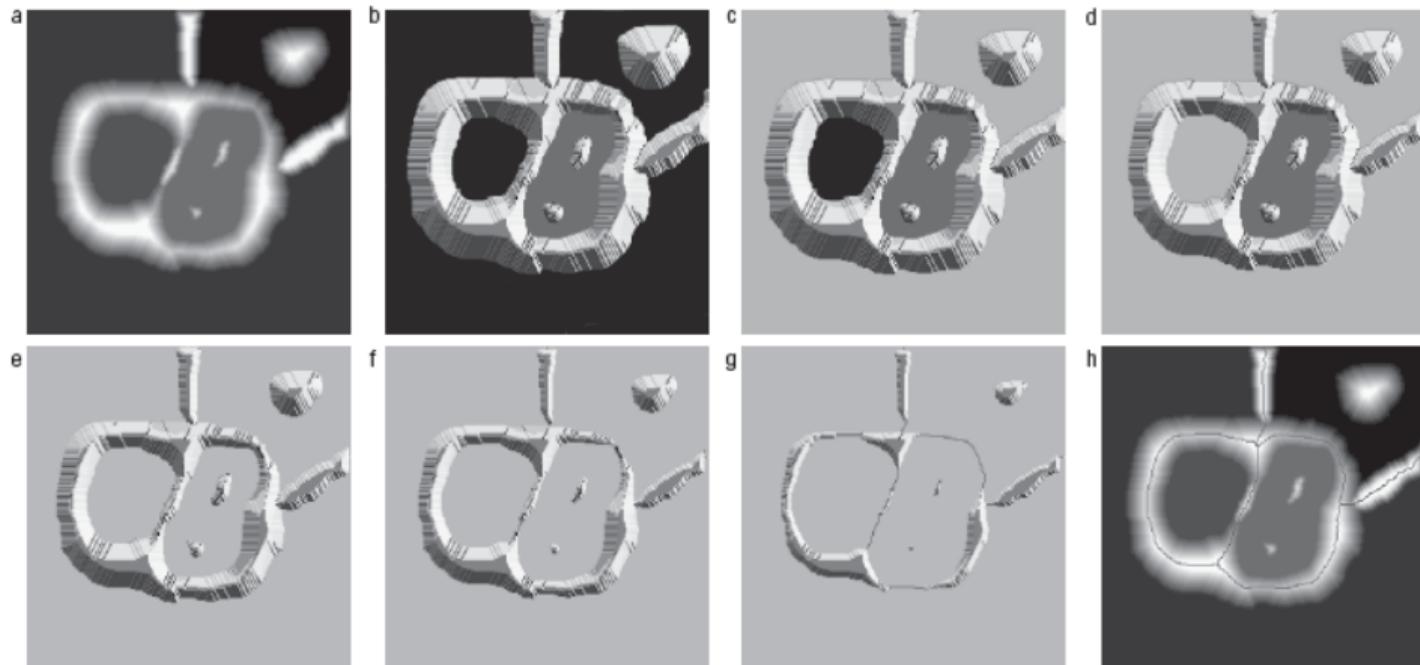


Figura: Processo de aplicação da segmentação por watersheads [Fonte: (GONZALEZ; WOODS, 2010)].

Estrutura da Rede Neural

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

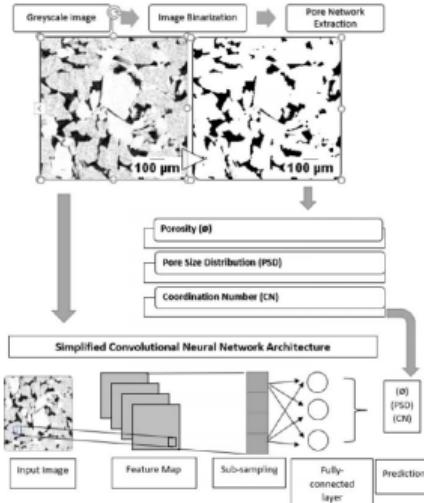


Figura: Framework da metodologia utilizada para prever propriedades de meios porosos utilizando redes neurais convolucionais [Fonte: (ALQAHTANI *et al.*, 2018)]x.

Resultados

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

- Dificuldade para classificar minerais com brilho intenso.
- Uso de dataset com valores de intensidade mais bem distribuídos.

Resultados

Introdução

Revisão

Bibliográfica

Lin et al. (2018)

Rubo et al. (2019)

Alqahtani et al. (2018)

Hébert et al. (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

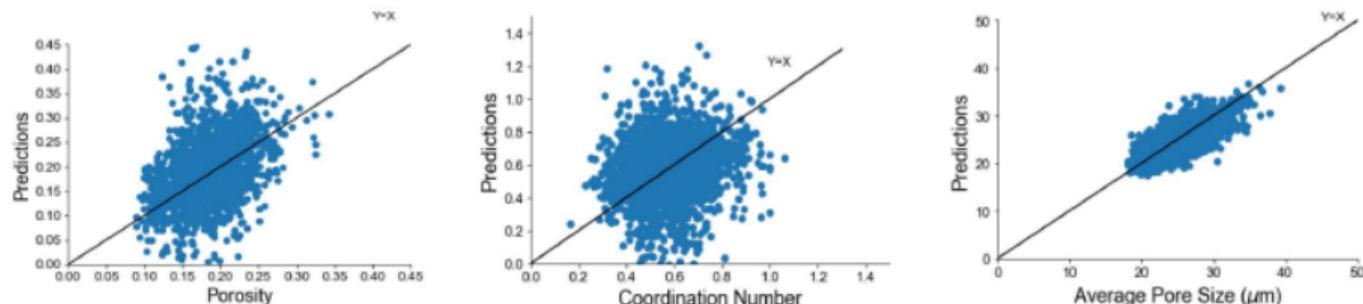


Figura: Correlação entre os valores previstos e reais de porosidade, número de coordenação e tamanho médio de poro, para cada amostra [Fonte: (ALQAHTANI et al., 2018)].

Descrição do Modelo - Problema de Classificação

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

- Dataset composto por carbonatos das formações de Estaillades e Savonnieres, e arenitos Berea e Fontainebleau.
- Uso do software Voxilon para extrair para extrair propriedades físicas de porosidade (aplicada ao trabalho), permeabilidade e tortuosidade.
- Problema de classificação abordado por meio da rede neural pré-treinada Inception v3 do Google.

Descrição do Modelo - Problema de Classificação

Introdução

Revisão
Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

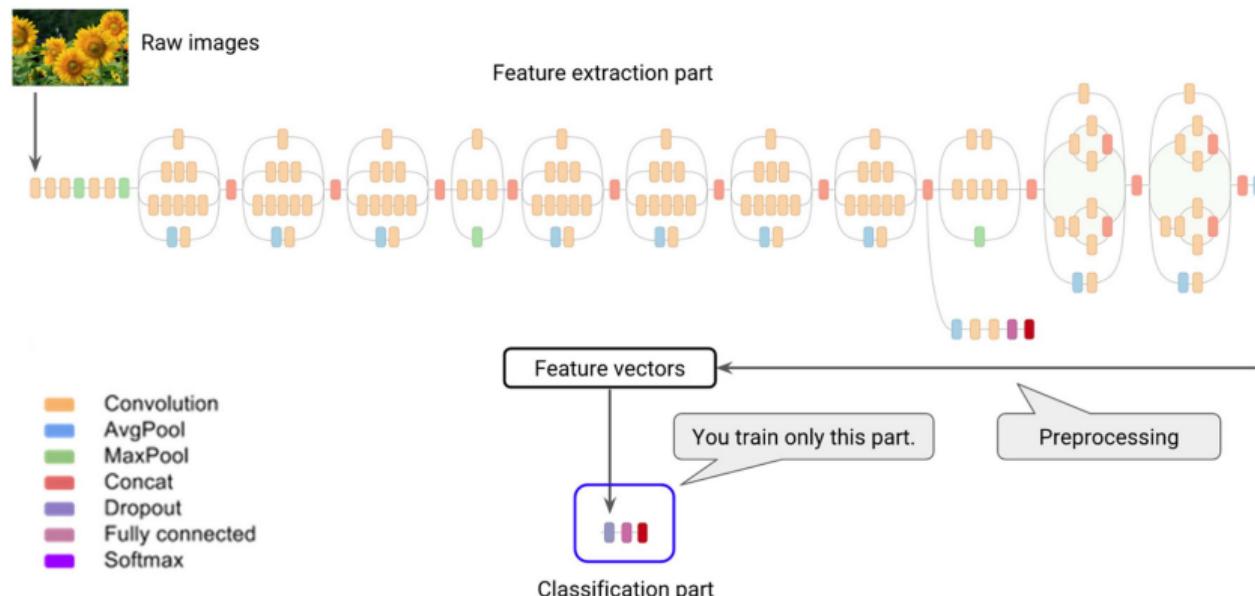


Figura: Arquitetura da Inception V3(Google Codelabs) [Fonte: (HÉBERT et al., 2020)].

Descrição do Modelo - Estimativa de Porosidade

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

- Modelo RegPhi, desenvolvido por Sudakov *et al.* (2019), para estimar a porosidade nas amostras.
- Obteve-se um erro relativo médio em 18% e uma mediana abaixo de 15%.

Descrição do Modelo - Estimativa de Porosidade

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

Tabela 1: Arquitetura da rede *RegPhi*.

| Tipo de Camada | Parâmetros |
|-----------------------|--|
| Convolução 3D | filters=32, kernel_size=(5, 5, 5), strides=(2,2,2), padding='valid', activation='relu' |
| Convolução 3D | filters=32, kernel_size=(5, 5, 5), strides=(2,2,2), padding='valid', activation='relu' |
| <i>Max Pooling</i> 3D | pool_size=(2, 2, 2) |
| Convolução 3D | filters=32, kernel_size=(3, 3, 3), padding='valid', activation='relu' |
| Convolução 3D | filters=32, kernel_size=(3, 3, 3), padding='valid', activation='relu' |
| <i>Max Pooling</i> 3D | filters=32, kernel_size=(3, 3, 3), padding='valid', activation='relu' |
| Densa | units=128, activation='relu' |
| Densa | units=64, activation='relu' |
| <i>Flatten</i> | - |
| Densa | units=1 |

Motivação Para o Tema

- A escolha de um bom algoritmo de segmentação é um ponto chave para uma boa binarização de imagens de rochas reservatório.
- Dificuldade de processamento de imagens com grãos muito claros ou muito escuros.
- Utilização de uma arquitetura de rede neural mais otimizada para lidar com imagens.
- Funções de ativação de que não estejam suscetíveis ao fenômeno do *vanishing gradient*.
- Utilização de outros algorítimos de otimização que não SGD (*Stochastic Gradient Descendent*).

Classificação da Pesquisa

- Área de Estudo: Processamento digital de imagens de rocha reservatório utilizando inteligência artificial.
- Subordinação do tema a áreas do conhecimento científico: Ligado à engenharia de reservatório de petróleo, ao estudo e caracterização do meio poroso, a determinação de propriedades petrofísicas utilizando métodos da área de processamento e análise de imagens digitais e da área de inteligência artificial.
- Problema específico: Desenvolvimento de modelos de inteligência artificial (IA) aplicados a binarização de imagens de rocha reservatório.
- Tipo de pesquisa: A pesquisa em desenvolvimento apresenta caráter misto entre a modelagem numérico-computacional e desenvolvimento experimental.

Hipóteses

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

- O arcabouço, matriz e cimento dos arenitos, e o aloquímico, a micrita e o esparito dos carbonatos serão tratados como fase granular, e os poros como fase rochosa. Dessa forma portanto, está desconsiderada a classificação dos minerais.
- Serão utilizados valores de porosidade efetiva, já que a resina preenche apenas os poros interconectados.

Materiais e Pressupostos

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

- Realização de um estudo acerca da geologia das rochas reservatórios ao se cursar as disciplinas de Introdução a Engenharia de Petróleo, Petrofísica e Escoamento em Meios Poros e Fraturados.
- Cursar Disciplinas de Desenvolvimento de Software em C++, Processamento Paralelo e Concorrente e Processamento de Imagens para dar suporte ao desenvolvimento das técnicas computacionais.

Materiais e Pressupostos

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

- Desenvolvimento de modelos de redes neurais profundas para binarização de amostras de imagens de rochas digitais providas pelo acervo digital do Prof. DSc. André Bueno e pelo banco de dados disponibilizados pelo CENPES-PETROBRÁS.
- Integração dos códigos desenvolvidos com a LIB_LDSC em C++.
- Comparação dos resultados com outros trabalhos na literatura.

Ferramenta de Anotação de Regiões de Interesse

Introdução

Revisão
Bibliográfica

Lin *et al.* (2018)
Rubo *et al.* (2019)
Alqahtani *et al.* (2018)
Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados
Treinamento e Aplicação
das Redes Neurais
Coleta de Resultados

Resultados

Conclusões

Bibliografia

- Demarcação de regiões que representariam a matriz sólida e os poros. Cada região é representada por um cor, escolhida pelo usuário.
- Desenvolvido em C++.
- Utilização da Biblioteca QT para construção da interface gráfica.
- Exportação da informação RGB dos pixels representados sobre as regiões de interesse.

Introdução

Revisão Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

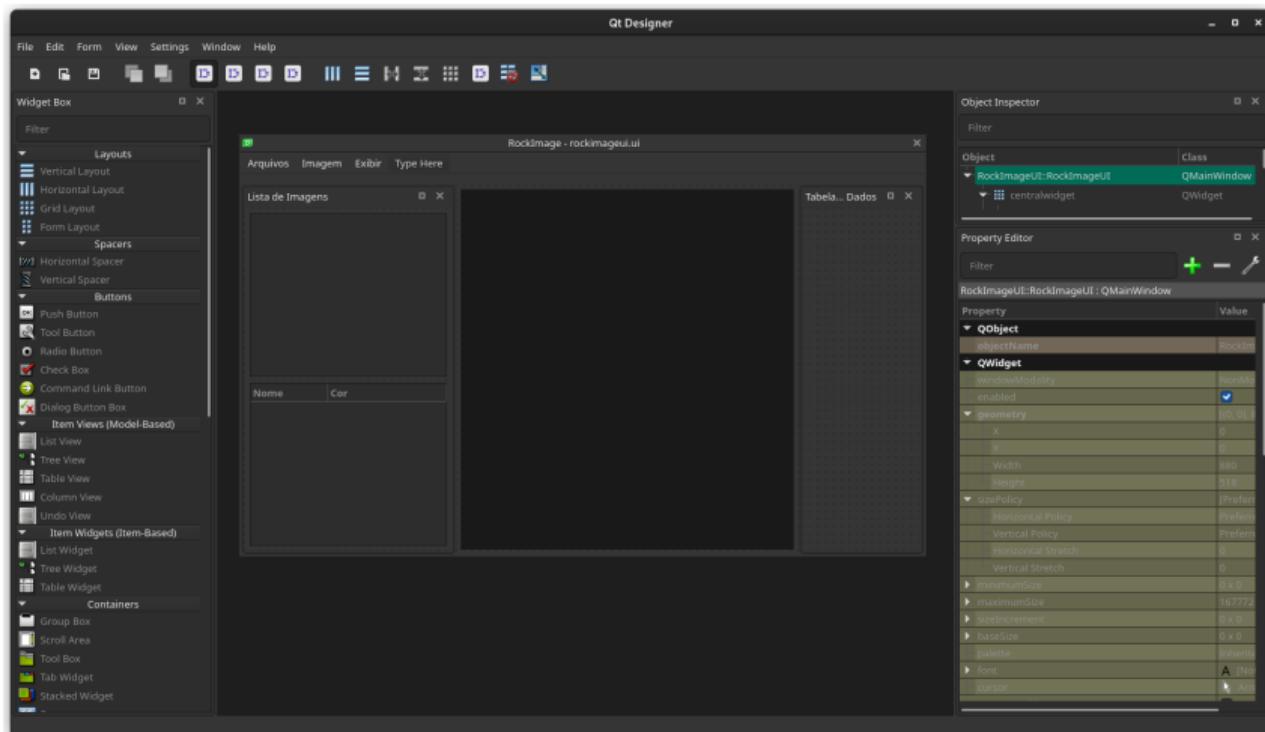


Figura: Interface Gráfica do *QT Designer*.

Ferramenta de Anotação de Regiões de Interesse

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

| | PosX | PosY | Vermelho | Verde | Azul | Label |
|-----|------|------|----------|-------|------|-------|
| 1 | 242 | 154 | 7 | 73 | 72 | Poro |
| 2 | 232 | 167 | 20 | 56 | 44 | Poro |
| 3 | 238 | 156 | 16 | 60 | 59 | Poro |
| 4 | 233 | 180 | 12 | 83 | 75 | Poro |
| 5 | 220 | 170 | 18 | 70 | 66 | Poro |
| 6 | 254 | 138 | 9 | 75 | 65 | Poro |
| 7 | 246 | 158 | 2 | 80 | 82 | Poro |
| 8 | 241 | 158 | 3 | 60 | 67 | Poro |
| 9 | 242 | 165 | 31 | 74 | 55 | Poro |
| 10 | 247 | 148 | 19 | 93 | 92 | Poro |
| 11 | 236 | 162 | 0 | 46 | 40 | Poro |
| 12 | 226 | 164 | 68 | 101 | 74 | Poro |
| 13 | 226 | 177 | 3 | 43 | 34 | Poro |
| 14 | 248 | 154 | 45 | 115 | 113 | Poro |
| 15 | 234 | 164 | 17 | 64 | 56 | Poro |
| 16 | 238 | 170 | 1 | 25 | 9 | Poro |
| 17 | 223 | 175 | 3 | 53 | 44 | Poro |
| 18 | 224 | 176 | 22 | 64 | 52 | Poro |
| 19 | 221 | 170 | 16 | 71 | 66 | Poro |
| 20 | 241 | 169 | 12 | 53 | 37 | Poro |
| 21 | 232 | 166 | 0 | 40 | 28 | Poro |
| 22 | 232 | 192 | 5 | 59 | 45 | Poro |
| 23 | 238 | 175 | 16 | 73 | 67 | Poro |
| ... | ... | ... | ... | ... | ... | ... |

Figura: Exemplo de Tabela com Dados Coletados.

Ferramenta de Anotação de Regiões de Interesse

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

**Ferramenta de Anotação de
Regiões de Interesse**

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

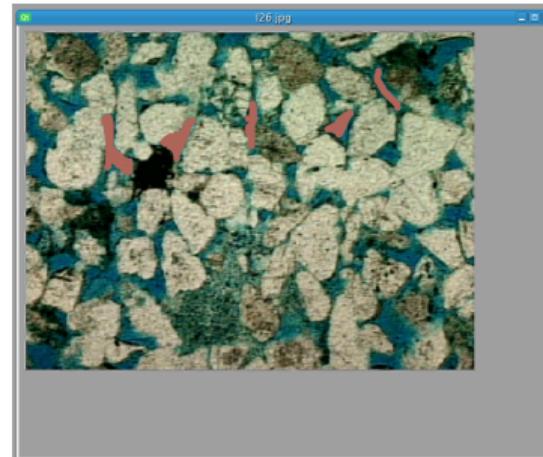


Figura: Exemplo Marcação de Poros.

Coleta dos Dados

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

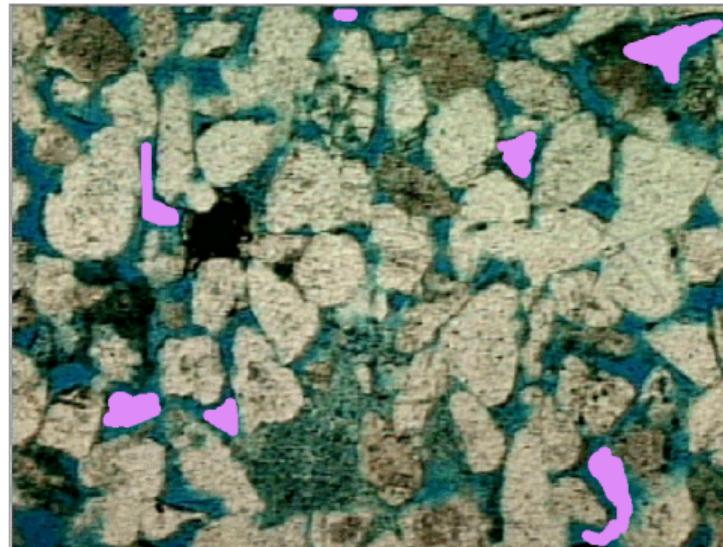


Figura: Exemplo de Coleta de Dados com Berea200.

Coleta dos Cados

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

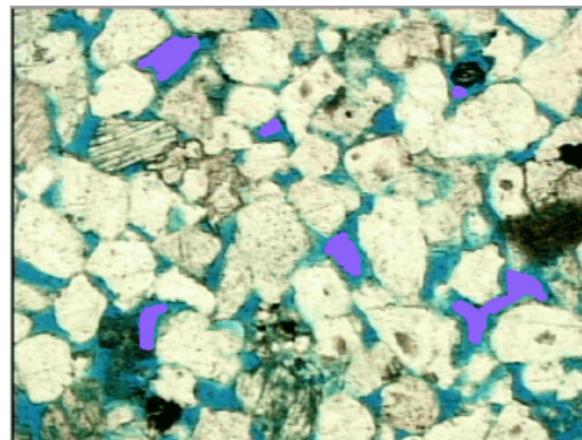


Figura: Exemplo de Coleta de Dados com Berea500.

Coleta dos Dados

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

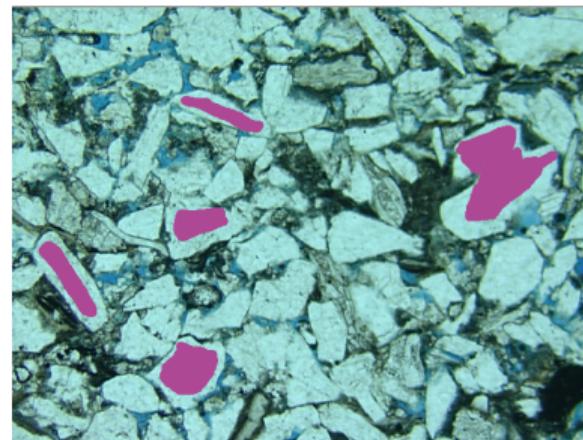


Figura: Exemplo de Coleta de Dados com P148_K2.

Coleta dos Cados

Introdução

Revisão
Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

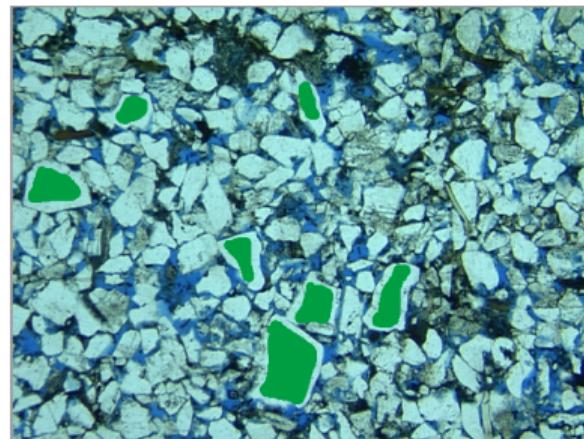


Figura: Exemplo de Coleta de Dados com P240_K104.

Coleta de Dados

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

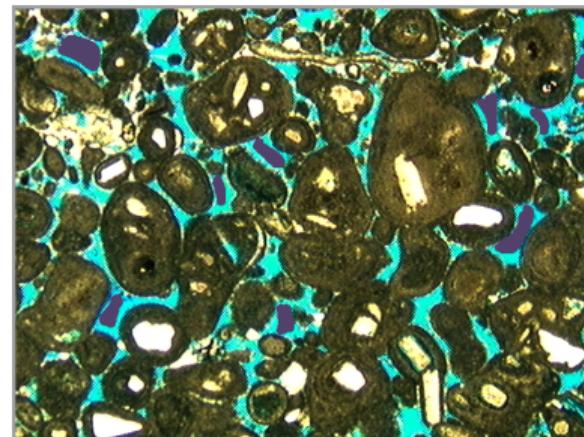


Figura: Exemplo de Coleta de Dados com P262_K441.

Treinamento e Aplicação das Redes Neurais

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

- Código desenvolvido em Python.
- Utilização de uma CLI (*Command-Line Interface*) para treinar e aplicar os modelos nas imagens.
- Utilização das biblioteca *PyTorch*, *NumPy* e *Pillow*.

Descrição do Modelo

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

Tabela: Camadas da rede neural representada pelo modelo.

| Número da Camada | Número de Neurônios | Função de Ativação |
|---------------------|---------------------|--------------------|
| 1 | 4 | <i>relu</i> |
| 2 | 4 | <i>relu</i> |
| 3 | 4 | <i>relu</i> |
| 4 (<i>output</i>) | 2 | <i>log_softmax</i> |

Descrição do Modelo

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

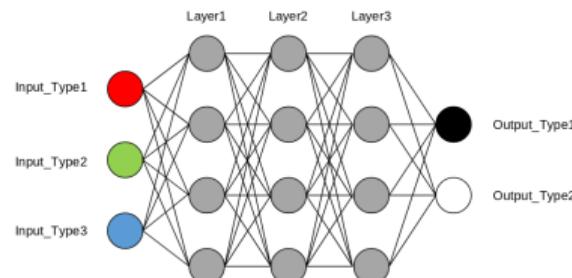


Figura: Representação da rede neural construída.

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

Procedimento de Coleta de Dados

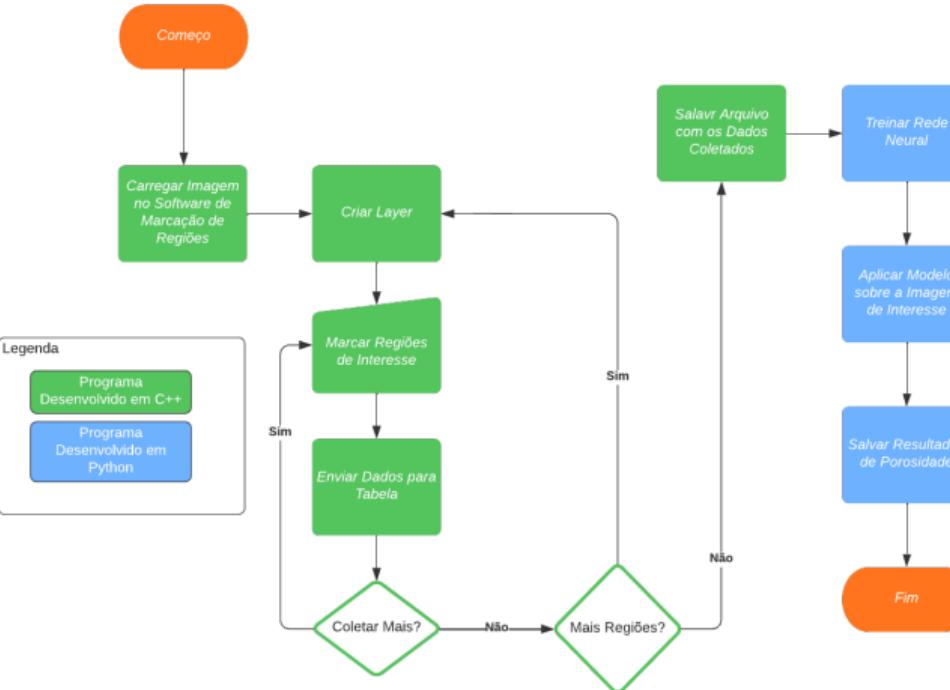


Figura: Procedimento de Coleta de Dados para Binarização de Rochas Digitais com Redes Neurais.

Resultados para Amostras Berea200

Tabela: Resultados Berea200.

| Imagen | Porosidade (%) | | | | | | |
|--------|----------------|---------|---------|---------|---------|--------|-----------|
| | Iter. 1 | Iter. 2 | Iter. 3 | Iter. 4 | Iter. 5 | Média | D. Padrão |
| I22 | 31,00% | 31,00% | 36,74% | 37,38% | 31,00% | 33,42% | 3,33% |
| I212 | 23,84% | 23,84% | 21,52% | 33,16% | 23,84% | 25,24% | 4,54% |
| I26 | 16,58% | 16,58% | 22,17% | 38,31% | 25,57% | 23,84% | 8,95% |
| I216 | 25,57% | 25,57% | 22,64% | 26,63% | 25,57% | 25,19% | 1,50% |

Resultados para Amostras Berea200

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

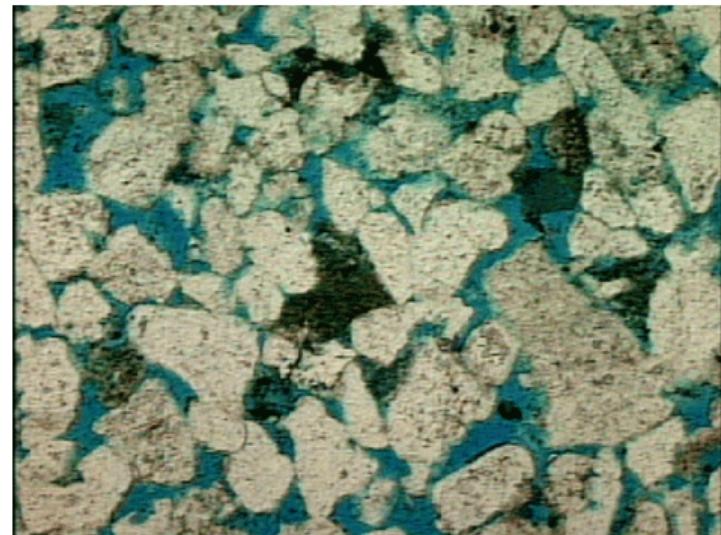
Resultados

Conclusões

Bibliografia



(a) I216.png Binarizada.



(b) I216.png Original.

Figura: Resultados pra I216.png.

Resultados para Amostras Berea200

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

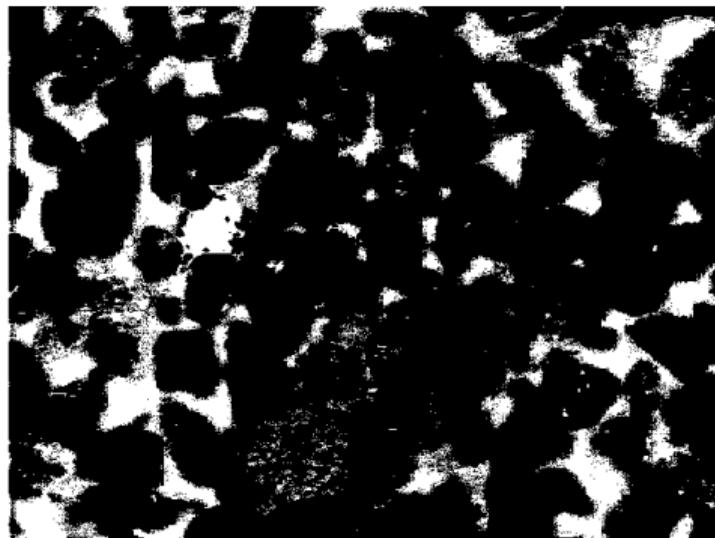
Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

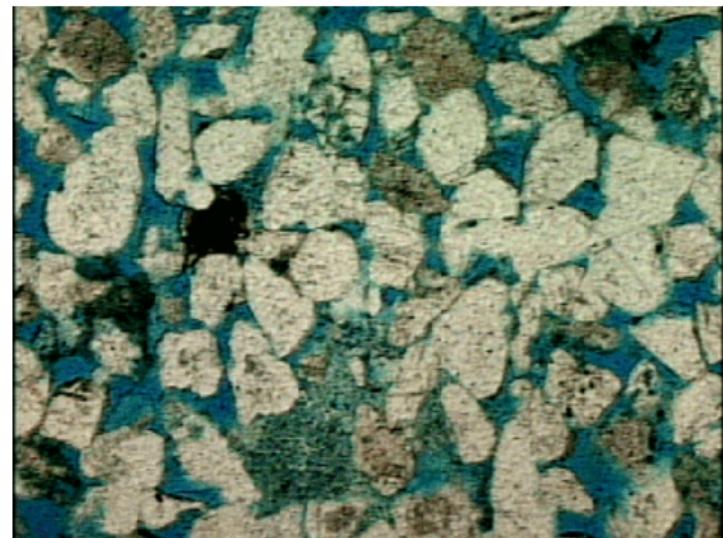
Resultados

Conclusões

Bibliografia



(a) I26.png Binarizada.



(b) I26.png Original.

Figura: Resultados pra I26.png.

Resultados para Amostras Berea500

Tabela: Resultados Berea500.

| Imagens | Porosidade (%) | | | | | | |
|---------|----------------|---------|---------|---------|---------|--------|-----------|
| | Iter. 1 | Iter. 2 | Iter. 3 | Iter. 4 | Iter. 5 | Média | D. Padrão |
| I31 | 22,18% | 22,18% | 24,03% | 20,91% | 22,18% | 22,30% | 1,12% |
| I310 | 23,43% | 23,43% | 35,39% | 29,80% | 23,43% | 27,09% | 5,39% |
| I311 | 22,60% | 22,60% | 30,15% | 24,06% | 22,60% | 24,40% | 3,28% |
| I312 | 34,72% | 34,72% | 39,96% | 34,09% | 34,72% | 35,64% | 2,43% |
| I318 | 24,53% | 24,53% | 35,01% | 28,60% | 24,53% | 27,44% | 4,58% |
| I32 | 21,28% | 21,28% | 26,36% | 22,50% | 21,28% | 22,54% | 2,20% |
| I320 | 14,46% | 14,46% | 26,32% | 22,86% | 14,46% | 18,51% | 5,68% |

Resultados para Amostras Berea500

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

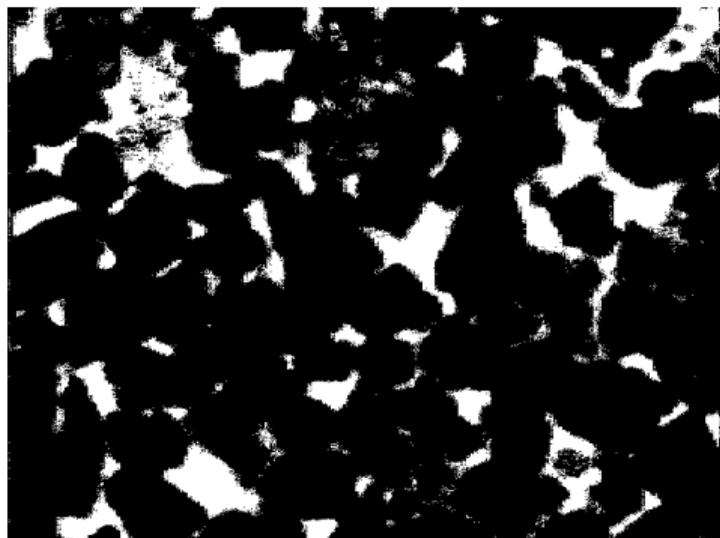
Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

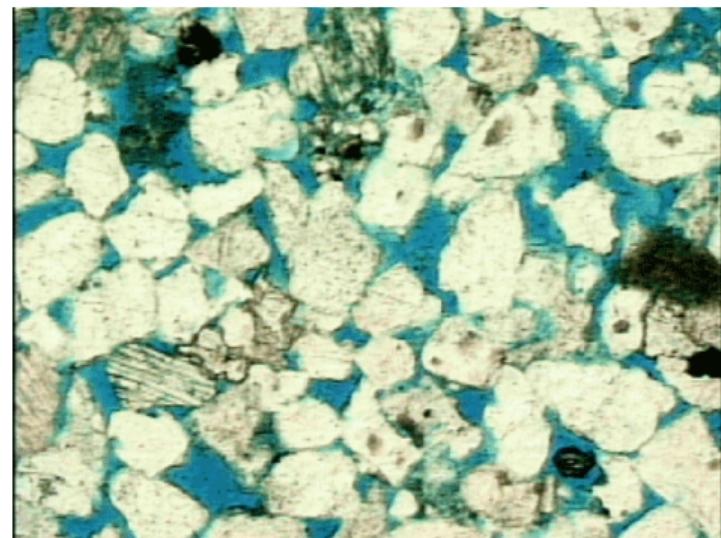
Resultados

Conclusões

Bibliografia



(a) I320.png Binarizada.



(b) I320.png Original.

Figura: Resultados pra I320.png.

Resultados para Amostras Berea500

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

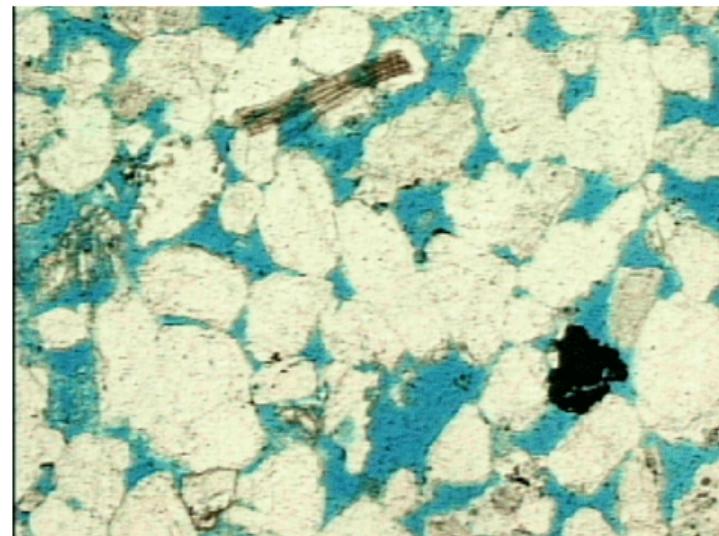
Resultados

Conclusões

Bibliografia



(a) I31.png Binarizada.



(b) I31.png Original.

Figura: Resultados pra I31.png.

Resultados para Amostras P148_K2

Tabela: Resultados P148_K2.

| Imagen | Porosidade (%) | | | | | | |
|---------|----------------|---------|---------|---------|---------|--------|-----------|
| | Iter. 1 | Iter. 2 | Iter. 3 | Iter. 4 | Iter. 5 | Média | D. Padrão |
| 3271i01 | 24,50% | 24,50% | 5,27% | 27,17% | 24,50% | 21,19% | 8,97% |
| 3271i02 | 6,24% | 6,24% | 12,96% | 13,48% | 6,24% | 9,03% | 3,83% |
| 3271i03 | 20,59% | 20,59% | 17,00% | 21,43% | 20,59% | 20,04% | 1,74% |
| 3271i04 | 9,37% | 9,37% | 11,95% | 10,15% | 9,37% | 10,04% | 1,12% |
| 3271i05 | 24,62% | 24,62% | 29,25% | 25,56% | 24,62% | 25,73% | 2,01% |
| 3271i06 | 37,84% | 37,84% | 32,46% | 31,14% | 37,84% | 35,42% | 3,34% |
| 3271i07 | 30,43% | 30,43% | 27,48% | 37,56% | 30,43% | 31,26% | 3,75% |
| 3271i08 | 33,87% | 33,87% | 32,21% | 31,06% | 33,87% | 32,98% | 1,29% |
| 3271i09 | 22,58% | 22,58% | 14,85% | 22,03% | 22,58% | 20,93% | 3,41% |
| 3271i10 | 27,03% | 27,03% | 21,36% | 25,06% | 27,03% | 25,50% | 2,47% |

Resultados para Amostras P148_K2

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

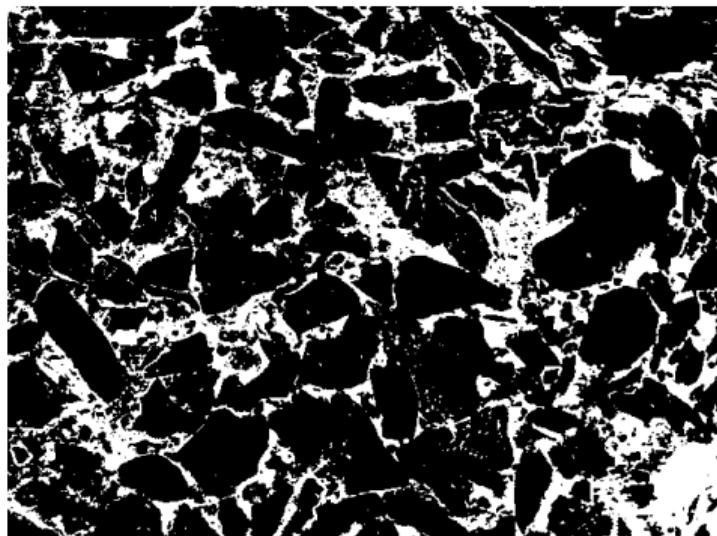
Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

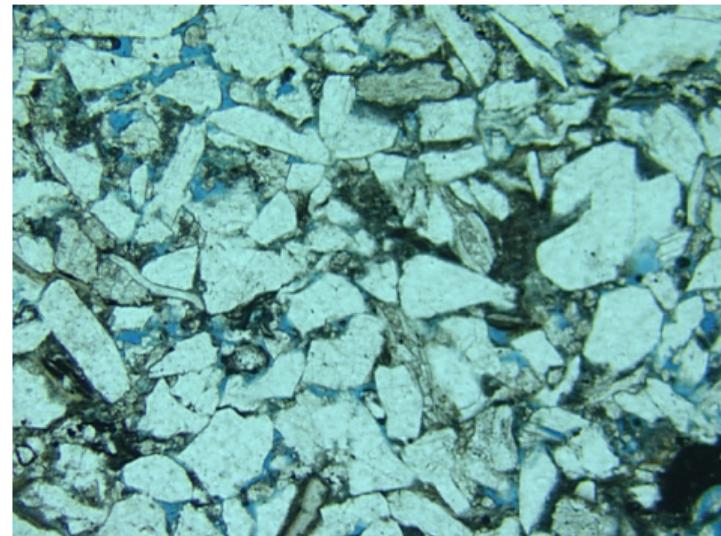
Resultados

Conclusões

Bibliografia



(a) 3271i01.png Binarizada.



(b) 3271i01.png Original.

Figura: Resultados pra 3271i01.png.

Resultados para Amostras P148_K2

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

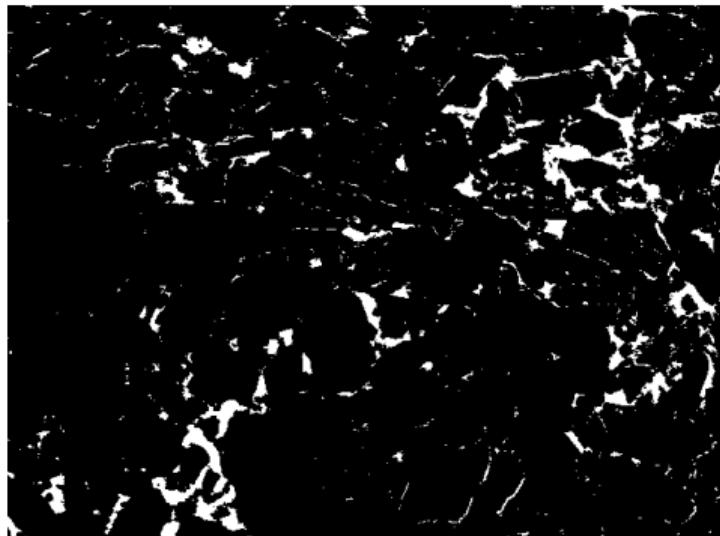
Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

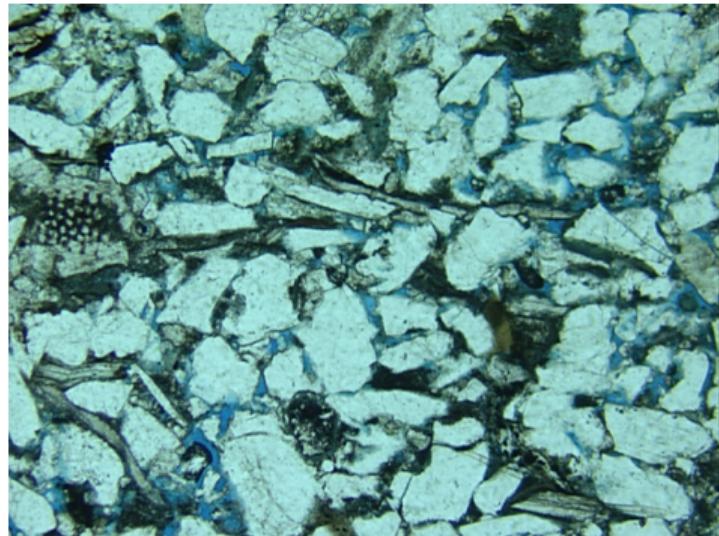
Resultados

Conclusões

Bibliografia



(a) 3271i02.png Binarizada.



(b) 3271i02.png Original.

Figura: Resultados pra 3271i02.png.

Resultados para Amostras P240_K104

Tabela: Resultados P240_K104.

| Imagen | Porosidade (%) | | | | | | |
|---------|----------------|---------|---------|---------|---------|--------|---------------|
| | Iter. 1 | Iter. 2 | Iter. 3 | Iter. 4 | Iter. 5 | Média | Desvio Padrão |
| 3251i01 | 27,61% | 27,61% | 37,30% | 34,31% | 34,74% | 32,31% | 4,45% |
| 3251i02 | 34,11% | 34,11% | 38,65% | 36,40% | 35,91% | 35,84% | 1,88% |
| 3251i03 | 27,75% | 27,75% | 34,47% | 33,49% | 32,78% | 31,25% | 3,25% |
| 3251i04 | 31,88% | 31,88% | 34,30% | 34,47% | 34,60% | 33,42% | 1,42% |
| 3251i05 | 25,67% | 25,67% | 31,15% | 30,61% | 30,66% | 28,75% | 2,82% |
| 3251i06 | 28,52% | 28,52% | 35,61% | 34,73% | 34,66% | 32,41% | 3,57% |
| 3251i07 | 43,48% | 43,48% | 38,20% | 36,21% | 35,99% | 39,47% | 3,76% |
| 3251i08 | 35,73% | 35,73% | 39,19% | 37,10% | 36,72% | 36,90% | 1,42% |
| 3251i09 | 27,94% | 27,94% | 40,94% | 36,39% | 36,56% | 33,96% | 5,78% |
| 3251i10 | 33,40% | 33,40% | 40,95% | 37,07% | 36,64% | 36,29% | 3,13% |

Resultados para Amostras P240_K104

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

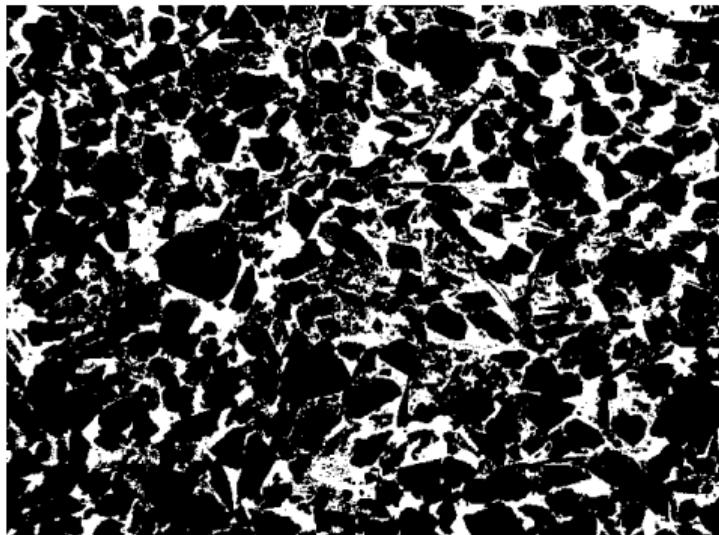
Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

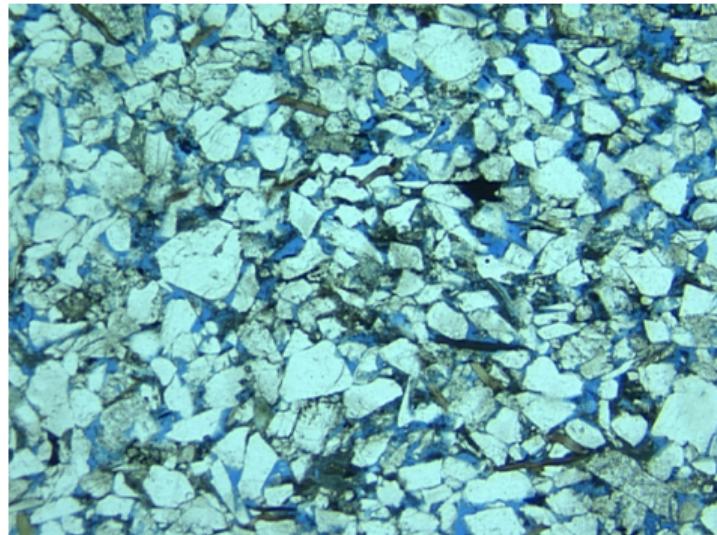
Resultados

Conclusões

Bibliografia



(a) 3251i05.png Binarizada.



(b) 3251i05.png Original.

Figura: Resultados pra 3251i05.png.

Resultados para Amostras P240_K104

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

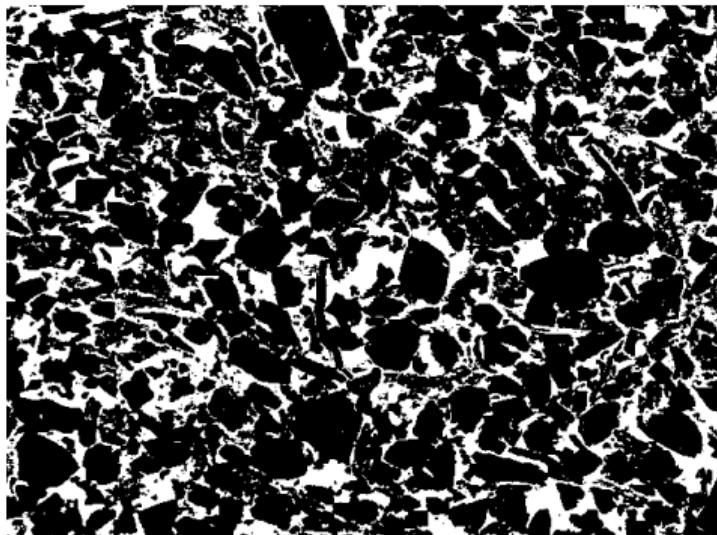
Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

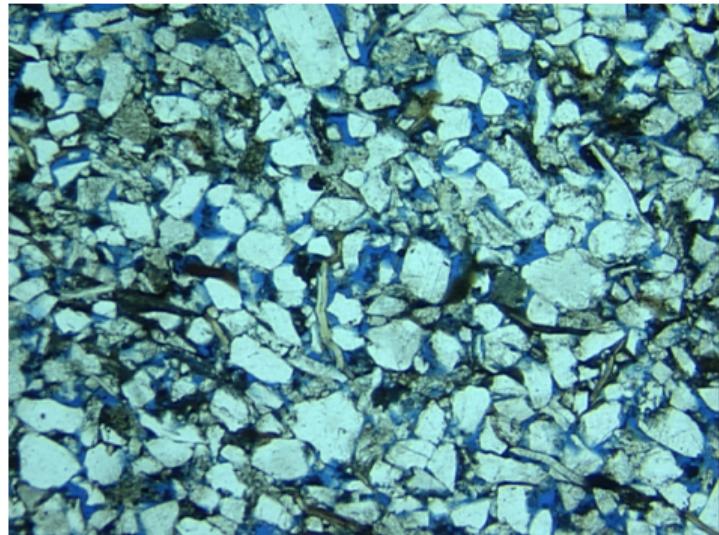
Resultados

Conclusões

Bibliografia



(a) 3251i09.png Binarizada.



(b) 3251i09.png Original.

Figura: Resultados pra 3251i09.png.

Resultados para Amostras P262_K441

Tabela: Resultados P262_K441.

| Imagen | Porosidade (%) | | | | | | |
|-----------|----------------|---------|---------|---------|---------|--------|---------------|
| | Iter. 1 | Iter. 2 | Iter. 3 | Iter. 4 | Iter. 5 | Média | Desvio Padrão |
| L67409i1 | 20,13% | 20,13% | 20,13% | 16,13% | 21,23% | 19,55% | 1,97% |
| L67409i2 | 19,44% | 19,44% | 19,44% | 15,66% | 20,05% | 18,81% | 1,78% |
| L67409i3 | 16,28% | 16,28% | 16,28% | 15,27% | 20,06% | 16,84% | 1,85% |
| L67409i4 | 17,00% | 17,00% | 17,00% | 11,51% | 16,16% | 15,73% | 2,39% |
| L67409i5 | 22,07% | 22,07% | 22,07% | 17,81% | 22,08% | 21,22% | 1,91% |
| L67409i6 | 20,76% | 20,76% | 20,76% | 19,87% | 21,05% | 20,64% | 0,45% |
| L67409i7 | 7,63% | 7,63% | 7,63% | 8,69% | 10,05% | 8,33% | 1,07% |
| L67409i8 | 10,69% | 10,69% | 10,69% | 10,41% | 10,40% | 10,58% | 0,16% |
| L67409i9 | 11,19% | 11,19% | 11,19% | 11,83% | 11,05% | 11,29% | 0,31% |
| L67409i10 | 19,61% | 19,61% | 19,61% | 16,40% | 20,05% | 19,06% | 1,50% |

Resultados para Amostras P262_K441

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

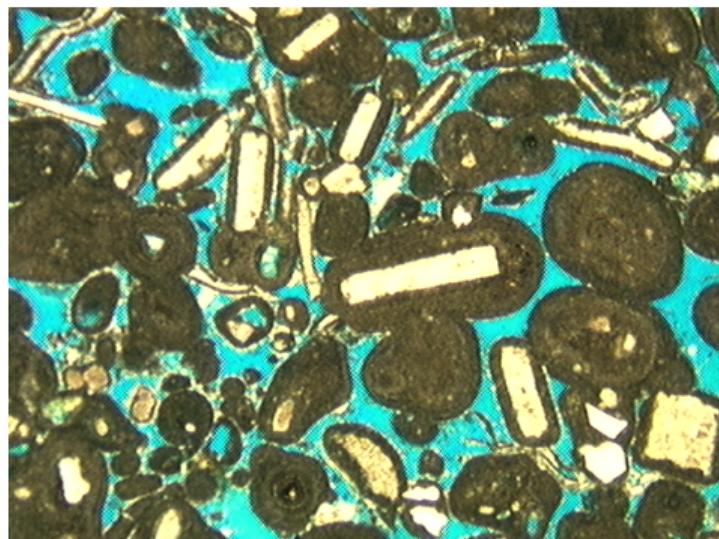
Resultados

Conclusões

Bibliografia



(a) L67409i5.png Binarizada.



(b) L67409i5.png Original.

Figura: Resultados pra L67409i5.png.

Resultados para Amostras P262_K441

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

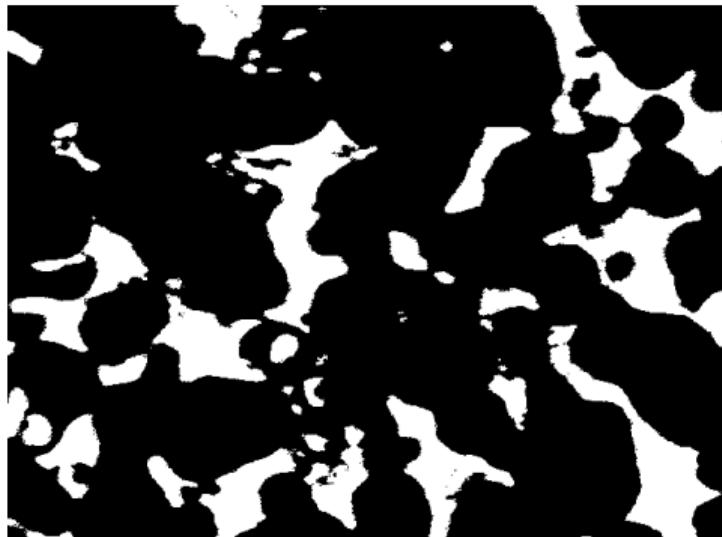
Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

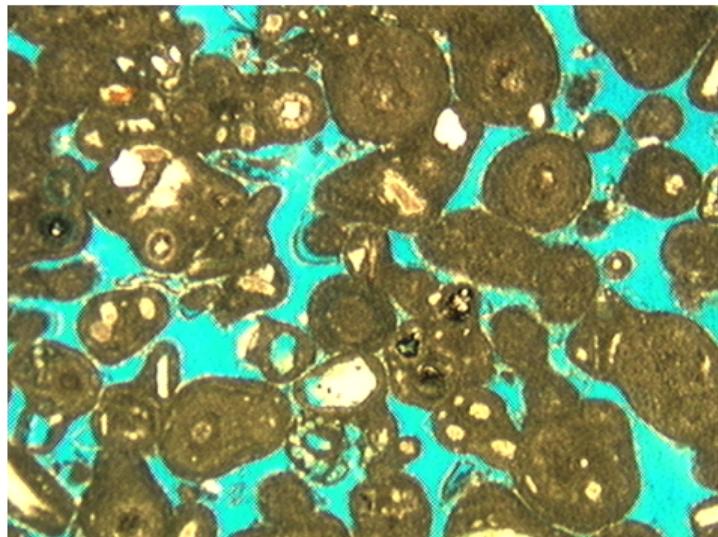
Resultados

Conclusões

Bibliografia



(a) L67409i6.png Binarizada.



(b) L67409i6.png Original.

Figura: Resultados pra L67409i6.png.

Análise para Mesmo Usuário

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

- As amostras da categoria P240_K104 entregaram o melhor resultados de segmentação;
- Amostras Berea200 e Berea500 com regiões de contorno afetadas;
- Experiência do usuário com fator impactante para os resultados;
- Demanda por um grande número de pontos para treinar a rede neural;
- Processo de coleta cansativo.

Análise para Usuários Distintos

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

Tabela: Valores de Porosidade das Análises dos Voluntários.

| Imagens | Voluntário 1 | Voluntário 2 | Voluntário 3 | Voluntário 4 |
|----------|--------------|--------------|--------------|--------------|
| I212 | 30,2003 % | 31,2881 % | 28,1389 % | 21,6879 % |
| I310 | 33,2604 % | 31,9063 % | 31,6811 % | 21,4062 % |
| 3271i01 | 14,0071 % | 10,6523 % | 15,9402 % | 21,6104 % |
| 3251i01 | 27,7952 % | 30,1705 % | 23,0253 % | 33,7577 % |
| L67409i1 | 27,4941 % | 25,6866 % | 28,2072 % | 16,5648 % |

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

- *Machine Learning* como ferramenta útil para obtenção de valores de porosidade;
- Ferramenta de anotação para tornar o processo de coleta de dados menos cansativo;
- *Background* do usuário ao executar o procedimento;
- Treinamento e aplicação do modelo com duração na ordem de milissegundos;
- Uso dos *softwares* desenvolvidos como ferramenta educacional.

Sugestões para Trabalhos Futuros

- Utilizar a ferramenta de anotação de regiões de interesse para classificação e segmentação de não apenas regiões de poros e matriz sólida, mas também para os diferentes componentes mineralógicos que compõem a imagem.
- Aplicar o modelo de rede neural em outras amostras de rochas reservatórios além daquelas descritas neste trabalho.
- Portar *scripts* escritos em *python* para C++ utilizando o *frontend* da biblioteca *PyTorch* para a linguagem.
- Integrar a ferramenta de anotação de regiões de interesse com o software *Laboratório Virtual de Petrofísica*.
- Desenvolvimento de um serviço que possa armazenar dados coletados para diversos tipos de amostras, criando uma base de dados.
- Desenvolvimento de uma versão para Web da ferramenta de anotação de regiões de interesse.
- Aplicar outras arquiteturas de redes neurais.

Bibliografia

- ALQAHTANI, N.; ARMSTRONG, R. T.; MOSTAGHIMI, P. et al. Deep learning convolutional neural networks to predict porous media properties. In: SOCIETY OF PETROLEUM ENGINEERS. SPE Asia Pacific oil and gas conference and exhibition. [S.I.], 2018.
- GONZALEZ, R.; WOODS, R. Processamento Digital de Imagens. Book. [S.I.]: São Paulo: Pearson Pretience Hall, 2010.

Bibliografia

- HÉBERT, V.; PORCHER, T.; PLANES, V.; LÉGER, M.; ALPEROVICH, A.; GOLDLUECKE, B.; RODRIGUEZ, O.; YOUSSEF, S. Digital core repository coupled with machine learning as a tool to classify and assess petrophysical rock properties. In: EDP SCIENCES. E3S Web of Conferences. [S.I.], 2020. v. 146, p. 01003.
- LIN, W.; LI, X.; YANG, Z.; LIN, L.; XIONG, S.; WANG, Z.; WANG, X.; XIAO, Q. A new improved threshold segmentation method for scanning images of reservoir rocks considering pore fractal characteristics. Fractals, World Scientific, v. 26, n. 02, p. 1840003, 2018.

Bibliografia

Introdução

Revisão

Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

- NIELSEN, M. A. Neural networks and deep learning. [S.I.]: Determination press San Francisco, CA, 2015. v. 25.
- REGO, E. A.; BUENO, O. A. D. Desenvolvimento de Método de Binarizacao para Analise de Rochas Reservatorio Tipicas da Bacia de Campos. Tese (Doutorado) — Dissertacao (Msc Dissertation)âUENF/LENEP, 2010.

Bibliografia

- RODRIGUEZ, O.; PORCHER, T.; PLANES, V.; MECUSON, G.; BOUVIER, R. Non destructive testing of cmc engine internal parts from x-ray tomographic images. In: 9th Int. Conf. Industrial Computed Tomography, Padova, Italy. [S.l.: s.n.], 2019.
- RUBO, R. A.; CARNEIRO, C.; MICHELON, M.; GIORIA, R. Digital petrography: Mineralogy and porosity identification using machine learning algorithms in petrographic thin section images. Journal of Petroleum Science and Engineering, v. 183, p. 106382, 08 2019.

Bibliografia

Introdução

Revisão
Bibliográfica

Lin *et al.* (2018)

Rubo *et al.* (2019)

Alqahtani *et al.* (2018)

Hébert *et al.* (2020)

Metodologia

Desenvolvimento

Ferramenta de Anotação de
Regiões de Interesse

Coleta dos Dados

Treinamento e Aplicação
das Redes Neurais

Coleta de Resultados

Resultados

Conclusões

Bibliografia

- SUDAKOV, O.; BURNAEV, E.; KOROTEEV, D. Driving digital rock towards machine learning: Predicting permeability with gradient boosting and deep neural networks. *Computers & geosciences*, Elsevier, v. 127, p. 91–98, 2019.