

1 *Conclusões*

Apresenta-se neste capítulo as conclusões e sugestões para trabalhos futuros.

1.1 *Conclusões*

Conforme já explicado anteriormente, o uso de algoritmos de inteligência artificial é cada vez mais comum nas mais diferentes áreas de pesquisa, especialmente no campo da engenharia. O uso de tal tecnologia torna a execução de tarefas complexas, como o modelo de classificação e de predição, em um curto espaço de tempo possível.

Mais especificamente no âmbito da engenharia de reservatórios, o uso de redes neurais e visão computacional permitem que sejam realizadas análises para descrever características petrofísicas de uma amostra sem precisar danificá-la. Neste trabalho foi mostrado como valores de porosidade absoluta podem ser obtidas por meio de modelos inteligentes que permitem a segmentação de imagens em regiões de poros e de matriz sólida, em um tempo relativamente mais curto e com precisão semelhante a análises físicas. Além disso o desenvolvimento desses modelos se deu utilizando tecnologias de código aberto, o que torna mais fácil a reprodução dos resultados aqui descritos.

Este trabalho teve como objetivo geral desenvolver métodos de inteligência artificial capazes de reconhecer padrões relevantes para a análise das propriedades petrofísicas em imagens de rochas reservatórios. Procurou-se estudar diferentes métodos de aprendizagem de máquina e aprendizagem profundas aplicadas à análise de imagens, e desenvolver aplicações que pudessem tornar possível aplicação desses modelos em exemplos do mundo real. Dentre essas aplicações estariam scripts em *python* para utilização das técnicas de inteligência artificial e uma ferramenta para anotação de regiões de interesse em amostras de rocha digital.

A obtenção dos resultados para que os objetivos descritos anteriormente fossem alcançados se deu na forma de um procedimento descrito na Figura ??, onde as

informações de cor dos pixels das regiões de interesse eram coletados e salvos em um arquivo no formato *.dat*. Esse arquivo é utilizado como *inputs* de uma rede neural desenvolvida utilizando a biblioteca de *Machine Learning PyTorch*. A saída do *script* de treinamento é um outro arquivo no formato *.pt*, que contém os valores dos *biases* e pesos da rede neural treinada. Esse modelo salvo é então aplicado sobre a imagem a ser binarizada. Por fim, é calculado o valor de porosidade para a nova imagem gerada no processo. Todo esse procedimento foi repetido para imagens contidas acervo digital do Prof. DSc. André Duarte Bueno.

Para esse trabalho foi desenvolvido um único modelo de rede neural do tipo *feed-forward*, com 3 camadas profundas, cada uma com 4 neurônios, conforme mostrado na Figura ???. Como função de ativação foi utilizada função *ReLU* mostrada na Figura ???. Para a ultima camada foi aplicada a função *softmax* seguida da aplicação do logaritmo natural do valor obtido. Como otimizador foi escolhido o algoritmo *Adam* e, por fim, a função de perda *NLL Loss*, ou, *Negative Log-Likelihood Loss*.

Como resultado, a duração, tanto do treinamento, quanto a aplicação do modelo duraram na ordem dos milisegundos, o que mostra a capacidade desses algoritmos entregar resultados de forma rápida.

1.2 Sugestões Para Trabalhos Futuros

- Utilizar a ferramenta de anotação de regiões de interesse para classificação e segmentação de não apenas regiões de poros e matriz sólida, mas também para os diferentes componentes mineralógicos que compõem a imagem.
- Aplicar o modelo de rede neural em outras amostras de rochas reservatórios além daquelas descritas neste trabalho.
- Portar *scripts* escritos em *python* para C++ utilizando o *frontend* da biblioteca *PyTorch* para a linguagem.
- Integrar a ferramenta de anotação de regiões de interesse com o *Laboratório Virtual de Petrofísica (LVP)*, de modo a facilitar o processo de obtenção das propriedades petrofísicas da amostra de rocha digital.