

CARACTERIZAÇÃO DE ROCHA DIGITAL USANDO INTELIGÊNCIA
ARTIFICIAL – APLICAÇÃO A SEGMENTAÇÃO DE IMAGENS

JOÃO MARCELO CARDOSO CARVALHO

UNIVERSIDADE ESTADUAL DO NORTE FLUMINENSE
LABORATÓRIO DE ENGENHARIA E EXPLORAÇÃO DE PETRÓLEO

MACAÉ - RJ
MARÇO - 2021

CARACTERIZAÇÃO DE ROCHA DIGITAL USANDO INTELIGÊNCIA ARTIFICIAL – APLICAÇÃO A SEGMENTAÇÃO DE

JOÃO MARCELO CARDOSO CARVALHO

Dissertação apresentada ao Centro de Ciências e Tecnologia da Universidade Estadual do Norte Fluminense, como parte das exigências para obtenção do título de Mestre em Engenharia de Reservatório e de Exploração.

Orientador: André Duarte Bueno, D.Sc.

MACAÉ - RJ
MARÇO - 2021

CARACTERIZAÇÃO DE ROCHA DIGITAL USANDO INTELIGÊNCIA ARTIFICIAL – APLICAÇÃO A SEGMENTAÇÃO DE

JOÃO MARCELO CARDOSO CARVALHO

Dissertação apresentada ao Centro de Ciências e Tecnologia da Universidade Estadual do Norte Fluminense, como parte das exigências para obtenção do título de Mestre em Engenharia de Reservatório e de Exploração.

Aprovada em xx de xxxxxx de 20xx.

Comissão Examinadora:

Prof. Fulano de Tal (Título, FormaçãoMaisElevada) - INSTITUIÇÃO/EMPRESA

Prof. Um Dois Três de Oliveira Quatro (D.Sc, Ciências da Computação) - PURO/UFF

Prof. Fulano de Tal (Ph.D, Matemática) - LENEP/CCT/UENF

Prof. André Duarte Bueno (D.Sc, Engenharia) - LENEP/CCT/UENF - (Orientador)

[Opcional]

[Opcional]

coloque aqui a dedicação da Tese/Dissertação/Monografia.

Ao ...Agradecimentos

Aos pais...

Aos amigos

Aos membros da banca, professores ...

Aos professores e funcionários do LENEP/CCT/UENF...

Ao CENPES/PETROBRAS pelo fornecimento de material....

- Reconhecer que teve ajuda e apoio é uma característica importante para todo profissional e pesquisador.
- Lembre-se dos amigos, dos professores, dos funcionários, dos colaboradores. Lembre-se de quem emprestou/cedeu material, dados, informações, amostras.
- Lembre-se de quem lhe ajudou nos algoritmos/programas;
- Lembre-se de quem lhe ajudou na preparação e realização de experimentos de laboratório.
- Não economize, seja generoso nos agradecimentos.
- Cada agradecimento deve ser curto e objetivo.
- Troque o genérico "aos amigos" pelo nome completo dos seus amigos e nome completo das pessoas que colaboraram com seu trabalho. Os nomes das pessoas devem ser completos (não ambíguos).

Ao comitê gestor do PRH20-ANP-CTPETRO/LENEP/CCT/UENF, a Agência Nacional do Petróleo, Gás Natural e Biocombustíveis – ANP, a Financiadora de Estudos e Projetos – FINEP e ao Ministério da Ciência e Tecnologia – MCT pelo fornecimento de bolsa de estudos e taxa de bancada por meio do Programa de Recursos Humanos da ANP para o Setor Petróleo e Gás – PRH-ANP/MCT.

Ao comitê gestor do PRH20-ANP-PETROBRAS/LENEP/CCT/UENF, e a Universidade Petrobras pelo fornecimento de bolsa de estudos e taxa de bancada por meio do PFRH-PETROBRAS, Programa de Formação de Recursos Humanos da Petrobras.

[Opcional e a escolha do autor(a) Ex:]

Sumário

| | |
|---|------------|
| Nomenclatura | xiv |
| 1 Introdução | 1 |
| 1.1 Escopo do Problema | 1 |
| 1.2 Objetivos | 3 |
| 1.3 Organização do Documento | 4 |
| 2 Revisão Bibliográfica | 5 |
| 2.1 Segmentação de Imagens Amostras de Rochas | 5 |
| 2.2 Inteligência Artificial Aplicada à Modelagem de Propriedades Petrofísicas | 7 |
| 2.3 Crítica aos Trabalhos Existentes | 11 |
| 3 Revisão de Conceitos | 13 |
| 3.1 Propriedades das Rochas Reservatórios | 13 |
| 3.2 Processamento de Imagens Digitais | 23 |
| 3.3 Inteligência Artificial | 40 |
| 4 Metodologia | 53 |
| 4.1 Motivação Para o Tema | 53 |
| 4.2 Classificação da Pesquisa | 54 |
| 4.3 Hipóteses | 54 |
| 4.4 Materiais e Pressupostos | 55 |
| 5 Cronograma | 56 |
| 5.1 Etapas Para o Desenvolvimento do Trabalho | 56 |

| | | |
|-----|---------------------------------|----|
| 5.2 | Cronograma de Eventos | 58 |
| 5.3 | Orçamentos | 58 |

Lista de Figuras

| | | |
|----|--|----|
| 1 | Conhecimentos de Base para Análise de Imagens de Rochas Reservatório [Fonte: (REGO; BUENO, 2010)] | 2 |
| 2 | Imagem em escala de cinza de um arenito obtido por meio de tomografia computadorizada . [Fonte: (LIN <i>et al.</i> , 2018)] | 5 |
| 3 | Imagem binarizada do arenito usando método comum para o cálculo da porosidade . [Fonte: (LIN <i>et al.</i> , 2018)] | 6 |
| 4 | Imagem binarizada do arenito usando método baseado nas características petrofísicas . [Fonte: (LIN <i>et al.</i> , 2018)] | 6 |
| 5 | <i>Framework</i> da metodologia utilizada para prever propriedades de meios porosos utilizando redes neurais convolucionais . [Fonte: (ALQAHTANI <i>et al.</i> , 2018)] | 8 |
| 6 | Correlação entre os valores previstos e reais de porosidade, número de coordenação e tamanho médio de poro, para cada amostra . [Fonte: (ALQAHTANI <i>et al.</i> , 2018)] | 8 |
| 7 | Arquitetura da Inception V3(Google Codelabs) . [Fonte: (HÉBERT <i>et al.</i> , 2020)] | 9 |
| 8 | Estrutura do <i>auto-encoder</i> utilizado para criar a máscara de segmentação . [Fonte: (HÉBERT <i>et al.</i> , 2020)] | 11 |
| 9 | Detalhes da arquitetura de cada camada do <i>auto-encoder</i> . [Fonte: (HÉBERT <i>et al.</i> , 2020)] | 11 |
| 10 | Função Sigmoid e sua Derivada | 12 |

| | | |
|----|---|----|
| 11 | Ângulo de contato formado pela água em relação a uma superfície sólida. [Fonte: (ROSA <i>et al.</i> , 2006)] | 16 |
| 12 | Ângulo de contato formado pela água em relação a uma superfície sólida. [Fonte: (ROSA <i>et al.</i> , 2006)] | 17 |
| 13 | Experimento realizado por Darcy para a formulação da equação da vazão total em um meio poroso. [Fonte: (ROSA <i>et al.</i> , 2006)] | 20 |
| 14 | Relação entre a saturação da fase molhante e sua permeabilidade efetiva para um escoamento bifásico. [Fonte: (ARCHER; WALL, 2012)] | 21 |
| 15 | Processo de embebição de em um escoamento bifásico gás-óleo. [Fonte: (ARCHER; WALL, 2012)] | 22 |
| 16 | Processo de drenagem de em um escoamento bifásico gás-óleo. [Fonte: (ARCHER; WALL, 2012)] | 22 |
| 17 | Relações entre os processos de discretização, reconstrução, codificação e decodificação. [Fonte: (VELHO <i>et al.</i> , 2009)] | 24 |
| 18 | Fenômeno <i>aliasing</i> em um sinal unidimensional. [Fonte: (SZELISKI, 2010)] | 24 |
| 19 | Modelo cromático RGB. [Fonte: (QUEIROZ; GOMES, 2006)] | 27 |
| 20 | Representação em coordenadas cilíndricas dos valores de tonalidade (<i>hue</i>), saturação (<i>saturation</i>) e brilho (<i>brightness</i>). [Fonte: (VELHO <i>et al.</i> , 2009)] | 27 |
| 21 | Imagem ao lado de seu histograma. [Fonte: (VELHO <i>et al.</i> , 2009)] | 28 |
| 22 | Diferenças entre histograma bimodal (a) e multimodal (b). [Fonte: (BHUYAN, 2019)] | 29 |
| 23 | Histogramas e variações de contrastes. [Fonte: (BHUYAN, 2019)] | 30 |

| | | |
|----|--|----|
| 24 | Redução de ruído aplicando filtro de mediana. [Fonte: (GONZALEZ; WOODS, 2010)] | 31 |
| 25 | Duas máscaras 3x3 aplicadas em uma suavização. [Fonte: (GONZALEZ; WOODS, 2010)] | 32 |
| 26 | Resultado do processo de suavização em uma imagem produzida pelo telescópio <i>Hubble</i> . [Fonte: (GONZALEZ; WOODS, 2010)] | 32 |
| 27 | Máscara de um filtro laplaciano 3x3. [Fonte: (GONZALEZ; WOODS, 2010)] | 33 |
| 28 | Segmentação de uma imagem utilização a abordagem baseada em bordas (a, b, c) e em regiões (d, e, f). [Fonte: (GONZALEZ; WOODS, 2010)] | 36 |
| 29 | Processo de aplicação da segmentação por <i>watersheds</i> . [Fonte: (GONZALEZ; WOODS, 2010)] | 37 |
| 30 | Preparação de uma lâmina de uma amostra de um meio poroso. [Fonte: (REGO; BUENO, 2010)] | 39 |
| 31 | Representação de uma árvore de decisão. [Fonte: (SILVA, 2005)] | 43 |
| 32 | Representação de um neurônio artificial. | 45 |
| 33 | Função degrau. | 45 |
| 34 | Função rampa. | 46 |
| 35 | Função sigmoid. | 46 |
| 36 | Função tangente hiperbólico. | 46 |
| 37 | Função ReLU. [Fonte: (CHOLLET <i>et al.</i> , 2018)] | 47 |
| 38 | Rede neural artificial direta com 2 camadas profundas. | 48 |
| 39 | Diagrama sobre a notação matemática de um peso RNA. [Fonte: (NIELSEN, 2015)] | 49 |
| 40 | Relação custo x número de épocas para uma função de custo quadrática. [Fonte: (NIELSEN, 2015)] | 51 |

| | | |
|----|--|----|
| 41 | Relação custo x número de épocas para uma função de custo <i>cross-entropy</i> . [Fonte: (NIELSEN, 2015)] | 52 |
|----|--|----|

Lista de Tabelas

| | | |
|---|--|----|
| 1 | Arquitetura da rede <i>RegPhi</i> | 10 |
| 2 | Cronograma de eventos para o desenvolvimento deste trabalho. | 58 |

Nomenclatura

A nomenclatura está dividida em: alfabeto latino, alfabeto grego, sub-índices, super-índices, símbolos e acrônimos, sendo apresentada em ordem alfabética.

Alfabeto Latino

| | |
|-----------------|---|
| A | Área [m^2] |
| B^r | Reflexão do conjunto B |
| $C(\mathbf{u})$ | Função autocorrelação |
| dl | Variação elementar do comprimento [m] |
| E_x^i | Bola centrada em um ponto x |
| f | Determinada fase de um escoamento |
| F | Força [$Kg \times m/s^2$] |
| g | Aceleração da gravidade [m/s^2] |
| I | Imagem binária |
| k | Permeabilidade [mD] |
| l | Comprimento [m] |
| M | Meio poroso |

Alfabeto Grego

| | |
|---------------------|---|
| β | Compressibilidade [l/Pa] |
| γ_a | Peso específico da água [$kg/m^2 \times s^2$] |
| ε | Comprimento [m] |
| $\zeta(\mathbf{u})$ | Função conectividade |
| θ | Ângulo |
| τ | Tensão cisalhante [N/m^2] |
| μ | Viscosidade [$N.s/m^2$] |
| ν | Viscosidade cinemática [m^2/s] |
| ρ | Massa específica [Kg/m^3] |
| σ | Tensão interfacial [Kg/m] |
| ϕ | Porosidade [m^3/m^3] |

Sub-índices

| | |
|------|-------------------|
| ef | Efetivo |
| eq | Equivalente |
| i | Índice |
| nw | Não molhante |
| p | Poroso |
| rf | Relativa a fase f |
| S | Matriz sólida |
| T | Total |
| x | Posição |
| w | Molhante |

Super-índices

| | |
|------|--------------|
| c | Complemento |
| i | Índice |
| nw | Não molhante |
| r | Reflexão |

Símbolos

| | |
|-------------------|------------------------|
| \oplus | Operador de dilatação |
| \ominus | Operador de erosão |
| \circ | Operador de abertura |
| \bullet | Operador de fechamento |
| $\langle \rangle$ | Média geométrica |
| ∇ | Gradiente |

Acrônimos

| | |
|-----------------|---|
| <i>ASCII</i> | <i>American Standard Code for Information Interchange</i> (Código Padrão Americano para o Intercâmbio de Informações) |
| <i>C++</i> | Linguagem de programação com recursos para orientação a objetos |
| <i>GCS</i> | Grafo de Conexão Serial |
| <i>GMRES</i> | Solver que utiliza o método do Resíduo Mínimo Generalizado |
| <i>IDF</i> | Imagem de Distância ao Fundo |
| <i>lib_Idsc</i> | Biblioteca computacional para análise de imagens de meios porosos |
| <i>LVP</i> | Laboratório Virtual de Petrofísica (<i>Software</i>) |
| <i>SDK</i> | <i>Software Development Kit</i> (Kit para Desenvolvimento de <i>softwares</i>) |

1 Introdução

No presente trabalho desenvolve-se um estudo acerca da aplicação de algoritmos de inteligência artificial no processamento de imagens de rochas reservatório. Mais especificamente, ele é focado no processo de binarização das mesmas, de forma a facilitar a caracterização de propriedades petrofísicas.

Será apresentado nesse capítulo o escopo do problema abordado, uma pequena introdução sobre o tema, os objetivos do trabalho e a organização deste documento.

1.1 Escopo do Problema

É cada vez mais comum a aplicação de algoritmos de inteligência artificial nas mais diferentes áreas de pesquisa, principalmente na engenharia. O uso de algoritmos inteligentes torna factível a execução, em um curto espaço de tempo, de tarefas complexas de classificação e predição. Métodos dessa natureza já haviam sido previstos há décadas, mas somente com o aumento exponencial da capacidade de processamento dos computadores e a diminuição de seu custo isso tem se tornado possível.

O uso dessas metodologias se torna muito pertinente na engenharia de reservatórios, uma vez que a capacidade de prever e delimitar sua capacidade produtiva é essencial no âmbito econômico. Ter conhecimento das propriedades físicas das rochas, como porosidade e permeabilidade, ajudam nesse processo já que são capazes de trazer importantes informações acerca das heterogeneidades que formam tais estruturas. Métodos como análise petrofísica de testemunhos são extremamente úteis nesses aspectos, muitas vezes demandam um custo muito alto para serem realizadas devido aos equipamentos utilizados no processo, como porosímetro e permeâmetro, mas principalmente devido o custo para obter as amostras. Além disso essas análises são destrutivas, logo, o objeto de estudo é perdido depois que o estudo é concluído.

Os recentes avanços no campo da tecnologia de imageamento torna emergente

a análise de rochas por meio de imagens digitais. Microtomógrafos permitem uma análise não destrutiva dos testemunhos e ajudam a construir um entendimento mais completo acerca dos processos físicos em meios porosos. A Figura 1 ilustra de forma simples o procedimento utilizado na análise de imagens de rochas bidimensionais.




Figura 1: Conhecimentos de Base para Análise de Imagens de Rochas Reservatório [Fonte: (REGO; BUENO, 2010)]

O processo se inicia com a aquisição da amostra, seja um testemunho ou uma amostra de calha, que logo em seguida é limpa, polida e passa por um processo de impregnação. As imagens das rochas nesse caso são produzidas em um microscópio óptico ou eletrônico a partir das lâminas obtidas após o polimento. A partir desse ponto todo o procedimento passa a ser realizado no computador, onde as imagens passam por uma etapa crítica de processamento. Primeiramente, no pré-processamento, alguns problemas podem ser corrigidos por meio de filtros. Todavia alguns métodos de pré-processamento podem acabar afetando, em alguns casos, o resultado para propriedades físicas que são dependente da geometria porosa (LEU *et al.*, 2014).

Logo depois, na segmentação, o objetivo é, na maioria dos casos, separar a fase porosa da fase granular. Em muitos casos são utilizadas técnicas que limitam o nível de cinza em uma imagem controlando o *thresholding*. Contudo em estruturas com geometrias mais complexas esses métodos em geral não trazem bons resultados so-

zinhos e acabam dependendo de etapas adicionais (IASSONOV *et al.*, 2009).

O procedimento de caracterização corresponde à obtenção de informações sobre as propriedades da rochas por meio da aplicação de função de autocorrelação, medição do tamanho dos poros e a distribuição dos mesmos.

São nessas três últimas etapas que a aplicação de inteligência artificial pode ser extremamente proveitosa. Com o uso de redes neurais, por exemplo, é possível treinar um algoritmo capaz de reconhecer padrões nas imagens de rochas e assim facilitar o processo de binarização (REGO; BUENO, 2010) ou realizar uma quantificação entre a permeabilidade e caminhos ótimos entre os poros (LINDEN *et al.*, 2016). Florestas Aleatórias, um modelo de aprendizagem de máquina baseado em árvores de decisão, permitem obter classificações mineralógicas dos grãos presentes nas lâminas petrográficas (RUBO *et al.*, 2019).

Redes neurais convolucionais vem sendo utilizadas nos últimos anos para a análise de uma extensa gama de problemas envolvendo reconhecimento facial, classificação de imagens, detecção de borda e segmentação semântica (SIMONYAN; ZISSERMAN, 2014; TAIGMAN *et al.*, 2014; GOODFELLOW *et al.*, 2016; LIN *et al.*, 2016). No campo da pesquisa da engenharia de reservatórios, as redes convolucionais tem sido utilizadas para estimar propriedades como porosidade, tamanho médio de grão e número de coordenação a partir não apenas de imagens 2D de lâminas finas (ALQAHTANI *et al.*, 2018), mas também com imagens 3D provenientes de microtomógrafos (SUDAKOV *et al.*, 2019).

1.2 Objetivos

Os objetivos deste trabalho são:

- Objetivo geral:
 - Desenvolver métodos de inteligência artificial capazes de reconhecer padrões relevantes para a análise das propriedades petrofísicas em imagens de rochas reservatórios.
- Objetivos específicos:
 - Estudar diferentes métodos de aprendizagem de máquina e aprendizagem profundas aplicadas à análise de imagens.

- Estudar o comportamento dos métodos de IA em geometrias de poros complexas.
- Comparar resultados obtidos com aqueles já apresentados na literatura.
- Implementação de algoritmos em C++ e inclusão dos mesmos na biblioteca criada pela equipe do Laboratório de Desenvolvimento de Software Científico (lib_ldsc).

1.3 Organização do Documento

Apresenta-se nesta seção a organização do documento.

No Capítulo 2, “Revisão Bibliográfica”, apresenta-se uma revisão bibliográfica detalhada dos trabalhos, técnicos e científicos relacionados ao desenvolvimento de métodos de inteligência artificial relacionados à segmentação de imagens de rochas reservatórios.

No Capítulo 3, “Revisão dos Conceitos e Modelos a Serem Utilizados”, apresenta-se um conjunto de conceitos e modelos desenvolvidos por outros autores mas que estão diretamente relacionados a este trabalho e que serão amplamente utilizados.

No Capítulo 4, “Metodologia”, apresenta-se a metodologia científica a ser utilizada no desenvolvimento deste trabalho. Inclui-se informações sobre motivação, área da pesquisa, instrumentos (materiais, equipamentos, softwares) utilizados, limitações do tema, pressupostos e hipóteses simplificadoras.

No Capítulo 5, “Cronograma”, serão apresentadas às próximas etapas que relacionadas ao desenvolvimento deste trabalho, bem como um cronograma detalhado do que será realizado nos próximos meses.

2 *Revisão Bibliográfica*

Neste capítulo é apresentada uma revisão bibliográfica dos trabalhos, técnicos e científicos, relacionados ao desenvolvimento de métodos de inteligência artificial associados à segmentação de imagens de rochas reservatórios.

2.1 Segmentação de Imagens Amostras de Rochas

No trabalho de Lin *et al.* (2018) é proposta uma nova metodologia para segmentação de imagens de rochas baseadas na porosidade calculada como limitador para obter o melhor valor de limiar. Dessa forma é levado em consideração características petrofísicas da amostras, o que ajuda na obtenção de resultados mais próximos da realidade quando se trata de segmentação. O resultado obtido por essa nova metodologia é comparado com o calculo convencional de porosidade nas Figuras 2, 3 e 4.




Figura 2: Imagem em escala de cinza de um arenito obtido por meio de tomografia computadorizada .

[Fonte: (LIN *et al.*, 2018)]




Figura 3: Imagem binarizada do arenito usando método comum para o cálculo da porosidade .

[Fonte: (LIN *et al.*, 2018)]




Figura 4: Imagem binarizada do arenito usando método baseado nas características petrofísicas .

[Fonte: (LIN *et al.*, 2018)]

Em Rubo *et al.* (2019) foi possível a geração de modelos de classificação mineralógica dos grãos presentes em amostras de rochas da secção do pré-sal, na bacia de Santos, por meio da utilização de redes neurais artificiais e algoritmos de florestas aleatórias. Nesse trabalho também foram utilizados filtros convolucionais para extrair mais informações sobre cada pixel que compõe a imagem analisada, entre eles o filtro gaussiano, sobel, hessiano e diferença de gaussianas. As redes neurais desenvolvidas utilizaram três camadas profundas com 45 neurônios cada, função logística como função de ativação e gradiente descendente estocástico como algoritmo de aprendizagem. Os modelos foram validados utilizando o teste de validação cruzada “*n-fold*”.

O informação obtida na saída de cada modelo foi dividida em 7 classes: “calcita”, “dolomita”, “quartzo”, “minerais opacos”, “argilas”, “outros” e “poro”. Mesmo que o resultado obtido tenha apresentado uma alta acurácia, o fato de ter sido utilizado imagens apenas de uma determinada região limita os resultados à mesma. Além disso os autores identificaram que os modelos criados confundiram bolhas em regiões porosas como fase sólida e dolomita como outros minerais, e tiveram dificuldade de classificar poros com presença de materiais argilosos.

2.2 Inteligência Artificial Aplicada à Modelagem de Propriedades Petrofísicas

Alqahtani *et al.* (2018) propõe uma abordagem baseada em redes neurais convolucionais para prever de forma rápida propriedades relacionadas aos meios porosos a partir de um *dataset* composto por 7860 imagens 2D em escala de cinza formadas por regiões de interesse de 128 x 128 pixels de microtomografias. Essas imagens representavam amostra de 3 tipos de arenitos diferentes: *Bentheimer*, *Berea* e *Fine-Grain*.

As imagens foram submetidas à um processo de segmentação para diferenciar a matriz dos poros por meio do método de *Otsu*. Em seguida, a rede de poros foi extraída utilizando-se o algoritmo de *watershead*. Assim, foram extraídos os valores de porosidade, número de coordenação e tamanho médio de poro de cada uma das amostras. O passo seguinte foi separar os conjuntos de treino (5680 imagens) e validação (2180 imagens), que foram utilizados para alimentar a rede neural em *batches* de 256 imagens. Para cada tipo de amostra foram realizadas 500 épocas.

A rede neural aplicada utilizou como função de perda a função de *Huber*, que é descrita na equação 2.1 onde a perda L de uma saída a é calculada de acordo como um parâmetro $\delta = 0,5$. Como otimizador foi utilizado o modelo *Adam*, proposto por Kingma e Ba (2014). Sua estrutura foi composta por 5 camadas convolucionais, que realizavam a operação de convolução, ativação por *ReLU*, normalização e *max pooling*; uma camada para as operações de *flattening*, ativação com *ReLU* e *dropout*; e uma última camada usada como saída com a informação sobre a propriedade física. A Figura 5 ilustra a metodologia utilizada pelos autores.

$$L_s(a) = \begin{cases} 0,5a^2 & |a| \leq \delta \\ (|a| - 0,5\delta) \delta & |a| > \delta \end{cases} \quad (2.1)$$

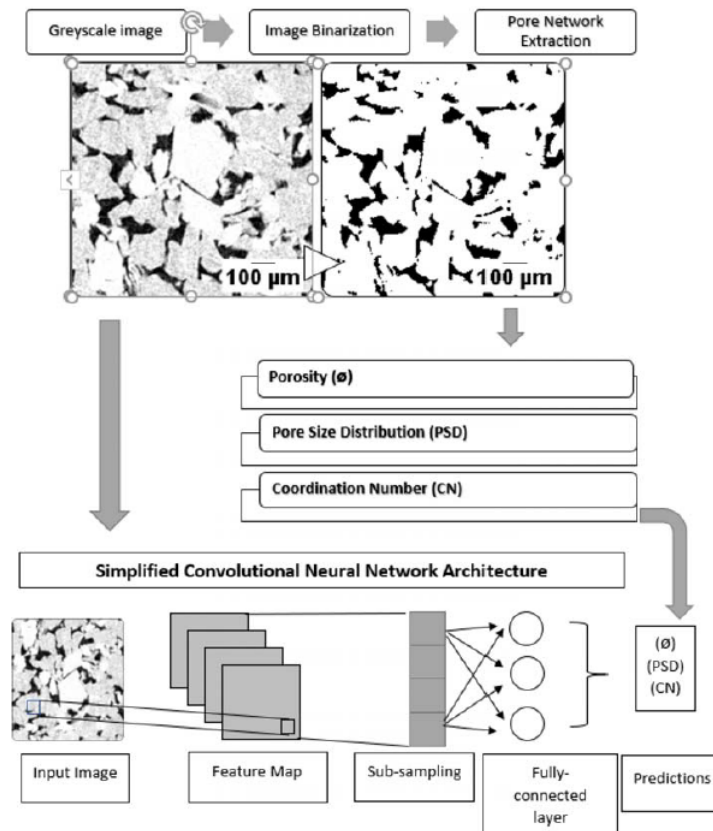


Figura 5: *Framework* da metodologia utilizada para prever propriedades de meios porosos utilizando redes neurais convolucionais .

[Fonte: (ALQAHTANI *et al.*, 2018)]

Como resultado, o modelo foi capaz de estimar os valores de porosidade, tamanho médio dos grãos e número de coordenação com um erro médio de 0.05, 1.8 e 0.17 μm , respectivamente. . A Figura 6 mostra uma relação entre os valores previstos e os valores reais para cada uma das amostras de validação.




Figura 6: Correlação entre os valores previstos e reais de porosidade, número de coordenação e tamanho médio de poro, para cada amostra .

[Fonte: (ALQAHTANI *et al.*, 2018)]

Já em Hébert *et al.* (2020) foi utilizada uma abordagem semelhante, envolvendo

redes neurais convolucionais e um *dataset* de treino composto por 15 mil amostras 2D de 4 tipos de rochas: carbonatos provenientes das formações de *Estailades* e *Savonnieres*, e arenito *Berea* e *Fontainebleau*. As propriedades física de porosidade, permeabilidade e tortuosidade foram extraídas por um usuário experiente por meio do *software Voxilon* (RODRIGUEZ *et al.*, 2019). As propriedades permeabilidade e tortuosidade não foram aplicadas ao trabalho.

Para o problema de classificação, 4 mil imagens foram utilizadas como insumo para um modelo pré treinado do *Google* para a resolução de problemas de classificação e extração de atributos chamado *Inception V3*, cuja estrutura é mostrada na Figura 7. Para que esse modelo fosse utilizado, aplicou-se o conceito de transferência de conhecimento, no qual as primeiras camadas da rede são mantidas intactas, e somente a ultima camada é adaptada para o problema a ser analisado. Dessa forma poupa-se bastante tempo, já que não foi necessário treinar a rede várias vezes para reajustar os parâmetros de todas as camadas. Nesse caso foi utilizado uma função de ativação *softmax*. Estimou-se então os valores de porosidade das imagens de entrada com resolução de 299 x 299 pixels. Os testes foram feitos utilizando um conjunto de 1200 imagens, 300 para cada classe, e foi obtido um resultado de 100% para todas as amostras. Ou seja, o modelo se tornou capaz de distinguir entre qualquer um dos tipos de rocha utilizada.

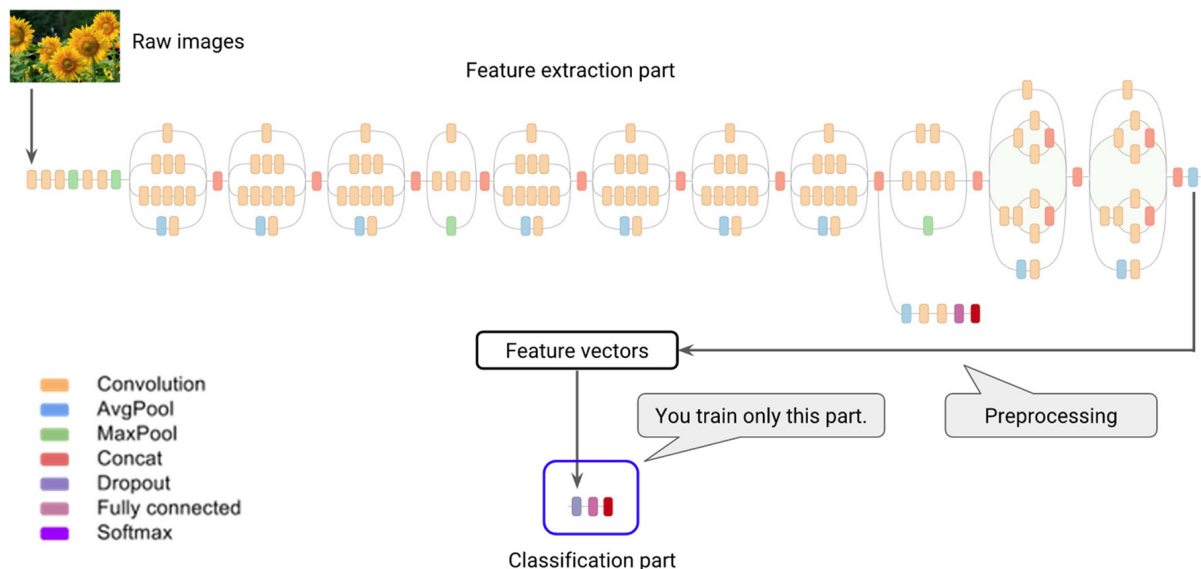


Figura 7: Arquitetura da Inception V3(Google Codelabs) .[Fonte: (HÉBERT *et al.*, 2020)]

Para a estimativa da porosidade foram utilizadas 3500 blocos 3D de 100 x 100 x 100 voxels para treinar uma rede convolucional baseado no trabalho de Sudakov *et al.* (2019). A arquitetura do modelo *RegPhi* é mostrado na Tabela 1. Os testes foram

feitos em um conjunto com 1000 imagens 3D com as mesmas dimensões dos dados de entrada. Obteve-se um erro relativo médio em 18% e uma mediana abaixo de 15% na previsão dos valores de porosidade.

Tabela 1: Arquitetura da rede *RegPhi*.

| Tipo de Camada | Parâmetros |
|-----------------------|--|
| Convolução 3D | filters=32, kernel_size=(5, 5, 5), strides=(2,2,2), padding='valid', activation='relu' |
| Convolução 3D | filters=32, kernel_size=(5, 5, 5), strides=(2,2,2), padding='valid', activation='relu' |
| <i>Max Pooling</i> 3D | pool_size=(2, 2, 2) |
| Convolução 3D | filters=32, kernel_size=(3, 3, 3), padding='valid', activation='relu' |
| Convolução 3D | filters=32, kernel_size=(3, 3, 3), padding='valid', activation='relu' |
| <i>Max Pooling</i> 3D | filters=32, kernel_size=(3, 3, 3), padding='valid', activation='relu' |
| Densa | units=128, activation='relu' |
| Densa | units=64, activation='relu' |
| <i>Flatten</i> | - |
| Densa | units=1 |

Os autores deste trabalho ainda utilizaram uma terceira metodologia para estimar a porosidade a partir de um processo de segmentação automatizada gerado por um *auto-encoder*. A ideia aqui foi computar atributos de alto nível a partir de uma imagem 3D que já contenha alguma informação acerca da porosidade e então decodificar esses atributos em uma máscara de segmentação, onde cada valor representa a probabilidade de um *voxel* ser um poro ou não. A estrutura da rede montada é mostrada nas Figuras 8 e 9. A função de perda aplicada aqui é uma junção da função *cross-entropy*, e o erro médio quadrático entre o valor de porosidade previsto e o computado no *bottleneck*, e entre o valor da probabilidade final e a computada no *bottleneck*.

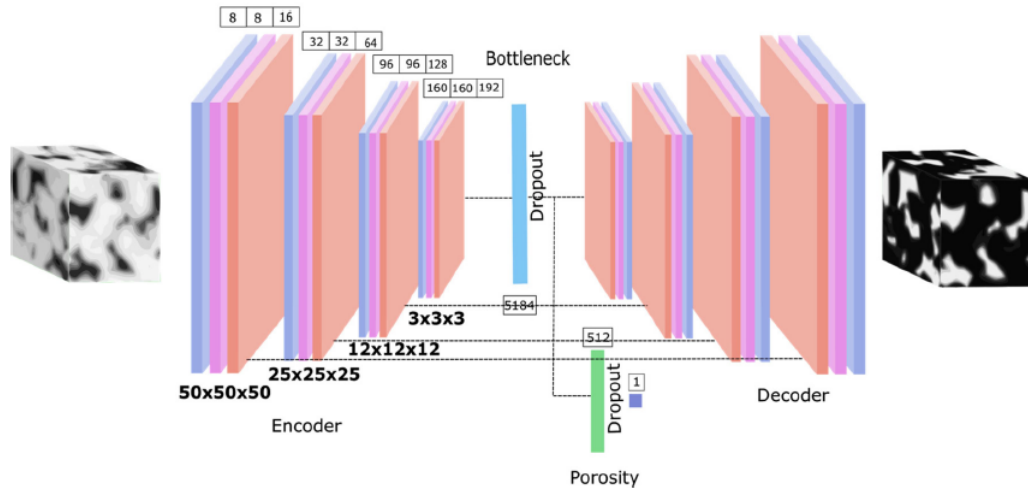


Figura 8: Estrutura do *auto-encoder* utilizado para criar a máscara de segmentação .
[Fonte: (HÉBERT *et al.*, 2020)]

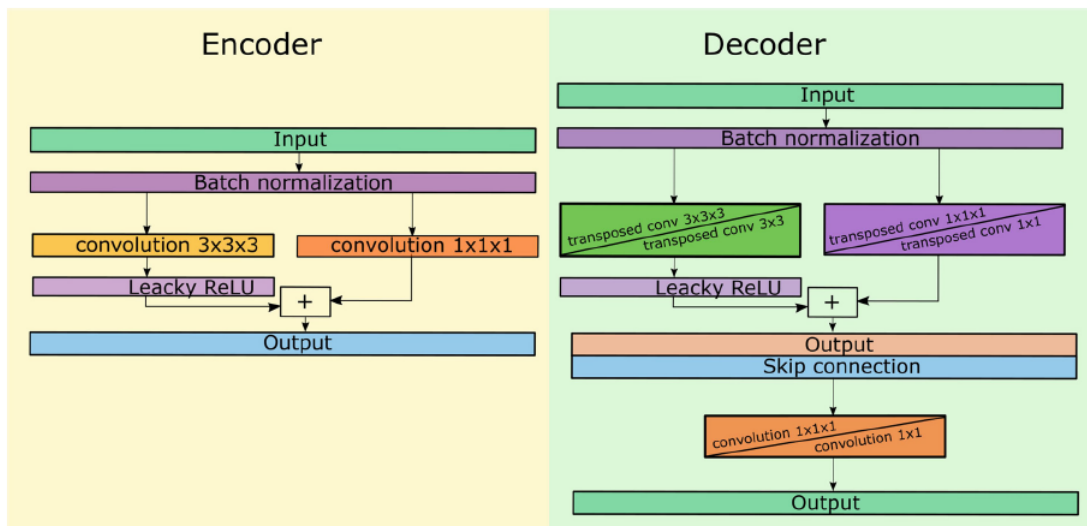


Figura 9: Detalhes da arquitetura de cada camada do *auto-encoder* .
[Fonte: (HÉBERT *et al.*, 2020)]

2.3 Crítica aos Trabalhos Existentes

No trabalho de Rubo *et al.* (2019) poderia ser feita uma tentativa de ser treinar a base de dado utilizando outras funções de ativação como ReLU e softmax, que já se mostraram bastante proeminentes em outros trabalhos envolvendo redes convolucionais e visão computacional. A função escolhida (função logística ou *sigmoid*) já se mostrou problematica no que se diz respeito à aplicação de sua derivada (TAN; LIM, 2019; HU *et al.*, 2018; NIELSEN, 2015). Como se sabe, para se treinar uma rede neural

os pesos e *biases* devem ser atualizados de forma a minimizar o valor retornado por uma função de custo, e a Equação 3.44 mostra que essa atualização ocorre de forma associada ao gradiente das função de ativação. No momento que esse gradiente se torna cada vez menor observa-se o fenômeno do *vanishnig gradient*, ou seja, os novos valores de peso se tornam tão pequenos que a rede neural se torna cada vez mais difícil de se treinar.

Na figura 10 é mostrado um gráfico com a função *sigmoid* $\sigma(x)$ e sua derivada. Nela fica fácil entender porque essa função se torna um probla em algoritmos de redes neurais que são treinados de forma dependente das funções de ativação. Quanto mais $\sigma(x)$ se aproxima de 1, menor se torna seu gradiente.




Figura 10: Função Sigmoid e sua Derivada

Outros algoritmos de aprendizagem além do gradiente descendente estocastico (*Stochastic Gradient Descendent*) também poderiam ser aplicados para ajudar a contornar esse problema. O trabalho de Alqahtani *et al.* (2018) se mostrou bem sucedido nesse aspecto, mas todavia ainda foram observadas dificuldades no que se diz respeito a anomalias provocadas por minerais de brilho mais intenso, algo que poderia ser melhorado se fosse utilizado um *dataset* com valores de intensidade mais bem distribuídos.

3 *Revisão de Conceitos*

Este capítulo apresenta um conjunto de conceitos e modelos desenvolvidos por outros autores e que estão diretamente relacionados a este trabalho, estes conceitos serão utilizados neste trabalho.

3.1 Propriedades das Rochas Reservatórios

Esta seção trata de definir alguns conceitos relacionados às propriedades físicas das rochas reservatório, dentre elas porosidade, permeabilidade, capilaridade.

3.1.1 Petrofísica

Por definição, a petrofísica é o estudo das propriedades físicas e químicas das rochas detentoras e geradoras de hidrocarbonetos, dos selos, de aquíferos, e os fluidos as percolam, principalmente no que se diz respeito à sistemas porosos, a distribuição de fluidos e as características do escoamento sob essas condições (AHMED, 2018).

3.1.2 Rochas Reservatórios

Em um sistema petrolífero, uma rocha reservatório é, de forma geral, uma estrutura geológica que se torna capaz de armazenar o óleo ou gás que foi gerado ou migrado para a mesma. Para isso ela deve possuir alguma tipo de porosidade, de forma que seja possível um fluido poder se acumular ali (COSSE, 1993). Os reservatórios comerciais, em sua grande maioria, são formados por rochas sedimentares clásticas e não clásticas, especialmente arenitos e calcarenitos.

Os reservatórios de arenitos são, na maioria dos casos, de grande espessura e continuidade lateral, sendo o tipo de rocha-reservatório mais comum. Considerando sua porosidade intergranular, ou seja, aquela formada a partir da porosidade inicial

e reduzida após processos de cimentação, observa-se uma porosidade de aproximadamente 10 a 20 %, que pode ser muito maior se for considerada a porosidade gerada por fraturas. No caso de rochas carbonatadas, ou seja, calcários e dolomitas, a porosidade pode ser muitas vezes maior que no caso dos arenitos, dando ao reservatório uma grande permeabilidade (ROSA *et al.*, 2006).

3.1.3 Porosidade

A porosidade, do ponto de vista da engenharia de reservatórios, é a medida de espaço disponível para que o petróleo possa ser armazenado (ARCHER; WALL, 2012). É definida, portanto, como a razão entre o volume de espaço vazio e o volume total da rocha e é representado pela letra $\phi[m^3/m^3]$ na Equação 3.1:

$$\phi = \frac{V_{vazios}}{V_{total}} \quad (3.1)$$

A porosidade pode ser classificada de acordo com a maneira na qual foi originada. A porosidade primária se desenvolve no momento da deposição sedimentar e é observada nos arenitos como intergranular e nos calcários como intercrystalina ou oolítica. Já a porosidade secundária se desenvolve a partir de processos geológicos subsequentes, como a formação fraturas ou pela dissolução da rocha, o que é mais observado em calcários (LAKE *et al.*, 2006).

No estudo da porosidade é comum definir dois conceitos relacionados à forma com a qual os poros se conectam, a porosidade total e efetiva. Na porosidade total, considera-se todo o volume de vazios presente em uma rocha, independente se estão isolados ou não. A porosidade efetiva trata da razão entre o volume de poros que estão devidamente interconectados e o volume total. É uma medida que, do ponto de vista da engenharia, é de suma importância, já que está relacionada com o percentual de fluido que possui alguma mobilidade dentro do sistema rochoso (TERRY *et al.*, 2015).

Em areias muito limpas se, livres de grãos argilosos, a porosidade total chega bem próximo de se igualar à porosidade efetiva. A relação entre a porosidade total e efetiva por meio do modelo representado na Equação 3.2, (COSSE, 1993).

$$\phi_{total} = \phi_{efetiva} + V_{argilas} \times \phi_{argilas} \quad (3.2)$$

3.1.4 Saturação

A saturação é definida como a fração de volume poroso ocupado por um fluido em particular. No caso de reservatórios, normalmente se observa água, gás ou óleo. Expressando de forma matemática o que se tem é:

$$S_{fluido} = \frac{V_{fluido}}{V_{poroso}} \quad (3.3)$$

De acordo com Dake (1983), acredita-se que os fluidos dentro de um reservatório tenham a muito alcançado um estado de equilíbrio, e portanto estão separados de acordo com sua densidade. Em um escoamento, existe um ponto de saturação do óleo no qual ele permanece parado chamado de saturação crítica do óleo $S_{oc}[m^3/m^3]$. A medida que os poros são preenchidos com algum outro fluido, como em um processo de injeção de água ou gás, a saturação chega ao um ponto que se torna maior que a saturação crítica do óleo. Esse ponto é chamado de saturação de óleo residual S_{or} .

Define-se como a saturação de água existente no reservatório, no momento de sua descoberta, como a saturação de água inicial, inata ou conata $S_{wi}[m^3/m^3]$ (ARCHER; WALL, 2012). Durante a produção de óleo, a pressão do reservatório começa a cair, o que dependendo das condições iniciais, permite o aumento da saturação de gás no mesmo. Por meio do balanço de materiais dentro da formação é possível inferir uma saturação média do óleo durante a produção. Considerando um reservatório, inicialmente em uma condição subsaturada, com uma pressão maior do que a pressão de bolha do óleo, a saturação do óleo S_o pode ser calculada aplicando a Equação 3.4:

$$S_o = \left(1 - \frac{N_p}{N}\right) \frac{B_o}{B_{oi}} (1 - S_{wi}), \quad (3.4)$$

onde $N_p[m^3]$ é o volume de óleo produzido, $N[m^3]$ é o volume de óleo original, $B_o[m^3/m^3]$ é o fator volume-formação de óleo, e $B_{oi}[m^3/m^3]$ é o fator volume-formação de óleo à pressão inicial.

3.1.5 Capilaridade

A capilaridade é um fenômeno observado no interior de meios porosos em decorrência da presença de 2 ou mais fluidos, imiscíveis, ocupando o mesmo espaço vazio. Devido à essas condições, a separação desses fluidos não ocorre da forma que se espera, ou seja por meio de diferença de densidades (ROSA *et al.*, 2006). A presença

de capilares de diferentes tamanhos torna menos brusca a superfície de separação entre eles, o que provoca a formação de uma zona de transição.

A capilaridade é resultado das interações entre as moléculas dos fluidos, que tendem a ser atraídas em todas as direções pelas moléculas que às cercam, exceto se estiverem na superfície. Nessa região formam uma espécie de membrana elástica que prove resistência a separação.

Em um reservatório o estado de equilíbrio é governado por mecanismos de capilaridade, entre eles a molhabilidade, a tensão interfacial entre fluidos e a pressão capilar nos poros.

A molhabilidade pode ser observada ao se imaginar uma superfície sólida com a presença de dois fluidos imiscíveis sobre ela. Observa-se que no caso desses fluidos serem água e ar, a água tende a se espalhar ao longo da superfície, e o ângulo θ formado entre a conexão entre ela e o sólido é menor que $\pi/2$. Então pode se dizer que a água molha mais a superfície sólida que o ar. Agora se o fluido no lugar da água for, por exemplo, mercúrio, o ângulo formado será maior que $\pi/2$, e portanto nesse caso, o ar se torna o fluido molhante. A Figura 11 ilustra esse fenômeno para o caso da mistura de água e óleo.




Figura 11: Ângulo de contato formado pela água em relação a uma superfície sólida. [Fonte: (ROSA *et al.*, 2006)]

A tensão superficial σ [dyna/cm] entre a interface de dois fluidos imiscíveis pode ser definida como a força por unidade de comprimento necessária para manter o contato entre ambas as superfícies (AMYX *et al.*, 1960). Pode-se dizer que é a força que impede o rompimento das membranas formadas por cada um dos fluidos.

Considerando um cilindro de raio r [m], imerso em um recipiente contendo um fluido, por exemplo, água, percebe-se que esta tende a ascender até uma determinada altura h [m] no cilindro, conforme é mostrado na Figura 12. Também é possível

verificar que se forma uma interface esférica entre a água, que aqui é o fluido molhante. A pressão capilar é a diferença de pressão entre os dois pontos A e B :

$$P_{capilar}[Pa] = P_A - P_B. \quad (3.5)$$

Em uma condição de equilíbrio, a resultante vertical da tensão superficial é igualada à ação da pressão capilar na secção transversal do tubo. A Equação 3.6 descreve então a pressão capilar para uma superfície cilíndrica em função de seu raio r e da tensão superficial σ :

$$2\pi r \sigma \cos(\theta) = P_c \pi r^2$$

$$P_c = \frac{2\sigma \cos(\theta)}{r} [Pa]. \quad (3.6)$$




Figura 12: Ângulo de contato formado pela água em relação a uma superfície sólida.
[Fonte: (ROSA *et al.*, 2006)]

A partir da formulação dos conceitos de capilaridade e saturação é possível tirar algumas conclusões sobre o assunto. Para uma amostra de rocha saturada com dois fluidos diferentes pode-se observar que o fluido molhante é deslocado se o outro fluido com o qual ele interage exercer sobre ele uma pressão que exceda a pressão capilar dos poros.

3.1.6 Permeabilidade

A permeabilidade é a propriedade que relaciona a capacidade de uma determinada formação deixar transmitir um fluido. É, em outras palavras, a condutividade de fluidos de um material, ou inverso da resistência que o mesmo oferece à um escoamento (EZEKWE, 2010). É uma propriedade importante, uma vez que controla o movimento direcional do fluido e sua vazão.

A estimativa da permeabilidade em um sistema poroso pode ser feita inicialmente por meio de uma simplificação da sua geometria, considerando uma sequencia de feixes de capilares. A Equação de *Poiseuille* dita o comportamento de um escoamento viscoso de superfícies cilíndricas concêntricas, de viscosidade μ , que se movem em diferentes velocidades v [m/s]. A força viscosa F [N] que essas superfícies exercem umas sobre as outras em um cilindro de comprimento L [m] e raio r [m] é igual à:

$$F = -\mu A \frac{dv}{dx} = -\mu(2\pi r L) \frac{dv}{dx}. \quad (3.7)$$

Considerando que existe, além das forças viscosas, a ação do diferencial de pressão $\Delta P = (p_1 - p_2)[Pa]$ sobre a área da secção do cilindro πr^2 igual a:

$$F_{pressão} = \Delta P \pi r^2 \quad (3.8)$$

sob uma aceleração constante, $F_{visc} = F_{pressão}$ e portanto,

$$dv = -\frac{(p_1 - p_2)}{2\mu L} r dr. \quad (3.9)$$

Integrando a Equação 3.9

$$\int dv = -\frac{(p_1 - p_2)}{2\mu L} \int r dr$$

$$v = -\frac{(p_1 - p_2)}{2\mu L} r^2 + C_1,$$

onde C_1 é uma constante arbitrária, produto da integração.

Considerando uma condição de não escorregamento na parte do cilindro, ou seja, quando $r = r_0 \Rightarrow v = 0 \mid r_0 = 0$, então a constante C_1 torna-se,

$$C_1 = \frac{r_0^2(p_1 - p_2)}{4\mu L}$$

$$v = \frac{(r_0^2 - r^2)(p_1 - p_2)}{4\mu L}.$$

Se, a vazão do fluido ao longo de um elemento com área é igual a:

$$dq = v dA, \quad (3.10)$$

então a vazão como um todo será,

$$\begin{aligned} \int_0^q dq &= \int_r^{r_0} v dA \\ q &= \int_r^{r_0} \frac{(r_0^2 - r^2)(p_1 - p_2)}{4\mu L} 2\pi r dr \\ q &= \frac{\pi r_0^4(p_1 - p_2)}{8\mu L} \end{aligned} \quad (3.11)$$

Todavia, essa equação tem sua aplicação dificultada devido a irregularidade e a não linearidade dos poros ao longo de uma determinada formação. Sendo assim, ela se torna inaplicável na maioria dos casos mais complexos.

A formulação de Darcy, descrita na Equação 3.12 é utilizada justamente para contornar esse problema, uma vez que parte de uma constatação empírica do fenômeno do escoamento em meios porosos. A Figura 13 mostra como o experimento foi realizado para se chegar no seguinte resultado:

$$q = KA \frac{(h_1 - h_2)}{L} [m^2/s], \quad (3.12)$$

onde $A[m^2]$ representa a área da seção transversal, $L[m]$ o comprimento ou a altura do meio poroso, $h[m]$ a altura de água medido pelo manômetro durante o experimento e $K[md]$ é uma constante de proporcionalidade característica do meio e do fluido.




Figura 13: Experimento realizado por Darcy para a formulação da equação da vazão total em um meio poroso.

[Fonte: (ROSA *et al.*, 2006)]

Sob as condições de um fluxo horizontal, isotérmico, laminar e permanente de um fluido de natureza incompressível, homogêneo e de viscosidade invariável com o tempo, ao longo de um meio poroso homogêneo e não reativo, a equação da *Darcy* se torna:

$$q = \frac{kA\Delta P}{\mu L}, \quad (3.13)$$

onde $k[mD]$ é definida como a permeabilidade absoluta do meio poroso e é medida em *milidarcy* (*D*).

Essa permeabilidade absoluta é intrínseca ao meio poroso e independe do tipo de fluido ali presente. Se dentro de um mesmo poro for observado mais de um fluido, passa-se a medir a permeabilidade efetiva k_i de cada um desses fluidos. Assim, a permeabilidade relativa $k_{r,i}$ pode ser definida como a razão entre a permeabilidade efetiva e a permeabilidade absoluta do meio poroso, ou seja,

$$k_{r,i} = \frac{k_i}{k}. \quad (3.14)$$

É conveniente associar a permeabilidade relativa com a saturação em um meio poroso, uma vez que se observa que a permeabilidade efetiva de um determinado

fluido cai conforme a saturação do mesmo (AHMED, 2018). Na Figura 14 essa relação é mostrada para um escoamento bifásico, no qual w representa a fase molhante e nw a fase não-molhante. Nela é possível observar que a saturação do fluido molhante S_w é máxima quando a fase não-molhante atinge sua saturação residual.

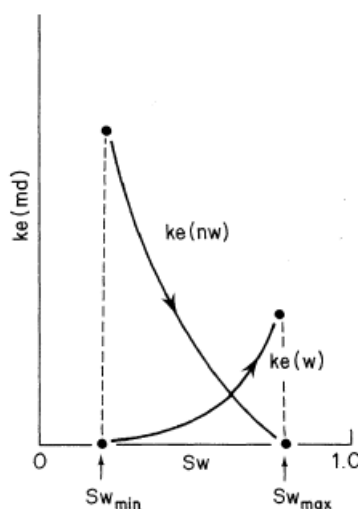


Figura 14: Relação entre a saturação da fase molhante e sua permeabilidade efetiva para um escoamento bifásico.

[Fonte: (ARCHER; WALL, 2012)]

Segundo Jr (2017), se um meio poroso está inicialmente saturado com um fluido que molha, e aos poucos se introduz uma segunda fase de um fluido que não molha, observa-se um processo de drenagem. Se a situação se inverte, ou seja, um meio saturado inicialmente com um fluido não molhante é invadido por uma fase molhante, o que acontece é um processo de embebição. Nesse ultimo, o fluido molhante se aloja às paredes dos capilares de menor diâmetro, forçando o fluido não-molhante para regiões com diâmetros maiores, até que em um certo ponto, a saturação dessa fase atinge um ponto crítico e a mesma deixa de escoar, como é possível ver na Figura 15 para o gás (não-molhante) e o óleo (molhante).




Figura 15: Processo de embebição de em um escoamento bifásico gás-óleo.

[Fonte: (ARCHER; WALL, 2012)]

Na drenagem, o fluido não-molhante entra inicialmente no meio poroso e ocupa as partes centrais dos poros de maior diâmetro até que seja atingido um ponto crítico de saturação para que o seja formada uma fase contínua e ele possa escoar (ARCHER; WALL, 2012). De forma semelhante, a Figura 16 ilustra esse processo.




Figura 16: Processo de drenagem de em um escoamento bifásico gás-óleo.

[Fonte: (ARCHER; WALL, 2012)]

3.2 Processamento de Imagens Digitais

Nesta seção serão apresentados os principais conceitos envolvendo imagens digitais e seu processamento, principalmente no que se diz respeito à aplicação de filtros para segmentação e binarização. Ao final encontra-se uma breve descrição sobre os procedimentos necessários para a aquisição e tratamento de imagens de rochas reservatórios.

3.2.1 Imagens Digitais

Segundo Velho *et al.* (2009) uma imagem definida por uma função bidimensional $f(x, y)$ é considerada digital quando suas coordenadas espaciais x e y , e a sua intensidade, ou nível de cinza f , representam quantidades discretas e finitas. Essas quantidades formam a unidade mais básica de uma imagem digital, o pixel. É possível afirmar ainda que uma imagem é o resultado de um estímulo luminoso em um sensor, seja este uma câmera fotográfica ou a retina humana.

3.2.1.1 Amostragem e Quantização

O processamento digital de imagens é composto de um complexo conjunto de tarefas interconectadas que se inicia com a captura da imagem, que representa a iluminação refletida na superfície dos objetos (VELHO *et al.*, 2009). Uma imagem capturada pode ser contínua em relação aos valores de suas coordenadas espaciais x, y e aos valores de intensidade. A amostragem é a digitalização dos valores espaciais e a quantização dos valores de amplitude. Com essa informação a imagem é discretizada em, por exemplo, uma matriz 2-D I_{MN} , na qual M representa o número de linhas, e N o número de colunas.

A discretização é a tarefa de converter um sinal de natureza contínuo (um sinal físico) em um modelo discreto (GONZALEZ; WOODS, 2010). Em oposição à ela existe a reconstrução, que trata de tornar contínuo um sinal inicialmente discreto. Todavia, em geral, esse processo nunca retorna uma reconstrução exata do que era o sinal original, mas sim uma função aproximada. A qualidade dessa aproximação varia de uma aplicação para a outra.

O sinal discreto para ser trabalhado em computadores digitais ainda demanda de uma etapa de codificação, no qual ele é reorganizado na forma de uma estrutura de dados formado por um conjunto finito de símbolos (PHILLIPS, 1994). De forma

análoga à discretização/reconstrução, o sinal codificado pode ser decodificado em uma imagem discreta. A escolha da estrutura de dados e do conjunto simbólico dita se esse novo sinal apresentará perdas, a velocidade no qual ele é tratado e a quantidade de espaço que poderá ocupar na memória de um sistema. A Figura 17 ilustra as etapas de discretização, reconstrução codificação e decodificação.




Figura 17: Relações entre os processos de discretização, reconstrução, codificação e decodificação.

[Fonte: (VELHO *et al.*, 2009)]

As vezes, durante o processo de aquisição de uma imagem pode acontecer da taxa de amostragem não ser suficiente para capturar todas as nuances de uma cena, provocando a formação de serrilhados (BHUYAN, 2019). Esse fenômeno é denominado de *aliased*, e para entender melhor como ele funciona a Figura 18 mostra o resultado da amostragem unidimensional de dois sinais, com frequências iguais a $f_{azul} = 3/4$ e $f_{vermelho} = 5/4$, e a taxa de amostragem $f_{amostragem} = 2$. O que se observa é que ambos os sinais apresentam as mesmas amostras e isso se torna um problema, já que se torna impossível agora reconstruir o sinal original.




Figura 18: Fenômeno *aliasing* em um sinal unidimensional.[Fonte: (SZELISKI, 2010)]

A taxa mínima de amostragem para que um sinal possa ser reconstruído é descrito pelo teorema de *Shannon* como pelo menos o dobro da frequência máxima do sinal,

ou frequência de *Nyquist* (SZELISKI, 2010). Dessa forma:

$$f_s \geq 2f_{max}. \quad (3.15)$$

3.2.1.2 Etapas do Processamento

No pré-processamento são aplicados filtros para a atenuação dos ruídos e das distorções geométricas provocadas pelos sensores durante a etapa de captura.

A identificação dos elementos ou objetos que compõem uma imagem dependem de um trabalho de extrair informações a respeito de bordas, texturas e vizinhanças entre os pixels. Depois, por um processo de segmentação, o qual demanda de técnicas sofisticadas de regularização e modelagem, esses objetos são separados do fundo da imagem.

A partir da forma geométrica dos objetos, obtida na segmentação, é possível aplicar operadores morfológicos a fim de analisar, modificar e extrair informações que podem ser úteis em modelos de classificação, ou seja, reconhecer, inferir e verificar a identidade dos objetos.

3.2.2 Sistemas de Cores e Histogramas

Cores são uma resposta subjetiva relacionada com os aspectos fisiológicos e psicológicos do sistema visual humano quando estimulado por uma onda eletromagnética dentro de uma pequena faixa do espectro de frequências (GONZALEZ; WOODS, 2010). A cor, não é, portanto uma característica da luz, mas uma sensação provocada pelo complexo sistema sensorial eletroquímico do corpo humano baseada na atividade do cérebro, olhos e do nervo óptico.

A percepção de cor nos olhos, em qualquer ponto de uma determinada cena, é dependente também da percepção de cores nos outros pontos ao seu redor (VELHO *et al.*, 2009).

Um sistema de cores é um sólido de cor que possa ser definido em um sistema de coordenadas. Um vetor de cor C pode ser definido pela Equação 3.16, onde c_i representam as coordenadas.

$$C = \sum_{i=1}^n c_i P_i. \quad (3.16)$$

De acordo com Velho *et al.* (2009) é possível definir quatro sistemas de cores que são mais importantes no campo da computação gráfica e no processamento de imagens:

- Sistemas de Cor Padrão: permitem a especificação dos sistemas de cores independente de sua aplicação;
- Sistemas de Cor de Dispositivos: relacionados a dispositivos de entrada, processamento e saída de imagens;
- Sistemas de Cor de Interface: usado para facilitar a especificação das informações de color por parte do usuário.
- Sistemas de Cor Computacionais: utilizados para a realização de cálculos em aplicações científicas.

Dentre estes, os mais comuns são os sistemas cromáticos CIE-RGB, HSV e HSL.

O sistema CIE-RGB define um espaço de cores tricromático baseado nas porções superior (azul), média (verde) e inferior (vermelho) do espectro visual, correspondendo aos valores de frequência definidos pela Comissão Internacional de Iluminação (QUEIROZ; GOMES, 2006):

$$\lambda_{red} = 700 \text{ nm}$$

$$\lambda_{green} = 546,1 \text{ nm}$$

$$\lambda_{blue} = 435,8 \text{ nm}.$$

Essas cores, combinadas duas a duas, em igual intensidade, produzem as suas secundárias, ou seja, Ciano, Magenta e Amarelo. A cor oposta a uma cor secundária é a cor primária que não entra na sua combinação, ou seja, o oposto do magenta é verde, do ciano é o vermelho e do amarelo é o azul. A cor branca é gerada pela combinação das três primárias ou da cor secundária com a sua oposta. Na Figura 19 essas relações são mostradas de forma mais clara.




Figura 19: Modelo cromático RGB.[Fonte: (QUEIROZ; GOMES, 2006)]

Sistemas de cores de interface são menos práticos em termos computacionais, porém muito mais intuitivas quando se trata de usabilidade (NIXON; AGUADO, 2019). Características como luminância, saturação e tonalidade (*hue*) estão muito mais ligadas a forma que humanos percebem as cores. Isso torna mais fácil, por exemplo, tornar uma cor mais “clara” ou mais “escura”, o que em termos de RGB se apresenta uma tarefa mais complicada.

A tonalidade de uma cor representa o comprimento de onda da mesma, ou, em outras palavras, seria a cor na sua forma pura. A saturação é o quanto de branco se mistura com essa cor, ou seja, quanto menos branco, menos saturada. Por fim, a luminância está ligada com a noção de intensidade. Essas quantidades são muitas vezes representadas graficamente em coordenadas cilíndricas conforme mostrado na Figura 20.




Figura 20: Representação em coordenadas cilíndricas dos valores de tonalidade (*hue*), saturação (*saturation*) e brilho (*brightness*).

[Fonte: (VELHO *et al.*, 2009)]

O modelo HSI (*hue, saturation, brightness*) pode ser descrito na forma de coorde-

nadas RGB usando uma série de transformações descritas nas Equações 3.17, 3.18 e 3.19, nos quais R , G e B representam os das cores primárias. Na maioria das aplicações esses valores podem ser normalizados, como é mostrado na Equação 3.20 (SZELISKI, 2010).

$$H = \tan \left[\frac{3(G - B)}{(R - G) + (R - B)} \right] \quad (3.17)$$

$$S = 1 - \frac{\min(R, G, B)}{I} \quad (3.18)$$

$$I = \frac{R + G + B}{3} \quad (3.19)$$

$$r = \frac{R}{R + G + B}, g = \frac{G}{R + G + B}, b = \frac{B}{R + G + B}. \quad (3.20)$$

3.2.2.1 Histograma

A quantidade de pixels que possuem uma determinada tonalidade em uma imagem pode ser denominado como uma espécie de frequência desses tons, sejam eles coloridos ou em escala de cinza. O conjunto de todas essas frequências podem ser compiladas graficamente em um histograma (REGO; BUENO, 2010), conforme é mostrado na Figura 21. Considerando que uma imagem digital tenha quantidades finitas de intensidade de cor, então essas quantidades podem ser representadas na forma de uma função discreta $h(i) = n_i$, onde n_i é quantidade de pixels que apresentam uma intensidade i . Na Figura 21 uma imagem e seu histograma.



Figura 21: Imagem ao lado de seu histograma.[Fonte: (VELHO *et al.*, 2009)]

O histograma pode ser considerado uma distribuição de probabilidades se os valores de seu componente forem normalizados, conforme é mostrado na Equação

3.21, onde N representa o número de linhas e M o número de colunas da imagem. Dessa forma a soma de todos os seus elementos será igual a 1.

$$p(i) = \frac{n_i}{NM} \quad (3.21)$$

Uma imagem binária tem apenas dois níveis de cinza em seu histograma. Já uma imagem que representa um objeto escuro junto de um fundo luminoso possui um histograma bimodal, que é bem característico pelos dois picos que se formam no gráfico (DISTANTE *et al.*, 2020). Por fim uma imagem que concentra uma grande quantidade de informação luminosa produz um histograma multimodal, no qual os níveis de cinza são distribuídos em várias quantidade diferentes ao longo do gráfico. Nele se destacam alguns picos que agregam a sua volta valores mais comportados de tonalidade. Na Figura 22 é mostrada a diferença entre um histograma bimodal e outro multimodal.




Figura 22: Diferenças entre histograma bimodal (a) e multimodal (b).

[Fonte: (BHUYAN, 2019)]

De acordo com Rego e Bueno (2010) o contraste de uma imagem pode ser revelado por meio de seu histograma. A Figura 23 mostra as distribuições de intensidade $p(i)$ para imagens com diferentes níveis de contraste. Para uma imagem com níveis baixos de contraste os valores de intensidade se concentram nas pontas do gráfico. Esses valores podem ser equalizados tornando a distribuição mais homogênea ao longo do histograma, de maneira que se busque deixá-los igualmente espaçados. enquanto uma imagem com valores de contraste mais bem balanceados tente a ter uma

resposta semelhante em seu histograma.

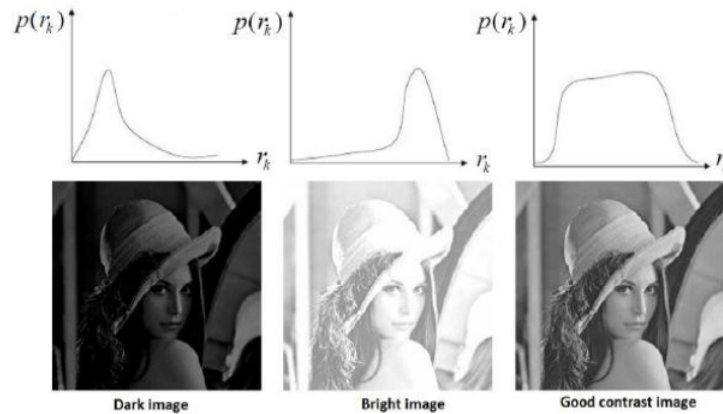


Figura 23: Histogramas e variações de contrastes.[Fonte: (BHUYAN, 2019)]

3.2.3 Filtros de Imagens

Se uma imagem é, para fins práticos, uma matriz bidimensional $M_{n,m}$, então os filtros seriam operações unárias realizadas sobre essa matriz, que nesse caso também pode ser tratada como um sinal S .

Filtros podem ser classificados quanto a linearidade, o método computacional utilizado (estatístico ou determinístico), ou quanto ao seu domínio de ações (topológicos ou de amplitude) (VELHO *et al.*, 2009).

Um filtro $L : S \rightarrow S$ é considerado linear se as operações naturais de adição e multiplicação por um escalar de um sinal forem preservadas, ou seja,

$$L(f + g) = L(f) + L(g) \quad (3.22)$$

$$L(\lambda f) = \lambda L(f), \quad (3.23)$$

onde f e g representam dois sinais distintos e λ um escalar qualquer. A equação 3.22 mostra que o resultado ao aplicar um filtro à duas imagens diferentes adicionadas é o mesmo que aplicar o filtro em cada uma das duas separadamente e em seguida somar os resultados. Já a equação 3.23 trata de preservar a informação da imagem mesmo que esta sofra uma transformação de escala, desde que essa transformação seja constante.

Filtros estatísticos, segundo (NIXON; AGUADO, 2019), utilizam de propriedades es-

tatísticas da imagem para determinar o resultado aplicado a cada pixel. Um exemplo é o filtro de mediana de ordem n (*Median Filter of Order n*), no qual a resposta para cada um dos pixel é calculado conforme a mediana dos 8 pixels vizinhos ordenados de acordo com seus valores de intensidade. Esse filtro ajuda na eliminação de valores de intensidade isolados em meio a sua vizinhança, tornando o sinal mais uniforme e eliminando os ruídos, como mostra a Figura 24. Outro filtro estatístico é o filtro de moda de ordem n (*Mode Filter of Order n*). Se define de forma semelhante ao anterior, mas dessa vez é o valor da moda que é aplicado à resposta do pixel. Tanto o filtro de moda quanto o de mediana são considerados filtros não lineares e atuam de forma local nas imagens.




Figura 24: Redução de ruído aplicando filtro de mediana.

[Fonte: (GONZALEZ; WOODS, 2010)]

Além disso, um filtro pode ser considerado invariante no espaço, em outras palavras, ele vai apresentar o mesmo comportamento em qualquer ponto do domínio espacial do sinal:

$$(Fg)(x - x_0, y - y_0) = F(g(x - x_0, y - y_0)) \quad (3.24)$$

onde g representa a função de imagem, e as coordenadas (x_0, y_0) a posição de um determinado vetor no domínio de g .

O filtro linear mais simples de ser implementado é o filtro retangular (*box filter*), o qual aplica sobre cada pixel o valor da média se seus vizinhos (GONZALEZ; WOODS, 2010). Podendo também ser chamado de filtro de passa-baixa, ele é considerado um filtro de suavização, no qual o resultado é uma imagem com uma redução na quantidade de mudanças abruptas de intensidade (PARIS *et al.*, 2009). Como as bordas dos objetos são consideradas mudanças abruptas, então sua aplicação provoca um resultado indesejável nessas regiões. Além disso é possível trabalhar utilizando uma média aritmética ou ponderada, como é mostrado nas imagens das máscaras da Figura 25.

a

| | | |
|---|---|---|
| 1 | 1 | 1 |
| 1 | 1 | 1 |
| 1 | 1 | 1 |

$\frac{1}{9} \times$

b

| | | |
|---|---|---|
| 1 | 2 | 1 |
| 2 | 4 | 2 |
| 1 | 2 | 1 |

$\frac{1}{16} \times$

Figura 25: Duas máscaras 3x3 aplicadas em uma suavização.

[Fonte: (GONZALEZ; WOODS, 2010)]

A Figura 26 mostra a aplicação dos filtros apresentados na Figura 25. Na imagem da esquerda (a) é aplicada uma média aritmética. Essa é uma aplicação mais eficiente em termos computacionais, e ao final da filtragem toda a imagem seria normalizada por um valor de $1/mn$. Já na imagem da b e c observa-se que é aplicado um peso a cada um dos pixels que forma a máscara, indicando que alguns deles possuem mais importância que outros. O pixel do centro possui um maior peso, enquanto os que estão a sua volta recebem valores de acordo com sua distância. Dessa forma essa técnica ajuda a reduzir o borramento na imagem durante o processo de suavização.

Uma importante aplicação dos filtros de suavização reside em tornar mais fácil a detecção de objetos maiores em uma imagem, como é mostrado na figura 26. Com aplicação dos filtros os objetos menores da imagem se mesclam com o fundo e os objetos maiores se tornam borrões, fazendo que sejam mais fáceis de serem identificados (GONZALEZ; WOODS, 2010).




Figura 26: Resultado do processo de suavização em uma imagem produzida pelo telescópio *Hubble*.

[Fonte: (GONZALEZ; WOODS, 2010)]

Em contraste aos filtros de suavização, existem os filtros de aguçamento, cujo

objetivo consiste em salientar transições de intensidade para o aumento da nitidez em uma imagem. Um exemplo comum de filtro dessa natureza é o filtro laplaciano.

Considerando a Equação 3.25 um operador laplaciano pode ser expresso de maneira discreta da seguinte forma:

$$\nabla^2 f = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2}$$

$$\frac{\partial^2 f}{\partial x^2} = f(x+1, y) + f(x-1, y) - 2f(x, y)$$

$$\frac{\partial^2 f}{\partial y^2} = f(x, y+1) + f(x, y-1) - 2f(x, y)$$

$$\nabla^2 f = f(x+1, y) + f(x-1, y) + f(x, y+1) + f(x, y-1) - 4f(x, y), \quad (3.25)$$

o que pode ser aplicado em uma mascara como a que é mostrada na Figura 3.25. A implementação é feita da mesma forma como visto nos filtros de suavização. Devido a sua natureza diferencial, o laplaciano realça as discontinuidades de intensidades na imagem e atenua as regiões com mudanças mais suaves, resultando em uma imagem com as linhas de borda em tons de cinza sobrepostos em um fundo escuro e uniforme (DISTANTE *et al.*, 2020). Se o resultado da filtragem for somado à imagem original o efeito de aguçamento é preservado e é possível recuperar a informação perdida do fundo.

| | | |
|---|----|---|
| 0 | 1 | 0 |
| 1 | -4 | 1 |
| 0 | 1 | 0 |

Figura 27: Mascara de um filtro laplaciano 3x3.[Fonte: (GONZALEZ; WOODS, 2010)]

3.2.4 Segmentação

Nixon e Aguado (2019) define a segmentação de imagens como uma técnica que consiste em dividir uma imagem ou cena em regiões homogêneas que possam apresentar algum significado. A ideia de homogeneidade aqui pode ser definida em termos de valores de escalas de cinza, cor, textura ou forma. O objetivo final deste processo é atribuir uma “classe” para cada pixel, baseando-se em suas similaridades. De acordo com Lin *et al.* (2016), a segmentação é um procedimento que tem um papel fundamental no estudo de imagens digitais, todavia apresenta algumas dificuldades a serem consideradas antes de sua aplicação:

- Encontrar as características discriminantes na imagem;
- Pode acontecer do objeto a ser segmentado estar de alguma forma mesclado com o fundo;
- No caso de uma segmentação em tempo real existe uma dificuldade a mais provocada por um fundo dinâmico;
- Demanda de algum processamento antes de ser utilizada para obtenção de melhores resultados.

Para imagens monocromáticas existem duas categorias baseadas em valores de intensidade em que se dividem os algoritmos de segmentação: descontinuidade e similaridade (QUEIROZ; GOMES, 2006). Na descontinuidade é aplicada a segmentação baseada em bordas, pois nessa categoria supõe-se que as fronteiras das regiões são suficientemente diferentes entre si e em relação ao fundo da imagem. Para a segunda categoria, similaridade, utiliza-se a abordagem da segmentação baseada em regiões, que consiste em trabalhar com a imagem dividindo-a em espaços suficientemente semelhantes entre si.

A segmentação baseada em bordas consiste na aplicação de técnicas e filtros de detecção de bordas de modo a possibilitar uma análise das descontinuidades nos níveis de cinza em uma imagem (GONZALEZ; WOODS, 2010). As bordas são regiões de interesse caracterizam os contornos dos objetos presentes. A posição dos pixels onde ocorrem variações abruptas nos valores de intensidade são denominados de pontos de borda e caracterizam as transições entre diferentes regiões. Nesse processo são aplicados operadores de gradiente, como laplaciano.

A segmentação de imagens baseada em regiões se fundamenta, como descrito anteriormente, na similaridade dos níveis de cinza da imagem (NIXON; AGUADO, 2019).

Por meio de um conjunto de pontos similares, denominado de semente, cada pixel é agregado à uma região caracterizada por uma determinada propriedade. Esse processo é chamado de agregação de pixels. Os problemas comuns observados nesse tipo de abordagem são a dificuldade de se selecionar um conjunto que seja satisfatoriamente similar e que possibilite o crescimento de regiões, e a seleção da propriedade característica.

Na Figura 28 é mostrado o resultado da aplicação de um processo de segmentação baseado em bordas (imagens a, b, c) e em regiões (imagens d, e, f). Na imagem (a) a intensidade dos pixels é constante na região destacada e no fundo. A imagem seguinte já mostra o resultado de um cálculo de fronteira aplicado na região mais clara baseado na diferença de intensidades nas bordas. Como não há nenhuma descontinuidade dentro e fora da região demarcada, então são atribuídos aos pixels o valor 0 (preto), enquanto que na borda onde a variação é brusca, atribui-se o valor 1 (branco). Para finalizar o procedimento de segmentação atribui-se ao conteúdo dentro da borda demarcada também o valor 1, conforme é visto em (c).

Já na imagem (d) o que se observa não é uma região comportada como no caso da (a), mas sim um padrão texturizado formado pelos diferentes valores de intensidade atribuídos aos pixels. Isso dificulta a detecção da borda pois irão existir vários pontos diferentes onde observa-se a mudança abrupta de intensidade, como observado em (e). Para contornar esse problema, aproveita-se do comportamento constante do fundo da imagem e utilizando-se do desvio padrão dos valores dos pixels é possível fazer a distinção entre a região texturizada e a região sólida. A imagem é então dividida em sub-regiões e onde o desvio padrão apresentou um resultado positivo, então foi atribuído o valor 1 (branco) como é mostrado em (f).




Figura 28: Segmentação de uma imagem utilização a abordagem baseada em bordas (a, b, c) e em regiões (d, e, f).

[Fonte: (GONZALEZ; WOODS, 2010)]

Algoritmos de segmentação baseados no crescimento de regiões tornam difícil a obtenção de bons resultados pois concentra a informação de forma local, mesclando regiões e provocando um processo de segmentação. Além disso é uma técnica cara em termos computacionais e demanda de um consumo muito alto de memória (SZELISKI, 2010). Em resposta a esses problemas surge a segmentação por divisão e fusão, o qual consiste em dividir uma imagem sucessivamente em sub-regiões até que seja atingido um critério de parada (divisão) e, logo em seguida, agrupar essas regiões de acordo com definições de homogeneidade.

Outra abordagem que envolve a segmentação por regiões é o algoritmo de divisores de água ou *watersheds*, que se baseia nos conceitos de bacias hidrográficas e topografia, tanto que nessa técnica a imagem é modelada como uma superfície topográfica, como se fosse na verdade composta por montanhas ou vales e a altitude dos pontos correspondessem ao gradiente dos valores de intensidade dos pixels (GONZALEZ; WOODS, 2010).

Inicialmente, simula-se uma inundação nos mínimos locais, o que provoca a formação de poças e bacias. Quando a água de duas bacias estão na iminência de se encontrarem forma-se uma linha de contenção, gerando os contornos dos objetos da imagem. O resultado então é a formação de uma espécie de uma bacia hidrográfica que formam das regiões segmentadas. Dessa forma, os pontos que compõem a imagem podem ser divididos em três categorias:

- pontos que pertencem à um mínimo local;
- pontos que pertencem à um mínimo de *watershead*, no qual uma gota cai em direção à um mínimo local;
- pontos que pertencem à linhas de *watershead*, no qual uma gota pode cair em direção a qualquer lado.

A Figura 29 mostra um processo de inundação de uma imagem. Em (a) é mostrada a imagem original e em (b) a sua forma topográfica. Em (c, d, e) a imagem passa por uma série de inundações, até que em (f, g) são formadas as barragens e consequentemente os contornos. Por fim em (h) a imagem é mostrada com as linhas de segmentação.




Figura 29: Processo de aplicação da segmentação por *watersheds*.

[Fonte: (GONZALEZ; WOODS, 2010)]

Além das técnicas de segmentação por bordas e regiões ainda existem outras abordagens que valem a pena serem exploradas. A segmentação por limiarização (*thresholding*) é um dos modelos mais simples. De forma geral, ela resulta sempre em uma imagem binária, ou seja, se uma imagem de entrada $f(x, y)$ for aplicada a um limiar T , então imagem de saída $g(x, y)$ é expressa na Equação 3.26:

$$g(x, y) = \begin{cases} 1, & f(x, y) \geq T \\ 0, & f(x, y) < T \end{cases} \quad (3.26)$$

A limiarização global, como mostra Bhuyan (2019), considera um limiar único para toda a imagem e é aplicado quando a variação de intensidade entre o fundo e o objeto

é grande. Esse limiar global pode ser calculado de diversas formas:

- A abordagem baseada em histogramas define o limiar no vale formado no histograma de uma imagem, ou seja, só é aplicado quando a imagem possui regiões homogêneas bem definidas;
- O método de *Otsu* tenta buscar ao longo de um conjunto de valores de pixels um limiar ótimo que minimiza as variâncias intraclasses de uma imagem segmentada;
- A limiarização iterativa aplica um processo de divisão da imagem em *clusters*.

Na limiarização local o valor do limiar depende da vizinhança dos pixels em termos de coordenadas espaciais. A imagem é primeiramente particionada e então o limiar é determinado localmente utilizando relações espaciais e características como a média e a variância dos pixels de uma da região. Dessa forma, múltiplos valores de limiar são definidos para a imagem e a segmentação procede de forma mais efetiva. Quanto menor forem as sub-regiões, maiores as chances de serem mais uniformes, todavia, essa técnica demanda de um grande consumo computacional.

3.2.5 Processamento Digital de Imagens de Rochas Reservatórios

A principais etapas para a realização do processamento de imagens de amostras de meios porosos provenientes de rochas reservatórios são mostradas na Figura 1. O uso desse método permite a análise de propriedades físicas das rochas em um grande número de amostras com um baixo custo, além de possibilitar também a utilização de amostras de calha ou de testemunhos danificados.

3.2.5.1 Etapa 1 - Obtenção e Preparação das Amostras

Essas primeira etapa envolve os processo de preparação das amostras para que estas estejam apropriadas para a aquisição das imagens. As amostras são obtidas por meio de critérios estatísticos, como o da representatividade.

Essas amostras são então submetidas à um processo de limpeza para a remoção de hidrocarbonetos residuais. Em seguida são impregnadas em uma resina especial, de cor azul, que irá preencher os poros e fraturas, tornando-os mais visíveis quando observadas no microscópio.

Corta-se uma fatia de rocha de aproximadamente 0,5 cm de espessura chamada de esquírola. Essa esquírola tem um de seus lados polido e colado em uma lamina de vidro. Em uma politriz o conjunto esquírola e vidro são submetidas a um processo abrasivo, de modo a se obter uma aparência semelhante ao que se vê na Figura 30(e). Após esse processo, a lamina final deve ter uma espessura de aproximadamente 0,03 mm. Ela ainda pode ser sujeita a um ultimo tratamento de polimento, como mostrado na Figura 30(g) ou simplesmente colada à uma segunda lamina de vidro (Figura 30(f)). Dessa forma a amostra já está pronto para terem suas imagens obtidas.




Figura 30: Preparação de uma lamina de uma amostra de um meio poroso.
[Fonte: (REGO; BUENO, 2010)]

3.2.5.2 Etapa 2 - Aquisição de Imagens

A aquisição de imagens pode ser feita por meio de câmeras, scanners ou sensores dedicados à esse propósito. Na maioria dos casos opta-se pela utilização de uma câmera de vídeo acoplada a um microscópio como sensor de aquisição. Um conversor ADC transforma o sinal analógico e em discreto e transmite essa informação para um computador ou armazena em algum dispositivo de memória.

3.2.5.3 Etapa 3 - Pré-Processamento

Como definido anteriormente, o pré-processamento envolve uma série de procedimentos para a eliminação de irregularidades das imagens, tornando-as mais apropriadas para determinadas aplicações. Nesse etapa são aplicados filtros espaciais ou frequenciais, organização dos dados, conversão de formatos e eliminação de bordas.

3.2.5.4 Etapa 4 - Segmentação e Binarização

Como também foi mostrado em seções anteriores, a segmentação de imagens trata-se em dividir regiões ou objetos de interesse. É um processo crítico quando se trabalha com imagens, ainda mais quando estas não são triviais.

Já a binarização é caracterizada pela separação de um ou mais objetos do fundo por meio da conversão de uma imagem colorida ou em escala de cinza em uma imagem binária, com pixels assumindo apenas os valores de 0 ou 1, por exemplo.

3.2.5.5 Etapa 5 - Caracterização

É nessa etapa que são extraídas informações de interesse, descrevesse e classifica-se os objetos e regiões segmentados nas etapas anteriores, e obtêm-se informações quantitativas sobre as propriedades físicas da rocha, como porosidade, permeabilidade, distribuição de tamanho dos poros e curvas de auto-correlação e conectividade.

3.2.5.6 Etapa 6 - Reconhecimento e Interpretação

Trata-se de atribuir significado aos objetos encontrados nas imagens. Envolve o reconhecimento de padrões, nesse caso de rochas reservatórios, a reconstrução 3D e a simulação de processos.

3.3 Inteligência Artificial

A pesquisa em inteligência artificial envolve a construção de algoritmos que sejam capazes de simular o processo cognitivo humano para a resolução de problemas (GOODFELLOW *et al.*, 2016). É uma área demasiada extensa e envolve uma série de técnicas, e dentre elas destacam-se as Redes Neurais Artificiais, os Algoritmos Genéticos e a Lógica Fuzzy. Nos últimos anos as IAs tem se tornado muito popular devido a disponibilidades de unidades de processamento gráfico (GPUs) com melhor desempenho e mais acessíveis, e a grande quantidade de dados como imagens, textos, mapas, vídeos que vêm sendo acumulados na internet.

3.3.1 Modelos de Aprendizagem de Máquina (*Machine Learning*)

Um algoritmo de *Machine Learning* é um algoritmo capaz de aprender a partir dos dados e poder realizar previsões acerca de coisas do mundo real. Por aprendizagem aqui, Mitchell (1997) define que o processo no qual um computador aprende a partir de uma experiência E acerca de uma classe de tarefas T com uma medida de desempenho P , de modo que o resultado seja realizar as tarefas em T de modo que a experiência em E seja melhorada.

Dentre as principais tarefas T que podem ser atribuídas à algoritmos de aprendizagem de máquina, Goodfellow *et al.* (2016) lista:

- **Classificação:** Nesse tipo de tarefa o computador deve atribuir para as informações de entrada uma determinada classe k de acordo com suas características e atributos. Essas classes podem ser atribuídas de forma determinística ou podem ser representadas na forma de distribuições de probabilidades. O exemplo mais comum da aplicação dessa tarefa é a visão computacional para o reconhecimento de objetos.
- **Classificação com Entradas Faltantes:** Nesse caso, o algoritmo de classificação passa a ser treinado em um conjunto de funções para atribuir a classe a uma entrada, e não apenas uma função, como no caso mais simples. Essa tarefa muitas vezes é implementada fazendo o algoritmo aprender o conjunto de funções por meio de distribuição probabilística sobre as variáveis mais importantes e resolvendo a classificação marginalizando as variáveis faltantes.
- **Regressão:** O resultado que se busca em um tarefa de regressão é realização de uma previsão numérica sobre um determinado conjunto de dados. É semelhante à classificação, porém apresenta a saída em um formato diferente. A regressão é largamente aplicada em sistemas para previsão do comportamento em mercados financeiros.
- **Transcrição:** Por meio da observação de algum tipo de dado não estruturado, o computador tem a tarefa de transcrever a informação na forma textual discreta. É muito utilizada no desenvolvimento de sistemas de escrita e reconhecimento de voz.
- **Deteção de Anomalias:** Aqui é atribuído ao computador a tarefa de analisar uma série de informações e apontar qualquer comportamento não usual ou atí-

pico. Um exemplo de aplicação desse tipo de tarefa é a detecção de fraudes em cartões de crédito por meio da análise do padrão de compra de um cliente.

A medida de desempenho P deve ser uma forma quantitativa se o algoritmo de fato está aprendendo, ou seja, o quão bem ele está realizando a tarefa a qual lhe foi atribuída (MURPHY, 2012). Tarefas como a classificação e transcrição normalmente utilizam uma métrica de acurácia, que nada mais é que a fração de entradas para as quais o algoritmo produz uma saída correta. Também é comum analisar essas tarefas por meio da taxa de erro, que representa as entradas para as quais a saída é incorreta.

Sistemas de aprendizagem que produzem saídas contínuas costumam medir a qualidade utilizando o erro médio quadrático (JAMES *et al.*, 2013), cuja formula é mostrada na Equação 3.27, onde $\hat{f}(x_i)$ é a previsão feita pelo algoritmo a partir de uma observação do i -ésimo elemento de um conjunto de dados.

$$MSE = \frac{1}{n} \sum_{i=1}^n \left(y_i - \hat{f}(x_i) \right)^2 \quad (3.27)$$

Para a realização dessa medida deve ser utilizado um conjunto de teste que corresponde a dados do mundo real que não foram utilizadas no processo de aprendizagem do modelo. Isso evita que o sistema fique de certa forma viciado com o aquilo que foi utilizado no conjunto de treino (SHUKLA; FRICKLAS, 2018).

Os modelos de *machine learning* podem ser classificados de acordo com a experiência que lhe são permitidas durante o treinamento em supervisionados e não-supervisionados.

Algoritmos de aprendizagem supervisionada são submetidos a um conjunto de dados, ou *dataset*, no qual a cada componente é atribuído um valor alvo ou uma *label*. Por meio da observação de exemplos ao longo de um vetor aleatório x e de seu valor correspondente em y , o algoritmo realiza um previsão de y dado x estimando $p(y|x)$ (BISHOP, 2006).

Algoritmos de aprendizagem não supervisionados experienciam um *dataset* que contém um série de atributos e então aprende utilizando propriedades acerca da estrutura desse conjunto. Ele tenta aprender a distribuição de probabilidade $p(x)$ observando de maneira implícita o conteúdo de um vetor aleatório x (JAMES *et al.*, 2013).

Além disso existe uma categoria de algoritmos de aprendizagem de máquina que não utilizam apenas um *dataset* fixo, mas sim se adaptam de acordo com o ambiente. Esse é o caso dos algoritmos de aprendizagem reforçada, os quais utilizam de um

sistema de realimentação entre suas saídas e entradas (MNIH *et al.*, 2013).

3.3.2 Algoritmos de Árvores de Decisão e Florestas Aleatórias

Árvores de decisão são algoritmos que podem ser aplicados tanto em problemas de regressão quanto em problemas de classificação. Conforme é mostrado na Figura 31, cada nó da árvore é associado com uma informação de entrada, cada uma dessas regiões são quebradas em sub-regiões e se associam com outros nós. Em outras palavras, uma árvore de decisão divide um problema complexo em subproblemas cada vez mais simples. No caso de problemas de classificação, cada “folha” da árvore estaria associada à uma classe, cada nó representa uma decisão para um determinado atributo e cada ramo um possível valor para estes atributos. O percurso tomado por cada atributo desde sua raiz até a uma determinada folha é chamado de regra de classificação.




Figura 31: Representação de uma árvore de decisão.[Fonte: (SILVA, 2005)]

A taxa de erro de classificação E em árvores de decisão são simplesmente a fração de resultados de treino que não pertencem a classe mais comum, como é mostrado na Equação 3.28, onde \hat{p}_{mk} representa a quantidade de observações na m -ésima região para a k -ésima classe. Contudo é preferível utilizar o índice *Gini*, da Equação 3.29, para a medição da impureza em cada nó. Quando esse índice é igual a 0, diz que o nó é considerado puro, se for diferente disso, é portando impuro.

$$E = 1 - \max_k (\hat{p}_{mk}) \quad (3.28)$$

$$G = \sum_{k=1}^K \hat{p}_{mk} (1 - \hat{p}_{mk}) \quad (3.29)$$

A principal vantagem desse método é a sua facilidade de compreensão e interpretação, já que ele pode ser relacionado com forma na qual as pessoas tomam suas decisões. Todavia, esses algoritmos não produzem a mesma acurácia em predições como outros métodos mais comum de regressão. Com tudo essa diferença pode ser minimizada aplicado outros métodos como florestas aleatórias.

Florestas aleatórias são formadas por combinações de árvores de decisão de forma randômica, de forma a se buscar a melhor característica de cada sub conjunto, gerando grande diversidade para o modelo.

Contudo sua maior limitação acaba sendo sua performance quando se trata de um modelo com uma grande quantidade de árvores. Florestas aleatórias são bem rápidas de treinar mas podem ser tornar muito lentas e ineficientes na hora de se fazer predições.

3.3.3 Redes Neurais Artificiais

A redes neurais artificiais são definidas como modelos não-lineares com capacidade de imitar o comportamento do cérebro humano e sua estrutura de neurônios (HAYKIN, 2007). Dessa forma, idealmente, uma RNA é capaz de realizar as operações de aprendizado, associação, generalização e abstração. Essas redes são compostas por uma série de elementos chamados de neurônios artificiais, altamente interligados e que executam operações simples e passando a informação para os elemento seguintes da estrutura. Um neurônio em geral possui várias entradas, mas apenas uma saída, como é mostrado na Figura 32. Cada entrada é representado por u_i e são ponderadas por um peso w_i com i variando de 1 a n . A combinação dessas entrada é feita pela soma Φ , a qual ainda é somado um valor de polarização ou *bias* θ , como é mostrado na Equação 32.

$$u = \Phi + \theta = \sum_{n=1}^n u_n w_n + \theta \quad (3.30)$$




Figura 32: Representação de um neurônio artificial.

3.3.3.1 Funções de Ativação

O resultado da operação mostrada na Equação 3.30 é aplicado como insumo para uma função de ativação η , assim a saída y do neurônio é mostrado na Equação 3.31. Essa função de ativação que é responsável por introduzir a não-linearidade ao modelo do neurônio, e pode aparecer na forma de uma função tangente hiperbólica, degrau, sigmoide, entre outras (CHOLLET *et al.*, 2018).

$$y = \eta(u) = \eta(\Phi + \theta) = \eta\left(\sum_{1}^n u_n w_n + \theta\right) \quad (3.31)$$

A função de ativação degrau é descrita na Equação 3.32 e mostrada na Figura 33. Ela atua de forma a binarizar a saída dos neurônios, como um chave. De forma semelhante existe a função degrau bipolar, que é mostrada na Equação 3.33.

$$\eta(u) = \begin{cases} 1 & u \geq 0 \\ 0 & u < 0 \end{cases} \quad (3.32)$$

$$\eta(u) = \begin{cases} 1 & u \geq 0 \\ -1 & u < 0 \end{cases} \quad (3.33)$$




Figura 33: Função degrau.

A função de rampa, descrita na Equação 3.34 e mostrada na Figura 34, retorna valores $\eta(u) = u$ dentro de um determinado intervalo $\{-a, a\}$.

$$\eta(u) = \begin{cases} 1 & u \geq a \\ u & -a < u < a \\ 0 & u \leq -a \end{cases} \quad (3.34)$$




Figura 34: Função rampa.

Na função sigmoid a saída assume valores reais entre 0 e 1, e sua inclinação é definida por um parâmetro β , conforme é descrito na Equação 3.35 e mostrado na Figura 35. A função tangente hiperbólica produz um gráfico muito semelhante, mas retornando valores entre -1 e 1. Ela é mostrada na Equação 3.35 e na Figura 36

$$\eta(u) = \frac{1}{1 + e^{(-\beta u)}} \quad (3.35)$$




Figura 35: Função sigmoid.

$$g(u) = \tanh(u) = \frac{1 - e^{-u}}{1 + e^{-u}} \quad (3.36)$$




Figura 36: Função tangente hiperbólico.

Existem ainda funções de ativação que são extremamente comuns em redes neurais profundas e vêm trazendo excelentes resultados nos últimos anos: *ReLU* e *Softmax*. A função de ativação *ReLU* mostrada na Equação 3.37 e na Figura 37 tem como principal vantagem o fato de que ela não ativa imediatamente todos os neurônios, pois os valores negativos de u acabam, sendo igualados a 0 (NIELSEN, 2015).

$$\eta(u) = \begin{cases} u & u \geq 0 \\ 0 & u < 0 \end{cases} \quad (3.37)$$




Figura 37: Função ReLU. [Fonte: (CHOLLET *et al.*, 2018)]

A função *softmax* é semelhante a uma função *sigmoid* e é bastante utilizada para a classificação de problemas com mais de duas classes. Ela converte os valores das camadas de saída em uma função de probabilidade. A Equação 3.38 mostra sua estrutura, onde \vec{u} representa todo um vetor de entrada com k elementos u_i . Aqui k também é o número de classes aplicadas ao algoritmo.

$$\eta(\vec{u})_i = \frac{e^{u_i}}{\sum_{j=1}^k e^{u_j}} \quad (3.38)$$

3.3.3.2 Redes Neurais Diretas (*FeedForwarding*)

Redes neurais são denominadas de diretas ou *feedforwarding* quando não possuem ciclos em sua estrutura, ou seja, ela sempre é alimentada em uma única direção (NIELSEN, 2015). São frequentemente representadas em camadas de neurônios, os quais sempre são alimentados pelas saídas das camadas anteriores. Os dados são introduzidos em uma camada de entrada e o produto final da rede é provido pela camada de saída. Qualquer camada entre essas duas é denominada de profunda

ou *hidden layers*. A Figura 38 mostra uma RNA direta com 2 camadas profundas, 3 entradas e 2 saídas.




Figura 38: Rede neural artificial direta com 2 camadas profundas.

O comportamento dessa rede neural pode ser expresso na forma da Equação 3.39. Nessa notação w_{jk}^l denota o peso da conexão entre o k -ésimo neurônio da $(l-1)$ -ésima camada com o j -ésimo neurônio da l -ésima camada. O diagrama da Figura 39 ajuda a entender melhor essa representação. Além disso θ_j^l e y_j^l representam, respectivamente, o *bias* e a ativação do j -ésimo neurônio na l -ésima camada. A ativação do k -ésimo neurônio da camada anterior $(l-1)$ é usada como insumo para a ativação do neurônio atual e é representada como y_k^{l-1} . A Equação 3.40 mostra a forma vetorizada da ativação.

$$y_j^l = \eta \left(\sum_k w_{jk}^l y_k^{l-1} + \theta_j^l \right) \quad (3.39)$$

$$y^l = \eta (w^l y^{l-1} + \theta^l) \quad (3.40)$$




Figura 39: Diagrama sobre a notação matemática de um peso RNA.

[Fonte: (NIELSEN, 2015)]

Existem diversos métodos utilizados para desenvolver o aprendizado desse tipo de rede neural, mas o mais utilizada é o da retro-propagação de erros ou *backpropagation*. O objetivo desse algoritmo é calcular o quanto é preciso modificar os valores dos pesos e *biases* da rede após cada saída que a rede neural retorna (GOODFELLOW *et al.*, 2016). Para isso define-se uma função de custo C que mede o quão diferente da saída da rede y^L está relação ao valor verdadeiro atribuído ao dado imputado na camada de entrada $y(x)$. O algoritmo da retro-propagação calcula então as derivadas parciais $\partial C / \partial \theta$ e $\partial C / \partial w$ para essa função em relação aos *biases* e aos pesos. Um exemplo de função de custo é a função de custo quadrático, que é expressada na Equação 3.41, na qual n é o número total de exemplos de treino no *dataset*.

$$C = \frac{1}{2n} \sum_x \| y(x) - y^L(x) \|^2 \quad (3.41)$$

Normalmente quando uma rede é treinada não se utiliza o conjunto de dados por inteiro de uma vez. É comum que antes ele seja dividido em conjuntos menores de pares entrada e *label*, selecionados aleatoriamente, denominados de *mini-batches*. Essa abordagem não apenas é mais viável computacionalmente, pois evita de carregar *datasets* muito grandes na memória de uma só vez, como também ajuda no processo de aprendizagem da rede (JAMES *et al.*, 2013). A velocidade que a rede aprende também é ditada pela taxa de aprendizagem μ .

Segundo Nielsen (2015) o procedimento para se trabalhar com redes neurais diretas pode ser descrito sob o seguinte algoritmo:

1. Entra-se com um conjunto de dados na camada de entrada da rede neural;

2. Para cada exemplo de treino é feito o seguinte procedimento:

- (a) computar as saídas dos neurônios até a última camada utilizando a Equação 3.39;
- (b) calcular o erro $\delta^{x,L}$ utilizando a Equação 3.42;
- (c) Retropropagar o erro pela rede utilizando a Equação 3.43 para calcular o erro em cada camada $l = L - 1, L - 2, \dots$;

3. Atualizar os pesos e *biases* da rede por meio das Equações 3.44 e 3.45, onde μ representa a taxa de aprendizagem da rede e m o tamanho do *mini-batches*.

$$\delta^{x,L} = \nabla_a C_x \odot \eta'(w^L y^{L-1} + \theta^L) \quad (3.42)$$

$$\delta^{x,l} = \left((w^{l+1})^T \delta^{x,l+1} \right) \odot \eta'(w^l y^{l-1} + \theta^l) \quad (3.43)$$

$$w^l \rightarrow w^l - \frac{\mu}{m} \sum_x \delta^{x,l} (a^{x,l-1})^T \quad (3.44)$$

$$b^l \rightarrow b^l - \frac{\mu}{m} \sum_x \delta^{x,l} \quad (3.45)$$

Percebeu-se no entanto que utilizar a função mostrada na Equação 3.41 pode tornar o aprendizado muito lento. Por isso uma função de custo substituta que ode ser adotada é *Cross-Entropy*, que é expressa na Equação 3.46, onde a representa a saída da função de ativação, n é o número total de elementos do conjunto de treino, x o valor de entrada e y é a saída desejada. As derivadas $\partial C / \partial \theta$ e $\partial C / \partial w$ são mostradas nas Equações 3.47 e 3.48. Observa-se que o gradiente da função de ativação não é considerado, o que ajuda a resolver o problema do *vanishing gradient*.

$$C = -\frac{1}{n} \sum_x [y \ln a + (1 - y) \ln(1 - a)] \quad (3.46)$$

$$\frac{\partial C}{\partial \theta} = \frac{1}{n} \sum_x (a - y) \quad (3.47)$$

$$\frac{\partial C}{\partial w} = \frac{1}{n} \sum_x x(a - y) \quad (3.48)$$

Nas Figuras 40 e 41 é feita uma comparação usando um função de custo quadrá-

tico e um função *cross-entropy* para um neurônio fictício com os valores de peso e *biases* configurados inicialmente iguais a 2, o *input* igual a 1, a saída atual em 0,98 e a saída desejada em 0. O que se observa é que no segundo caso o valor do custo atinge um número mais baixo em uma menor quantidade de épocas do que o primeiro. Isso mostra, portanto, que ele está aprendendo mais rápido.




Figura 40: Relação custo x número de épocas para uma função de custo quadrática.
[Fonte: (NIELSEN, 2015)]




Figura 41: Relação custo x número de épocas para uma função de custo *cross-entropy*.

[Fonte: (NIELSEN, 2015)]

4 Metodologia

Neste capítulo apresenta-se a metodologia científica a ser utilizada no desenvolvimento deste trabalho. Inclui-se informações sobre motivação, área da pesquisa, instrumentos (materiais, equipamentos, softwares) utilizados, limitações do tema, pressupostos e hipóteses simplificadoras.

4.1 Motivação Para o Tema

Conforme mostrado nos trabalhos de Andrä *et al.* (2013), Rubo *et al.* (2019) a escolha de um algoritmo de segmentação, a escolha dos filtros e principalmente o *threshold* em imagens em escala de cinza são os pontos chave para uma boa binarização de uma imagem de uma amostra de rocha reservatório, tanto que uma combinação infeliz desses parâmetros pode trazer ambiguidades para o processo de interpretação.

O trabalho de Rego e Bueno (2010) mostrou que a utilização de redes neurais artificiais podem trazer bons resultados para o processo de binarização de imagens, principalmente quando comparado com métodos tradicionais. Todavia, vale resultar que observou-se ainda uma dificuldade em processar amostras nas quais eram encontradas grãos muito claros ou escuros. Além disso no trabalho foram utilizadas redes neurais tradicionais *feedforward*, algoritmo da retro-propagação, função de custo quadrático e função de ativação *sigmoid*. Com o avanço dos métodos de IA essas escolhas se tornaram obsoleta com o passar dos anos, e trabalhos como os de Sudakov *et al.* (2019), Rubo *et al.* (2019), Linden *et al.* (2016), Saporetti *et al.* (2018) vem apresentando bons resultados sobre o processamento do que pode se chamar de Rocha Digital utilizando, por exemplo, redes neurais convolucionais combinadas com algoritmos de machine learning mais simples.

Esses fatores colaboram portanto para a motivação desse trabalho, que visa utilizar a experiencia obtida em trabalhos anteriores para o avanço do conhecimento da

área da pesquisa em Inteligência Artificial aplicada à engenharia de reservatórios de petróleo.

4.2 Classificação da Pesquisa

- Área de estudo:
 - Processamento digital de imagens de rocha reservatório utilizando inteligência artificial.
- Subordinação do tema a áreas do conhecimento científico:
 - Ligado à engenharia de reservatório de petróleo, ao estudo e caracterização do meio poroso, a determinação de propriedades petrofísicas utilizando métodos da área de processamento e análise de imagens digitais e da área de inteligência artificial.
- Problema específico:
 - Desenvolvimento de modelos de inteligência artificial (IA) aplicados a binarização de imagens de rocha reservatório.
- Tipo de pesquisa:
 - A pesquisa em desenvolvimento apresenta caráter misto entre a modelagem numérico-computacional e desenvolvimento experimental.

4.3 Hipóteses

Neste trabalho serão admitidas as seguintes hipóteses simplificadoras:

1. O arcabouço, matriz e cimento dos arenitos, e o aloquímico, a micrita e o esparito dos carbonatos serão tratados como fase granular, e os poros como fase rochosa. Dessa forma portanto, está desconsiderada a classificação dos minerais;
2. Serão utilizados valores de porosidade efetiva, já que a resina preenche apenas os poros interconectados.

4.4 Materiais e Pressupostos

Para a realização desse trabalho será feita inicialmente um estudo acerca da geologia das rochas reservatórios, as suas propriedades petrofísicas ao se cursar as disciplinas de Petrofísica, Escoamento em Meios Porosos e Fraturados e Introdução a Engenharia do Petróleo. Em seguida serão cursadas disciplinas de Processamento Digital de Imagens e Processamento Paralelo e Concorrente, para dar suporte ao desenvolvimento de técnicas computacionais e para a realização de uma revisão bibliográfica profunda sobre a área.

Em seguida serão desenvolvidos os modelos para serem aplicados nas amostras. O trabalho será focado no desenvolvimento e implementação de uma Rede Neural Artificial Profunda para a binarização das imagens. Todos os códigos desenvolvidos serão testados e incorporados a biblioteca LIB_LDSC em C++.

Estas serão providas pelo acervo digital do Prof. DSc. André Duarte Bueno e do banco de dados disponibilizado pelo CENPES-PETROBRÁS. Os resultados obtidos serão comparados com o trabalho de Rego e Bueno (2010) e outros da literatura.

5 *Cronograma*

Neste capítulo serão apresentadas às próximas etapas que relacionadas ao desenvolvimento deste trabalho, bem como um cronograma detalhado do que será realizado nos próximos meses.

5.1 Etapas Para o Desenvolvimento do Trabalho

Serão seguidas as seguintes etapas para o desenvolvimento deste trabalho:

1. **Disciplinas**

Participação nas disciplinas Geologia do Petróleo, Princípios de Geofísica Aplicada, Introdução a Engenharia do Petróleo, Métodos de Física Matemática, Desenvolvimento de Software Orientado à Objeto em C++, Processamento Digital de Imagens, Processamento Paralelo, Petrofísica e Escoamento em Meios Porosos.

2. **Revisão Bibliográfica**

Realização de pesquisa bibliográfica sobre geologia dos reservatórios de petróleo e suas propriedades petrofísicas, fundamentos de processamento de imagens e métodos e algoritmos de inteligência artificial.

3. **Estudo dos métodos a serem utilizados**

Estudo sobre o desenvolvimento e implementação de Redes Neurais Artificiais Profundas.

4. **Revisão e desenvolvimento de algoritmos**

Desenvolvimento dos algoritmos de IA em C++.

5. **Análise de resultados**

Treinar os modelos utilizando as imagens das amostras, comparar os resultados com aqueles obtidos por trabalhos anteriores e testar os códigos.

6. Desenvolvimento de artigos**7. Redação da dissertação****8. Defesa**

A defesa da tese está prevista para março de 2022.

5.2 Cronograma de Eventos

A Tabela 2 apresenta o cronograma de eventos para o desenvolvimento deste trabalho.

Tabela 2: Cronograma de eventos para o desenvolvimento deste trabalho.

| ANO ⇒ | | 2020 | | 2021 | | 2022 |
|-----------------------------|------------|------|----|------|----|------|
| EVENTOS ↓ | SEMESTRE ⇒ | 1º | 2º | 1º | 2º | 1º |
| Disciplinas | | X | X | X | | |
| Revisão Bibliográfica | | | X | X | | |
| Estudo dos Métodos | | | X | X | X | |
| Revisão de Algoritmos | | | | X | X | |
| Desenvolvimento do Programa | | | | X | X | |
| Análise de Resultados | | | | | X | |
| Desenvolvimento de Artigo | | | | | X | |
| Redação da Tese | | | | X | X | |
| Defesa | | | | | | X |

5.3 Orçamentos

Se pertinente, incluir aqui Tabela Orçamentária.

É possível que tenhamos gastos com despesas de deslocamento para a capital do estado, Rio de Janeiro, em visita ao CENPES, para busca de imagens a serem processadas.

Referências

- AHMED, T. *Reservoir engineering handbook*. [S.l.]: Gulf professional publishing, 2018.
- ALQAHTANI, N.; ARMSTRONG, R. T.; MOSTAGHIMI, P. *et al.* Deep learning convolutional neural networks to predict porous media properties. In: SOCIETY OF PETROLEUM ENGINEERS. *SPE Asia Pacific oil and gas conference and exhibition*. [S.l.], 2018.
- AMYX, J.; BASS, D.; WHITING, R. L. *et al.* *Petroleum reservoir engineering physical properties*. [S.l.: s.n.], 1960.
- ANDRÄ, H.; COMBARET, N.; DVORKIN, J.; GLATT, E.; HAN, J.; KABEL, M.; KEEHM, Y.; KRZIKALLA, F.; LEE, M.; MADONNA, C. *et al.* Digital rock physics benchmarksâpart i: Imaging and segmentation. *Computers & Geosciences*, Elsevier, v. 50, p. 25–32, 2013.
- ARCHER, J. S.; WALL, C. G. *Petroleum engineering: principles and practice*. [S.l.]: Springer Science & Business Media, 2012.
- BHUYAN, M. K. *Computer vision and image processing: Fundamentals and applications*. [S.l.]: CRC Press, 2019.
- BISHOP, C. M. *Pattern recognition and machine learning*. [S.l.]: springer, 2006.
- CHOLLET, F. *et al.* *Deep learning with Python*. [S.l.]: Manning New York, 2018. v. 361.
- COSSE, R. *Basics of Reservoir Engineering (Institut Francais Du Petrole Publications)*. [S.l.]: Technip, 1993.
- DAKE, L. P. *Fundamentals of reservoir engineering*. [S.l.]: Elsevier, 1983.
- DISTANTE, A.; DISTANTE, C.; DISTANTE; WHEELER. *Handbook of Image Processing and Computer Vision*. [S.l.]: Springer, 2020.
- EZEKWE, N. *Petroleum reservoir engineering practice*. [S.l.]: Pearson Education, 2010.
- GONZALEZ, R.; WOODS, R. *Processamento Digital de Imagens. Book*. [S.l.]: SÃO Paulo: Pearson Pretience Hall, 2010.
- GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A.; BENGIO, Y. *Deep learning*. [S.l.]: MIT press Cambridge, 2016. v. 1.
- HAYKIN, S. *Redes neurais: princípios e prática*. [S.l.]: Bookman Editora, 2007.

- HÉBERT, V.; PORCHER, T.; PLANES, V.; LÉGER, M.; ALPEROVICH, A.; GOLDLUECKE, B.; RODRIGUEZ, O.; YOUSSEF, S. Digital core repository coupled with machine learning as a tool to classify and assess petrophysical rock properties. In: EDP SCIENCES. *E3S Web of Conferences*. [S.l.], 2020. v. 146, p. 01003.
- HU, Y.; HUBER, A.; ANUMULA, J.; LIU, S.-C. Overcoming the vanishing gradient problem in plain recurrent networks. *arXiv preprint arXiv:1801.06105*, 2018.
- IASSONOV, P.; GEBRENEGUS, T.; TULLER, M. Segmentation of x-ray computed tomography images of porous materials: A crucial step for characterization and quantitative analysis of pore structures. *Water Resources Research*, v. 45, n. 9, 2009. Disponível em: <<https://agupubs.onlinelibrary.wiley.com/doi/abs/10.1029/2009WR008087>>.
- JAMES, G.; WITTEN, D.; HASTIE, T.; TIBSHIRANI, R. *An introduction to statistical learning*. [S.l.]: Springer, 2013. v. 112.
- JR, W. D. M. *Properties of petroleum fluids*. [S.l.]: PennWell Corporation, 2017.
- KINGMA, D. P.; BA, J. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.
- LAKE, L. W. *et al. Petroleum engineering handbook*. [S.l.]: Society of Petroleum Engineers, 2006.
- LEU, L.; BERG, S.; ENZMANN, F.; ARMSTRONG, R. T.; KERSTEN, M. Fast x-ray micro-tomography of multiphase flow in berea sandstone: A sensitivity study on image processing. *Transport in Porous Media*, Springer, v. 105, n. 2, p. 451–469, 2014.
- LIN, G.; SHEN, C.; HENGEL, A. V. D.; REID, I. Efficient piecewise training of deep structured models for semantic segmentation. In: *Proceedings of the IEEE conference on computer vision and pattern recognition*. [S.l.: s.n.], 2016. p. 3194–3203.
- LIN, W.; LI, X.; YANG, Z.; LIN, L.; XIONG, S.; WANG, Z.; WANG, X.; XIAO, Q. A new improved threshold segmentation method for scanning images of reservoir rocks considering pore fractal characteristics. *Fractals*, World Scientific, v. 26, n. 02, p. 1840003, 2018.
- LINDEN, J. H. van der; NARSILIO, G. A.; TORDESILLAS, A. Machine learning framework for analysis of transport through complex networks in porous, granular media: a focus on permeability. *Physical Review E*, APS, v. 94, n. 2, p. 022904, 2016.
- MITCHELL, T. M. Does machine learning really work? *AI magazine*, v. 18, n. 3, p. 11–11, 1997.
- MNIH, V.; KAVUKCUOGLU, K.; SILVER, D.; GRAVES, A.; ANTONOGLOU, I.; WIERSTRA, D.; RIEDMILLER, M. Playing atari with deep reinforcement learning. *arXiv preprint arXiv:1312.5602*, 2013.
- MURPHY, K. P. *Machine learning: a probabilistic perspective*. [S.l.]: MIT press, 2012.
- NIELSEN, M. A. *Neural networks and deep learning*. [S.l.]: Determination press San Francisco, CA, 2015. v. 25.

- NIXON, M.; AGUADO, A. *Feature extraction and image processing for computer vision*. [S.l.]: Academic press, 2019.
- PARIS, S.; KORNPORST, P.; TUMBLIN, J.; DURAND, F. *Bilateral filtering: Theory and applications*. [S.l.]: Now Publishers Inc, 2009.
- PHILLIPS, D. *Image processing in C*. [S.l.]: R & D Publications Lawrence, 1994. v. 724.
- QUEIROZ, J. E. R. de; GOMES, H. M. Introdução ao processamento digital de imagens. *Rita*, v. 13, n. 2, p. 11–42, 2006.
- REGO, E. A.; BUENO, O. A. D. *Desenvolvimento de Metodo de Binarizacao para Analise de Rochas Reservatorio Tipicas da Bacia de Campos*. Tese (Doutorado) — Dissertacao (Msc Dissertation) — UENF/LENEP, 2010.
- RODRIGUEZ, O.; PORCHER, T.; PLANES, V.; MECUSON, G.; BOUVIER, R. Non destructive testing of cmc engine internal parts from x-ray tomographic images. In: *9th Int. Conf. Industrial Computed Tomography, Padova, Italy*. [S.l.: s.n.], 2019.
- ROSA, A. J.; CARVALHO, R. de S.; XAVIER, J. A. D. *Engenharia de reservatórios de petróleo*. [S.l.]: Interciência, 2006.
- RUBO, R. A.; CARNEIRO, C.; MICHELON, M.; GIORIA, R. Digital petrography: Mineralogy and porosity identification using machine learning algorithms in petrographic thin section images. *Journal of Petroleum Science and Engineering*, v. 183, p. 106382, 08 2019.
- SAPORETTI, C. M.; FONSECA, L. G. da; PEREIRA, E.; OLIVEIRA, L. C. de. Machine learning approaches for petrographic classification of carbonate-siliciclastic rocks using well logs and textural information. *Journal of Applied Geophysics*, Elsevier, v. 155, p. 217–225, 2018.
- SHUKLA, N.; FRICKLAS, K. *Machine learning with TensorFlow*. [S.l.]: Manning Greenwich, 2018.
- SILVA, L. Uma aplicação de árvores de decisão, redes neurais e knn para a identificação de modelos arma não sazonais e sazonais. *Rio de Janeiro. 145p. Tese de Doutorado-Departamento de Engenharia Elétrica, Pontifícia Universidade Católica do Rio de Janeiro*, 2005.
- SIMONYAN, K.; ZISSERMAN, A. Very deep convolutional networks for large-scale image recognition. *arXiv preprint arXiv:1409.1556*, 2014.
- SUDAKOV, O.; BURNAEV, E.; KOROTEEV, D. Driving digital rock towards machine learning: Predicting permeability with gradient boosting and deep neural networks. *Computers & geosciences*, Elsevier, v. 127, p. 91–98, 2019.
- SZELISKI, R. *Computer vision: algorithms and applications*. [S.l.]: Springer Science & Business Media, 2010.
- TAIGMAN, Y.; YANG, M.; RANZATO, M.; WOLF, L. Deepface: Closing the gap to human-level performance in face verification. In: *Proceedings of the IEEE conference on computer vision and pattern recognition*. [S.l.: s.n.], 2014. p. 1701–1708.

TAN, H. H.; LIM, K. H. Vanishing gradient mitigation with deep learning neural network optimization. In: IEEE. *2019 7th International Conference on Smart Computing & Communications (ICSCC)*. [S.l.], 2019. p. 1–4.

TERRY, R. E.; ROGERS, J. B.; CRAFT, B. C. *Applied petroleum reservoir engineering*. [S.l.]: Pearson Education, 2015.

VELHO, L.; FRERY, A. C.; GOMES, J. *Image processing for computer graphics and vision*. [S.l.]: Springer Science & Business Media, 2009.

Índice Remissivo

A

Acrônimos, xvi
Agradecimentos, v
Alfabeto Grego, xiv
Alfabeto Latino, xiv
Amostragem, 23
Árvores de Decisão, 42

C

Capilaridade, 15
Classificação da Pesquisa, 53
cor, 25

D

dedicação, iv
discretização, 23

E

equação da *Darcy*, 20
Equação de *Poiseuille*, 18
Escopo do Problema, 1

F

Filtros de Imagens, 30
Florestas Aleatórias, 42
Funções de Ativação, 44

H

Hipóteses, 53
Histograma, 28

I

Imagens Digitais, 23
índice *Gili*, 43
Inteligência Artificial, 40
Introdução, 1

L

luminância, 27

M

Machine Learning, 40
Metodologia, 52

molhabilidade, 16
Motivação Para o Tema, 52

N

Nomenclatura, xiv

O

Objetivos, 3
Orçamentos, 57
Organização do Documento, 4

P

Permeabilidade, 18
permeabilidade absoluta, 20
Petrofísica, 13
Porosidade, 14
porosidade efetiva, 14
porosidade total, 14

Q

Quantização, 23

R

reconstrução, 23
Redes Neurais Artificiais, 44
Revisão Bibliográfica, 5
Revisão de Conceitos, 13
rocha reservatório, 13

S

Saturação, 15
saturação, 27
Segmentação, 33
Símbolos, xvi
Sistemas de Cores, 25
Sub-índices, xv
Super-índices, xv

T

taxa de amostragem, 24
tensão superficial, 16
tonalidade, 27